



**UNIVERSITÉ DE
MONTPELLIER**



**STATISTIQUE
SCIENCE DES DONNÉES**
UNIVERSITÉ DE MONTPELLIER

MASTER II STATISTIQUES ET SCIENCES DES DONNÉES

Parcours Biostatistique

Identification des déterminants génétiques de la pathogénicité de la dengue

Présenté par :
Damien MARIAC

Encadré par :
Vincent PEDERGNANA

Tuteur FdS :
Ludovic Menneteau

Jury :
Élodie BRUNEL-PICCININI
Xavier BRY
Benoite DE SAPORTA

Année universitaire 2025-2026



Table des matières

1	Environnement	2
2	Contexte	3
2.1	Contexte du sujet	3
2.2	Contexte biologique	3
3	Préparation des données	5
3.1	Le séquençage viral	5
3.2	Alignements multiples de séquences	6
3.2.1	Alignement progressif par rapport à une séquence de référence	6
3.2.2	Matrices de substitution	6
3.2.3	Pénalités de gap	8
3.3	Traitement des valeurs manquantes	8
4	Modélisation statistique	9
4.0.1	Modèle d'association "classique"	9
4.0.2	Limites du modèle "classique"	10
4.1	Modèle avec dépendances : Graph Fused Lasso	10
4.1.1	Construction du graphe de corrélation	10
4.1.2	Choix des paramètres de régularisation	11
4.1.3	Optimisation du modèle : algorithme FISTA	11
4.1.4	Calculs du gradient	12
4.1.5	Calculs du gradient	13
4.1.6	Limites de l'algorithme FISTA	14
4.2	Modèle avec effets aléatoires	14
4.2.1	Estimation - Test du score de Rao	15
4.2.2	Estimation approchée de l'effet β_{ij}	16
5	Résultats et discussion	20
5.1	Choix du codage	20
5.1.1	Description des données hépatite C	20
5.1.2	Description des données Dengue	20
5.2	Modèles linéaire généralisé avec effets aléatoires	21
5.2.1	Codage binaire sur l'HCV	21
5.2.2	Codage binaire sur la dengue	25
5.2.3	Avec un codage continu sur l'HCV	26
5.2.4	Avec un codage continu sur la dengue	29
5.3	Performances du modèle retenu	29
6	Conclusion et perspectives	30
7	Annexes	31
7.1	Annexe 1	31
8	Bibliographie	33

1 Environnement

UMR MIVEGEC.

2 Contexte

2.1 Contexte du sujet

La sévérité d'une infection virale varie fortement d'un individu à l'autre. Cette variabilité est en partie due à la diversité génétique de l'hôte et du virus. Les deux génomes interagissent indirectement entre eux par le biais du système immunitaire. Le virus est soumis à la pression de sélection exercée par le système immunitaire de l'hôte, et le génome de l'hôte cherche à éliminer le virus de l'organisme.

L'objectif de ce stage est de proposer de nouveaux modèles permettant de faciliter l'étude d'associations entre les variants génétiques de l'hôte et les mutations virales, afin de mieux comprendre les mécanismes des réponses immunitaires et des interactions entre les deux génomes.

Historiquement, les études d'association sont menées sur les symptômes provoqués par l'infection. Mais ceux-ci sont souvent largement influencés par des facteurs tels que l'environnement, l'alimentation ou les habitudes physiques.

Pour pallier ce problème, il existe depuis quelques années une variante de cette approche. On cherche à identifier les variants génétiques de l'hôte qui influencent l'évolution du génome viral. Cette approche est appelée *Genome-to-Genome* (GxG). L'idée est que les mutations virales sont le reflet de la pression de sélection exercée par le système immunitaire de l'hôte. Ainsi, en identifiant les variants génétiques de l'hôte associés à certaines mutations virales, on peut obtenir des informations sur les mécanismes immunitaires impliqués dans la réponse à l'infection.

Ce qui fait toute la difficulté de cette approche est la haute dimensionnalité des données. En effet, on a du côté des hôtes des centaines de milliers de variants génétiques et du côté des virus des centaines de mutations après avoir filtré les sites dépassant un certain taux de variabilité. De plus, les individus issus de régions géographiques et d'ethnies différentes présentent des différences génétiques, ce qui biaise les résultats d'association. Il est aussi possible que certains virus soient issus d'une même souche et partagent des mutations communes sans pour autant être responsables d'une pression de sélection. Il est donc nécessaire de prendre en compte la structure de population des hôtes et du virus.

Afin de mieux comprendre les mécanismes à l'origine de cette diversité génétique, il est nécessaire de rappeler brièvement le cycle de vie d'un virus et son interaction avec le système immunitaire.

2.2 Contexte biologique

Le virus est une entité biologique qui ne peut pas se reproduire par elle-même. Il a besoin d'un hôte pour se multiplier et se propager. Il est constitué d'une coque qui protège son matériel génétique, cela peut être de l'ADN ou de l'ARN. La nature du support de l'information ADN ou ARN dicte la réplication, ce qui a un impact majeur sur sa diversité génétique. De ce fait, les virus à ARN ont un taux de mutation beaucoup plus élevé que les virus à ADN. Cette haute variance est fondamentale : elle permet au virus de s'adapter très rapidement pour trouver des solutions face aux défenses de l'hôte.

Dans le cadre de ce stage, nous avons travaillé sur le virus de l'hépatite C dont on a déjà identifié des liaisons afin de pouvoir l'étendre au virus de la dengue. Ce sont tous deux des virus

à ARN qui présentent une grande diversité génétique.

La multiplication du virus dépend entièrement de la machinerie cellulaire de l'hôte. L'infection débute lorsqu'un virus reconnaît un récepteur spécifique à la surface d'une cellule. Après son entrée dans celle-ci, son génome est libéré dans le cytoplasme où il est répliqué grâce aux enzymes virales ou cellulaires. Les ARN messagers viraux sont ensuite traduits par les ribosomes de la cellule afin de produire les protéines virales nécessaires au cycle infectieux.




FIGURE 1 – Cycle de vie d'un virus à ARN.

Lors de cette infection, le système immunitaire met en place plusieurs mécanismes de défense. Comme par exemple la production d'interférons qui est une molécule chargée de limiter la réplication du virus. Mais développe aussi l'immunité adaptative en entraînant certains lymphocytes à reconnaître les virus et à les détruire.

La réponse immunitaire exerce une forte pression de sélection sur le virus. Cela signifie que toute mutation permettant de diminuer la reconnaissance d'une protéine virale par le système immunitaire peut conférer un avantage évolutif. Au fil des cycles de réplication, ces mutations peuvent être sélectionnées et devenir majoritaires au sein de la population virale présente chez un individu.

Dans le cadre de ce stage, nous nous sommes intéressés à deux virus à ARN : le virus de l'hépatite C (HCV) et le virus de la dengue (DENV). Tous deux présentent une importante diversité génétique, conséquence directe de leur fort taux de mutation. Le but étant de trouver de nouveaux modèles permettant d'identifier de nouveaux variants génétiques. La stratégie étant de le tester sur un jeu de données (HCV) dont on a déjà identifié des liaisons entre les variants génétiques de l'hôte et les mutations virales. Puis d'étendre cette approche sur le virus de la dengue.

3 Préparation des données

Cette partie détaille les étapes de collecte, d'alignement des séquences virales et de gestion des données manquantes faites avant toute modélisation statistique.

Les données utilisées dans ce type d'étude nécessitent l'acquisition simultanée d'informations génétiques sur le pathogène et sur son hôte. Les échantillons biologiques consistent généralement en des prélèvements sanguins effectués chez les patients infectés. Pour le génome viral, l'ARN de l'HCV est extrait à partir du plasma sanguin des patients. Ce matériel est ensuite amplifié et séquencé à l'aide de technologies de séquençage, ce qui permet de capturer l'ensemble des variants présents chez un individu et d'en dégager une séquence consensus par patient.

3.1 Le séquençage viral

Pour analyser le génome du virus présent chez un patient, il est important de comprendre comment les données génétiques sont techniquement lues par les machines (les séquenceurs).

Contrairement à ce que l'on pourrait penser, un séquenceur ne lit pas le génome du virus d'une seule traite, de la première à la dernière « lettre » (nucléotide). Les technologies modernes de séquençage à haut débit procèdent différemment : elles découpent l'ARN viral en des millions de minuscules fragments, appelés des *reads*. La machine va ensuite lire ces petits fragments de manière individuelle et désordonnée. Pour se représenter ce processus, on peut imaginer un livre (le génome viral) qui serait passé dans une déchiqueteuse à papier. On se retrouve avec des milliers de petites bandes de papier contenant chacune quelques mots. Pour reconstituer l'histoire, un algorithme informatique va comparer ces bandes, chercher les mots qui se chevauchent, et les aligner les unes par rapport aux autres, souvent en s'aidant d'un « texte de référence » connu (comme la séquence externe H77 pour le HCV).

Puisque nous avons généré des millions de petits fragments à partir de milliers de copies du virus présentes dans le sang du patient, un « mot » spécifique du livre ne sera pas lu une seule fois, mais des dizaines, voire des centaines de fois.




FIGURE 2 – Représentation schématique de l'alignement des lectures (*reads*) sur une séquence de référence.

Lorsqu'on observe un site précis du génome (par exemple, la position 1450), on constate que de nombreux petits fragments se superposent à cet endroit. Le nombre total de fragments qui couvrent une position donnée définit sa profondeur.

La profondeur est une information cruciale puisqu'elle permet la correction des erreurs. Les séquenceurs font parfois des erreurs de lecture. Si un seul fragment indique une mutation à une position, il peut s'agir d'un artefact technique. En revanche, si la profondeur est de 100 et que 99 fragments indiquent cette même mutation, nous avons la certitude statistique qu'elle est réelle.

Ainsi, l'alignement de cette multitude de petits fragments n'est pas un défaut technique, mais une nécessité qui donne tout son relief et sa fiabilité à l'analyse génétique du virus.

3.2 Alignements multiples de séquences

L'alignement multiple de séquences (MSA) consiste à disposer simultanément plusieurs séquences biologiques (nucléotidiques ou protéiques) de manière à faire correspondre les positions homologues, c'est-à-dire dérivées d'un ancêtre commun au cours de l'évolution. Contrairement à l'alignement par paires (deux séquences), l'alignement multiple permet d'identifier des régions conservées, des motifs fonctionnels ou structuraux communs à un ensemble de séquences, et sert de base à des analyses phylogénétiques. Puisque l'idée est de pouvoir considérer les positions du virus comme des variables.

Il s'agit d'un problème de haute complexité algorithmique : trouver l'alignement optimal de N séquences exacte a une complexité qui croît exponentiellement avec le nombre de séquences, de l'ordre de $O(L^N)$ pour N séquences de longueur L . Pour cette raison, des méthodes heuristiques sont généralement utilisées en pratique.

3.2.1 Alignement progressif par rapport à une séquence de référence

Dans notre cas, nous avons réalisé un alignement progressif basé sur une séquence de référence.

Cette approche consiste dans un premier temps à choisir une séquence de référence (souvent la plus longue, la plus représentative, ou une séquence d'intérêt particulier ou consensus).

Puis aligner successivement chaque autre séquence du jeu de données contre cette référence, par alignement deux à deux.

Enfin, fusionner progressivement ces alignements par paires en un alignement multiple global, en insérant des gaps (-) aux positions nécessaires pour maintenir la cohérence des colonnes entre toutes les séquences.

Cette stratégie est une simplification efficace par rapport aux méthodes progressives classiques (type ClustalW) qui construisent d'abord un arbre guide (*guide tree*) à partir des similarités deux à deux, puis alignent les séquences en suivant cet arbre. L'approche par référence unique est plus rapide, mais suppose que la séquence de référence est suffisamment représentative pour bien guider l'alignement de l'ensemble des autres séquences.

3.2.2 Matrices de substitution

L'alignement de deux séquences repose sur un système de score permettant de quantifier la ressemblance entre deux acides aminés dans une colonne de l'alignement. Comme les vingt acides aminés ne sont en effet pas interchangeables de manière équivalente, on ne peut pas se contenter d'un simple score binaire.

Certaines substitutions sont dites *conservatives* : elles remplacent un acide aminé par un autre

présentant des propriétés physico-chimiques voisines. De telles substitutions altèrent en général peu la structure et la fonction de la protéine, et sont donc fréquemment observées entre séquences homologues. À l'inverse, les substitutions dites *radicales* remplacent un résidu par un autre aux propriétés très différentes, et sont bien plus rarement tolérées par la sélection naturelle.

Une matrice de substitution est donc une matrice carrée S de dimension 20×20 , symétrique, dont le coefficient $s(a, b)$ représente le score attribué à l'alignement de l'acide aminé a avec l'acide aminé b . Ce score est d'autant plus élevé que la substitution est jugée plausible ou peu coûteuse, et d'autant plus faible (voire négatif) qu'elle est jugée improbable. Les termes diagonaux $s(a, a)$, correspondant à la conservation d'un résidu, sont naturellement les plus favorables.

On distingue classiquement deux grandes familles de matrices :

- Les matrices empiriques, construites à partir de l'observation des substitutions réellement constatées dans de grands jeux d'alignements de protéines homologues. C'est le cas des matrices PAM (*Point Accepted Mutation*, Dayhoff *et al.*, 1978) et BLOSUM (*BLOcks SUBstitution Matrix*, Henikoff & Henikoff, 1992). Leurs coefficients sont des rapports de vraisemblance logarithmiques (*log-odds*) de la forme

$$s(a, b) = \frac{1}{\lambda} \log \frac{q_{ab}}{p_a p_b},$$

où q_{ab} est la fréquence d'observation du couple (a, b) dans des alignements de référence, p_a et p_b les fréquences d'apparition de chaque acide aminé, et λ un facteur d'échelle. Un score positif traduit ainsi une substitution plus fréquente que ce que prédirait le hasard.

- Les matrices physico-chimiques, qui ne reposent pas sur des données évolutives mais sur la comparaison objective des propriétés chimiques des chaînes latérales des acides aminés. Elles définissent une *distance* entre acides aminés, et non directement un score de similarité. Les matrices de Grantham (1974), de Miyata (1979) ou de Sneath (1966) appartiennent à cette catégorie.

Le choix de la matrice n'est pas neutre : il conditionne directement l'alignement obtenu, et donc l'ensemble des analyses qui en découlent.

Plus tard dans ce travail, on utilisera un nouveau codage basé sur la matrice de Grantham (1974). Son principe est de quantifier la *dissimilarité chimique* entre deux acides aminés à partir de trois propriétés de leur chaîne latérale, jugées déterminantes pour le comportement du résidu au sein de la protéine : la composition, la polarité et le volume moléculaire.

Les valeurs obtenues s'échelonnent ainsi de 5, pour le couple leucine/isoleucine (substitution quasiment neutre sur le plan chimique), à 215 pour le couple cystéine/tryptophane, qui constitue la substitution la plus radicale au sens de ce critère.

L'intérêt de cette matrice est qu'elle repose sur des grandeurs physico-chimiques mesurables et indépendantes de tout jeu de données évolutif : elle n'introduit donc pas de biais lié à la composition des bases de données ayant servi à construire les matrices empiriques, et ne présuppose aucune distance évolutive particulière entre les séquences comparées (là où le choix d'une matrice PAM ou BLOSUM suppose implicitement un degré de divergence donné). En contrepartie, elle ignore la réalité observée des substitutions acceptées au cours de l'évolution, et notamment les contraintes fonctionnelles propres à certains sites.

/	Ser	Arg	Leu	Pro	Thr	Ala	Val	Gly	Ile	Phe	Tyr	Cys	His	Gln	Asn	Lys	Asp	Glu	Met	Trp
Ser	0	110	145	74	58	99	124	56	142	155	144	112	89	68	46	121	65	80	135	177
Arg	110	0	102	103	71	112	96	125	97	97	77	180	29	43	86	26	96	54	91	101
Leu	145	102	0	98	92	96	32	138	5	22	36	198	99	113	153	107	172	138	15	61
Pro	74	103	98	0	38	27	68	42	95	114	110	169	77	76	91	103	108	93	87	147
Thr	58	71	92	38	0	58	69	59	89	103	92	149	47	42	65	78	85	65	81	128
Ala	99	112	96	27	58	0	64	60	94	113	112	195	86	91	111	106	126	107	84	148
Val	124	96	32	68	69	64	0	109	29	50	55	192	84	96	133	97	152	121	21	88
Gly	56	125	138	42	59	60	109	0	135	153	147	159	98	87	80	127	94	98	127	184
Ile	142	97	5	95	89	94	29	135	0	21	33	198	94	109	149	102	168	134	10	61
Phe	155	97	22	114	103	113	50	153	21	0	22	205	100	116	158	102	177	140	28	40
Tyr	144	77	36	110	92	112	55	147	33	22	0	194	83	99	143	85	160	122	36	37
Cys	112	180	198	169	149	195	192	159	198	205	194	0	174	154	139	202	154	170	196	215
His	89	29	99	77	47	86	84	98	94	100	83	174	0	24	68	32	81	40	87	115
Gln	68	43	113	76	42	91	96	87	109	116	99	154	24	0	46	53	61	29	101	130
Asn	46	86	153	91	65	111	133	80	149	158	143	139	68	46	0	94	23	42	142	174
Lys	121	26	107	103	78	106	97	127	102	102	85	202	32	53	94	0	101	56	95	110
Asp	65	96	172	108	85	126	152	94	168	177	160	154	81	61	23	101	0	45	160	181
Glu	80	54	138	93	65	107	121	98	134	140	122	170	40	29	42	56	45	0	126	152
Met	135	91	15	87	81	84	21	127	10	28	36	196	87	101	142	95	160	126	0	67
Trp	177	101	61	147	128	148	88	184	61	40	37	215	115	130	174	110	181	152	67	0

FIGURE 3 – Matrice de distance de Grantham (1974)

3.2.3 Pénalités de gap

Enfin, l'algorithme d'alignement utilisé (de type Needleman-Wunsch, pour un alignement global) intègre une pénalité d'ouverture de gap (un trou dans le sequence) ainsi qu'une éventuelle pénalité d'extension de gap (une suite de trou), afin d'éviter la multiplication de petites insertions/délétions dispersées et de favoriser des gaps regroupés, biologiquement plus plausibles (une seule insertion/délétion plutôt que plusieurs événements ponctuels indépendants).

3.3 Traitement des valeurs manquantes

La présence de valeurs manquantes est inhérente aux limites techniques du séquençage et du génotypage, notamment aux erreurs de lecture. Dans le cadre des modèles mixtes (GLMM) utilisés pour les tests d'association (voir plus bas), ces données manquantes bloquent les calculs d'algèbre linéaire, comme l'inversion des matrices de parenté. Le traitement appliqué dépend donc du type de codage retenu pour le jeu de données.

Afin de rester cohérent avec un codage initialement binaire, les valeurs manquantes ont été imputées par la modalité la plus fréquente. Ce choix évite d'obtenir des valeurs différentes de 0 ou 1, ce qui aurait pu compromettre les modèles logistiques, tout en conservant une puissance statistique suffisante lors du recodage par transition d'acide aminé (voir section suivante). Cette approche permet enfin de disposer d'un support commun pour comparer les différentes méthodes entre elles.

4 Modélisation statistique

Dans cette approche *Genome-to-Genome* (GxG), le but est d’identifier des variants génétiques de l’hôte qui influencent l’évolution du génome viral. Cette problématique relève naturellement de modèle supervisé : les caractéristiques génétiques de l’hôte constituent les variables explicatives, tandis que les mutations observées chez le virus représentent les variables à expliquer. Contrairement à une approche non supervisée, qui se limite à décrire les structures présentes dans les données, un modèle supervisé permet de mettre en évidence des associations statistiques entre les deux génomes tout en tenant compte d’éventuels facteurs de confusion, tels que la stratification des populations hôtes et virus ou de caractère propre à l’individu.

4.0.1 Modèle d’association “classique”

Le modèle proposé par [?] vise à modéliser la probabilité d’une mutation virale en fonction d’un SNP de l’hôte et de covariables telles que l’âge et le sexe. Pour un site viral et un SNP donnés, une régression logistique est ajustée indépendamment, et ce pour l’ensemble des paires SNP–site viral.

Afin de corriger la structure de population, les auteurs incluent les composantes principales (CP) de l’hôte et du virus comme effets fixes. En effet, les premières CP de l’hôte capturent l’origine ethnique des individus [?], et les premières CP du virus capturent l’origine géographique des souches [?] (Figure 4).




FIGURE 4 – Structure de population capturée par l’ACP.

Les auteurs retiennent les 10 premières CP de l’hôte et les 5 premières du virus. Ce choix reste discutable : ces composantes ne capturent respectivement que XX % et 12 % de la variance cumulée, ce qui suggère qu’une part importante de la structure de population n’est pas corrigée.

Le modèle s’écrit finalement, pour un site de l’hôte SNP_j et un site viral Y_i fixés :

$$\text{logit}(P(Y_i = 1)) = \beta_0 + \beta_{ij} SNP_j + \sum_{k=1}^{10} \gamma_k PC_k^{\text{hôte}} + \sum_{l=1}^5 \delta_l PC_l^{\text{virus}}$$

Une p-value est extraite pour chaque test SNP–site viral. Les tests étant menés indépendamment sur un très grand nombre de paires, une correction pour tests multiples est nécessaire afin de limiter les faux positifs : les auteurs utilisent une correction de Bonferroni, avec un seuil de significativité $\alpha = 10^{-8}$.

4.0.2 Limites du modèle “classique”

Ce modèle présente plusieurs limites ce qui motivent le développement d’une approche plus adaptée à ce type de données.

D’abord, il ne capture qu’une fraction de la structure de population : se limiter à quelques composantes principales, en plus d’ignorer une part importante de la variance, ne permet pas de représenter plus précisément la dépendance génétique entre individus (côté hôte) ou entre souches (côté virus).

Ensuite, il ignore la corrélation entre sites : les mutations virales peuvent être corrélées entre elles du fait de leur proximité structurale (conformation 3D de la protéine), et les SNPs de l’hôte proches sur le génome sont corrélés par déséquilibre de liaison. Ne pas modéliser ces dépendances revient à traiter chaque test comme indépendant alors qu’il ne l’est pas, ce qui biaise l’estimation de la significativité.

Puis, la correction de Bonferroni, en supposant l’indépendance des tests, est très conservatrice dans ce contexte de forte corrélation : elle risque d’écraser un signal réel, en particulier étant donné la très haute dimensionnalité des données (des millions de tests SNP–site viral).

4.1 Modèle avec dépendances : Graph Fused Lasso

Un modèle de type Graph Fused Lasso (GFL) permettrait de pouvoir palier au problème de la corrélation entre sites. Celui-ci reprend le modèle logistique précédent, mais ajoute deux pénalisations sur les coefficients β_{ij} : une pénalité de type Lasso, qui contraint les coefficients à être nuls si le SNP j n’est pas suffisamment associé au site viral i , et une pénalité de fusion sur graphe, qui contraint les coefficients à être similaires lorsque les sites viraux i et i' sont corrélés.

Le modèle s’écrit alors, pour un SNP j fixé :

$$\hat{\beta}_{\cdot j} = \underset{\beta_{\cdot j}}{\operatorname{argmin}} \left\{ - \sum_{i=1}^p \ell_i(\beta_{ij}) + \lambda_1 \sum_{i=1}^p |\beta_{ij}| + \lambda_2 \sum_{(i,i') \in E} w_{ii'} |\beta_{ij} - \beta_{i'j}| \right\}$$

où $\ell_i(\beta_{ij})$ est la log-vraisemblance logistique associée au site viral i , E l’ensemble des arêtes du graphe de corrélation entre sites viraux, $w_{ii'}$ le poids de l’arête reliant les sites i et i' , et λ_1 , λ_2 les paramètres de régularisation contrôlant respectivement la sparsité et l’homogénéité locale des coefficients sur le graphe.

4.1.1 Construction du graphe de corrélation

Afin d’implémenter ce modèle, il est nécessaire de construire un graphe représentant les corrélations entre sites viraux.

Pour éviter d’avoir un biais, on calcule la corrélation sur un autre jeu de données de l’HCV du même serotype. Ces données proviennent de la banque de données du NCBI. On les a alignées par rapport à la séquence consensus de nos données afin de pouvoir faire correspondre les bonnes positions. Puis nous avons calculé la corrélation entre les sites après avoir recodé en variables binaires sous forme de mutation/conservation. C’est avec 5000 séquences que nous obtenons la matrice de corrélation.

Les sites viraux étant binaires, ils sont supposés suivre une loi de Bernoulli, ce qui permet d’estimer leur corrélation de façon paramétrique. Pour deux sites viraux i et i' , de probabilités marginales p_i et $p_{i'}$ et de probabilité jointe $p_{ii'} = P(Y_i = 1, Y_{i'} = 1)$, la corrélation s’écrit :

$$w_{ii'} = \operatorname{corr}(Y_i, Y_{i'}) = \frac{p_{ii'} - p_i p_{i'}}{\sqrt{p_i(1-p_i) p_{i'}(1-p_{i'})}}$$

La matrice de corrélation ainsi obtenue sert de support au graphe : une arête est créée entre deux sites viraux lorsque leur corrélation en valeur absolue dépasse un seuil fixé choisit arbitrairement à 0.7 (comme dans l'article [?]). La Figure 5 représente cette matrice sous forme de heatmap, où les valeurs proches de 1 sont en rouge et celles proches de 0 en jaune.




FIGURE 5 – Matrice de corrélation entre sites viraux sous forme de heatmap.

On remarque que la matrice de corrélation est très creuse, mais qu'elle présente des blocs de corrélations élevées, correspondant à des sites viraux fortement liés entre eux.

4.1.2 Choix des paramètres de régularisation

Il reste à définir les paramètres de régularisation λ_1 et λ_2 . Une validation croisée sur l'ensemble des données étant impossible à mettre en œuvre dans ce contexte de très haute dimensionnalité, elle a été réalisée sur plusieurs sous-ensembles de données, et les résultats ont ensuite été moyennés pour obtenir les paramètres optimaux. On obtient ainsi $\lambda_1 = XX$ et $\lambda_2 = XX$.

4.1.3 Optimisation du modèle : algorithme FISTA

L'estimation des coefficients du modèle revient à minimiser la fonction objectif présentée précédemment, qui se décompose en une partie lisse et une partie non lisse :

$$F(\beta) = \underbrace{f(\beta)}_{\text{log-vraisemblance}} + \underbrace{g(\beta)}_{\text{pénalités}}, \quad \text{où } g(\beta) = \lambda_1 \sum_{i=1}^p |\beta_{ij}| + \lambda_2 \sum_{(i,i') \in E} w_{ii'} |\beta_{ij} - \beta_{i'j}|$$

où f est convexe et différentiable, mais où g est convexe et non différentiable en raison des valeurs absolues. Cette fonction ne possède pas de solution analytique et doit donc être minimisée numériquement.

Pour cela, nous utilisons l'algorithme FISTA (Fast Iterative Shrinkage-Thresholding Algorithm) [?], particulièrement adapté aux problèmes de la forme $\min_{\beta} f(\beta) + g(\beta)$ lorsque f est différentiable à gradient L -Lipschitzien et g admet un opérateur proximal calculable. C'est la méthode principalement utilisée dans les packages R qui implémentent les modèles de type Lasso.

Étape de descente de gradient. À chaque itération k , l'algorithme réalise d'abord un pas de gradient sur la partie lisse f , évalué non pas en β_k mais en un point extrapolé $\mathbf{y}_k$:

$$\mathbf{z}_k = \mathbf{y}_k - \frac{1}{L} \nabla f(\mathbf{y}_k)$$

où $\nabla f(\mathbf{y}_k)$ est le gradient de la log-vraisemblance logistique, de la forme $\mathbf{X}^\top (\mathbf{p}(\mathbf{y}_k) - \mathbf{Y})$, avec $\mathbf{p}(\mathbf{y}_k)$ le vecteur des probabilités prédites $\text{logit}^{-1}(\mathbf{X}\mathbf{y}_k)$, et L une constante de Lipschitz du gradient (majorée ici par la plus grande valeur propre de $\mathbf{X}^\top \mathbf{X}/4$), qui fixe la taille du pas.

Étape de seuillage (opérateur proximal). Le point $\mathbf{z}_k$ est ensuite projeté via l'opérateur proximal de g , défini par :

$$\text{prox}_{g/L}(\mathbf{z}_k) = \underset{\beta}{\text{argmin}} \left\{ \frac{L}{2} \|\beta - \mathbf{z}_k\|_2^2 + g(\beta) \right\}$$

Pour la seule pénalité ℓ_1 , cet opérateur a une solution explicite, le seuillage doux (*soft-thresholding*) :

$$[\text{prox}_{\lambda_1/L, \|\cdot\|_1}(z)]_i = \text{sign}(z_i) \max(|z_i| - \lambda_1/L, 0)$$

qui annule progressivement les coefficients de faible amplitude, ce qui permet de sélectionner uniquement les mutations virales les plus associées au SNP étudié. En présence de la pénalité de fusion sur graphe, l'opérateur proximal combiné $\text{prox}_{g/L}$ n'a plus de forme close et est résolu par

Étape d'accélération. Enfin, FISTA ajoute une étape d'extrapolation de type Nesterov, en combinant les deux dernières estimations β_k et β_{k-1} :

$$\beta_k = \text{prox}_{g/L}(\mathbf{z}_k), \quad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \quad \mathbf{y}_{k+1} = \beta_k + \frac{t_k - 1}{t_{k+1}} (\beta_k - \beta_{k-1})$$

avec $t_1 = 1$ et $\mathbf{y}_1 = \beta_0$. Cette accélération permet d'obtenir une vitesse de convergence en $\mathcal{O}(1/k^2)$, contre $\mathcal{O}(1/k)$ pour l'algorithme ISTA classique (sans extrapolation), tout en conservant une implémentation relativement simple. Cette propriété est particulièrement intéressante dans notre contexte, où le modèle doit être estimé pour un très grand nombre de SNPs et de sites viraux.

4.1.4 Calculs du gradient

L'étape de descente de FISTA nécessite le gradient de la partie lisse f de la fonction objectif. On note n le nombre d'individus et p le nombre de sites viraux. On note également $\mathbf{X} \in \{0, 1, 2\}^{n \times p}$ la matrice des génotypes de l'hôte, de terme général x_{ki} (génotype de l'individu k au SNP i), $\mathbf{Y} = (Y_1, \dots, Y_n)^\top \in \{0, 1\}^n$ le vecteur réponse associé au SNP j , et $\beta_{\cdot j} = (\beta_{1j}, \dots, \beta_{pj})^\top$ le vecteur des coefficients à estimer, avec β_{0j} l'intercept. Et $\mathbf{B} = (\beta_{ij}) \in \mathbb{R}^{p \times q}$ la matrice des coefficients à estimer, et β_{0j} l'intercept associé au site viral j .

De plus, on note :

$$\eta_{kj} = \beta_{0j} + \sum_{i=1}^p x_{ki} \beta_{ij}, \quad \pi_{kj} = \text{logit}^{-1}(\eta_{kj}) = \frac{e^{\eta_{kj}}}{1 + e^{\eta_{kj}}}.$$

Qui sont respectivement le prédicteur linéaire et la probabilité pour l'individu k au site viral j .

j d'obtenir une mutation.

Les individus sont supposés indépendants conditionnellement à leur génotype, la log-vraisemblance du modèle logistique s'écrit donc :

$$\ell(\mathbf{B}) = \sum_{j=1}^q \sum_{k=1}^n \left\{ Y_{kj} \log \pi_{kj} + (1 - Y_{kj}) \log(1 - \pi_{kj}) \right\} = \sum_{j=1}^q \sum_{k=1}^n \left\{ Y_{kj} \eta_{kj} - \log(1 + e^{\eta_{kj}}) \right\},$$

4.1.5 Calculs du gradient

L'étape de descente de FISTA nécessite le gradient de la partie lisse f de la fonction objectif. Notons :

- n le nombre d'individus, p le nombre de SNPs hôtes et q le nombre de sites viraux ;
- $\mathbf{X} \in \{0, 1, 2\}^{n \times p}$ la matrice des génotypes hôtes, de terme général x_{ki} (dosage allélique du SNP i chez l'individu k), dont les colonnes sont centrées et réduites au préalable afin que la pénalisation s'applique de façon homogène ;
- $\mathbf{Y} \in \{0, 1\}^{n \times q}$ la matrice des sites viraux, de terme général Y_{kj} (présence de la mutation j chez l'individu k) ;
- $\mathbf{B} = (\beta_{ij}) \in \mathbb{R}^{p \times q}$ la matrice des coefficients à estimer, et β_{0j} l'intercept associé au site viral j .

Le prédicteur linéaire et la probabilité prédite pour l'individu k au site viral j s'écrivent

$$\eta_{kj} = \beta_{0j} + \sum_{i=1}^p x_{ki} \beta_{ij}, \quad \pi_{kj} = \text{logit}^{-1}(\eta_{kj}) = \frac{e^{\eta_{kj}}}{1 + e^{\eta_{kj}}}.$$

Log-vraisemblance. Les individus étant supposés indépendants conditionnellement à leur génotype, la log-vraisemblance du modèle logistique s'écrit

$$\ell(\mathbf{B}) = \sum_{j=1}^q \sum_{k=1}^n \left\{ Y_{kj} \log \pi_{kj} + (1 - Y_{kj}) \log(1 - \pi_{kj}) \right\} = \sum_{j=1}^q \sum_{k=1}^n \left\{ Y_{kj} \eta_{kj} - \log(1 + e^{\eta_{kj}}) \right\},$$

la seconde égalité s'obtenant en remarquant que $\log \pi_{kj} - \log(1 - \pi_{kj}) = \eta_{kj}$ et $\log(1 - \pi_{kj}) = -\log(1 + e^{\eta_{kj}})$. La partie lisse de la fonction objectif est la log-vraisemblance négative, normalisée par n afin de rendre le choix de λ_1 et λ_2 indépendant de la taille de l'échantillon :

$$f(\mathbf{B}) = -\frac{1}{n} \ell(\mathbf{B}) = \frac{1}{n} \sum_{j=1}^q \sum_{k=1}^n \left\{ \log(1 + e^{\eta_{kj}}) - Y_{kj} \eta_{kj} \right\}.$$

On notera que f est *séparable* en les colonnes de $\mathbf{B}$: seule la pénalité de fusion, portée par le graphe des sites viraux, couple les différents sites entre eux. Le calcul du gradient peut donc être mené site par site, le couplage étant entièrement reporté sur l'opérateur proximal.

Dérivées partielles. Comme $\partial \eta_{kj} / \partial \beta_{ij} = x_{ki}$ et

$$\frac{\partial}{\partial \beta_{ij}} \log(1 + e^{\eta_{kj}}) = \frac{e^{\eta_{kj}}}{1 + e^{\eta_{kj}}} x_{ki} = \pi_{kj} x_{ki},$$

on obtient, pour tout SNP $i \in \{1, \dots, p\}$ et tout site viral $j \in \{1, \dots, q\}$,

$$\frac{\partial f}{\partial \beta_{ij}} = \frac{1}{n} \sum_{k=1}^n x_{ki} (\pi_{kj} - Y_{kj}), \quad \text{et} \quad \frac{\partial f}{\partial \beta_{0j}} = \frac{1}{n} \sum_{k=1}^n (\pi_{kj} - Y_{kj}).$$

Le gradient s'interprète comme la covariance empirique entre le génotype au SNP i et le résidu $\pi_{kj} - Y_{kj}$: un SNP dont la distribution suit les erreurs de prédiction du site viral j verra son coefficient d'autant plus déplacé lors du pas de gradient.

Écriture matricielle. En notant $\mathbf{\Pi}(\mathbf{B}) = (\pi_{kj})_{k,j} \in [0, 1]^{n \times q}$ la matrice des probabilités prédites, les expressions précédentes se résument à

$$\nabla f(\mathbf{B}) = \frac{1}{n} \mathbf{X}^\top (\mathbf{\Pi}(\mathbf{B}) - \mathbf{Y}) \in \mathbb{R}^{p \times q},$$

ce qui correspond à la forme utilisée à l'étape de descente de FISTA, le gradient y étant évalué au point extrapolé plutôt qu'en l'itéré courant. Son évaluation ne requiert que deux produits matriciels, soit un coût en $\mathcal{O}(npq)$ par itération, qui peut être fortement réduit en exploitant le caractère creux de $\mathbf{X}$ et de $\mathbf{B}$ au fil des itérations.

Constante de Lipschitz. En dérivant une seconde fois et en utilisant $\partial \pi_{kj} / \partial \eta_{kj} = \pi_{kj}(1 - \pi_{kj})$, la hessienne de f est bloc-diagonale, chaque bloc correspondant à un site viral :

$$\nabla_{\beta,j}^2 f(\mathbf{B}) = \frac{1}{n} \mathbf{X}^\top \mathbf{W}_j \mathbf{X}, \quad \mathbf{W}_j = \text{diag}(\pi_{kj}(1 - \pi_{kj}))_{k=1,\dots,n}.$$

Comme $\pi(1 - \pi) \leq 1/4$ pour tout $\pi \in [0, 1]$, on a $\nabla^2 f \preceq \frac{1}{4n} \mathbf{X}^\top \mathbf{X}$ uniformément en $\mathbf{B}$, ce qui garantit que ∇f est L -lipschitzien avec

$$L = \frac{1}{4n} \lambda_{\max}(\mathbf{X}^\top \mathbf{X}) = \frac{1}{4n} \sigma_{\max}(\mathbf{X})^2,$$

constante commune à tous les sites viraux. En très grande dimension, cette valeur propre n'est pas calculée explicitement mais approchée par la méthode de la puissance itérée ; à défaut, la majoration $\lambda_{\max}(\mathbf{X}^\top \mathbf{X}) \leq \|\mathbf{X}\|_F^2$ fournit un pas admissible, plus conservateur mais immédiat. Enfin, le gradient ne porte que sur f : les deux pénalités, non différentiables, sont entièrement prises en charge par l'opérateur proximal.

4.1.6 Limites de l'algorithme FISTA

Cependant, dans le contexte de très haute dimensionnalité des données, l'algorithme FISTA met un temps de calcul très long pour converger.

En effet, après avoir testé sur un sous-ensemble de données afin de pouvoir estimer le temps d'implémentation sur l'ensemble des données, on a pu constater un temps de calcul de plusieurs mois pour l'ensemble du jeu de données.

De plus, l'algorithme FISTA ne peut pas être parallélisé du à la dépendance entre les sites qui impose de calculer les coefficients simultanément.

Ainsi, dans le cadre du stage il n'y pas eu de possibilité de tester l'algorithme FISTA sur l'ensemble des données, et nous n'avons pas pu obtenir de résultats. Il est néanmoins possible de tester l'algorithme sur un sous-ensemble de données, mais les résultats obtenus ne sont pas représentatifs de l'ensemble des données. Cette approche a donc été laissée de côté pour se concentrer sur une approche plus adaptée à l'ensemble des données.

Il est donc nécessaire de trouver une alternative à cette approche afin de pouvoir estimer le modèle sur l'ensemble des données.

4.2 Modèle avec effets aléatoires

Le modèle GFL présenté précédemment permet de prendre en compte la corrélation locale entre sites, mais uniquement via un graphe construit. Il ne modélise pas la structure globale de

parenté génétique au sein des populations hôte et virale, pourtant décrite comme un facteur de confusion majeur dans les études d'interaction génome-à-génome [?]. Une approche alternative, largement utilisée dans les études d'association (GWAS) classiques, consiste à modéliser cette structure via des effets aléatoires, plutôt que par un nombre limité de composantes principales ou un graphe de corrélation. Cette stratégie a notamment été adaptée dans un contexte similaire par [?] au travers de la méthode ATOMM (*Adaptive Two-way Mixed Model*), qui introduit un effet aléatoire distinct pour l'hôte et pour le virus.

En essayant de coller les notations le plus possible avec le modèle précédent et en reprenant cette idée, le modèle logistique s'écrit alors comme un modèle mixte linéaire généralisé (GLMM) à deux effets aléatoires :

$$\text{logit}(P(Y_i = 1)) = \beta_0 + W\alpha + X_j\beta_{ij} + \eta_v + \eta_h$$

où $W\alpha$ regroupe les effets fixes (covariables telles que l'âge ou le sexe), $X_j\beta_{ij}$ représente l'effet du SNP j sur le site viral i , et les deux effets aléatoires

$$\eta_v \sim \mathcal{N}(0, \sigma_v^2 K_v), \quad \eta_h \sim \mathcal{N}(0, \sigma_h^2 K_h)$$

capturent respectivement la structure de parenté du virus et de l'hôte, via les matrices de parenté K_v et K_h .

Contrairement aux composantes principales, ces matrices résument l'intégralité de la similarité génétique entre individus (ou souches), sans perte d'information liée à un nombre de dimensions fixé en amont.

Dans ce cadre, l'intérêt principal n'est plus seulement d'estimer les coefficients du modèle, mais de tester la significativité de l'association entre chaque SNP de l'hôte j et chaque site viral i , c'est-à-dire tester " $H_0 : \beta_{ij} = 0$ ". Or, ce test doit être répété pour un très grand nombre de paires SNP-site viral, et une estimation classique du modèle par maximum de vraisemblance nécessiterait de réinverser la matrice de covariance globale à chaque test, ce qui est numériquement impossible à l'échelle de nos données. Il est donc nécessaire d'utiliser une méthode d'estimation factorisée, qui sépare l'estimation des paramètres de nuisance (communs à tous les tests) de celle du test d'association lui-même : le test du score de Rao.

4.2.1 Estimation - Test du score de Rao

L'évaluation de chaque paires de variants (hôte, virus) implique d'ajuster le modèle mixte des millions de fois. Or, l'estimation des composantes de la variance (σ_v^2, σ_h^2) par maximum de vraisemblance nécessite l'inversion répétée de matrices de grande dimension, ce qui représente un coût computationnel important. Les tests du score de Rao est implémenté dans le package *GMMAT* de **R**.

Concrètement, la procédure se déroule en deux étapes :

1. Ajustement sous H_0 : On force le coefficient d'intérêt β_{ij} à 0. Le modèle nul ne contenant que l'intercept et les effets aléatoires. On ajuste le modèle une seule fois par phénotype viral pour estimer les paramètres de nuisance et les composantes de la variance.
2. Calcul du score : Pour chaque variant de l'hôte j , on évalue le gradient de la log-vraisemblance au point $\beta_{ij} = 0$. Si ce gradient est significativement éloigné de zéro, l'hypothèse nulle est rejetée, indiquant une association entre X_j et Y_i .

Cette méthode permet d'éviter le réajustement des effets aléatoires pour chaque SNP testé, réduisant ainsi drastiquement la complexité algorithmique tout en conservant une grande robustesse statistique.




FIGURE 6 – Test du score de Rao

La contre partie de ce test est qu'il ne fournit pas d'estimation directe de l'effet β_{ij} , mais uniquement une statistique de test et une p value associée. Cependant, dans le contexte d'une étude exploratoire visant à identifier des associations potentielles, cette limitation est acceptable. Néanmoins, pour les associations les plus prometteuses, il est possible de réajuster le modèle complet afin d'obtenir des estimations précises des effets et de leurs intervalles de confiance.

Il existe quand même des façons d'obtenir une estimation de l'effet β_{ij} à l'aide des p-values.

4.2.2 Estimation approchée de l'effet β_{ij}

On dispose de n individus, p sites de SNP de l'hôte indexés par $j \in \{1, \dots, p\}$ et q sites viraux indexés par $i \in \{1, \dots, q\}$. Pour un site viral i fixé, on note $\ell_i(\theta)$ la log-vraisemblance pénalisée du modèle mixte et $\theta_{ij} = (\beta_{ij}, \gamma_i)$, $\gamma_i = (\beta_0, \alpha^\top, \sigma_v^2, \sigma_h^2)^\top$, où $\beta_{ij} \in \mathbb{R}$ est le paramètre d'intérêt et γ_i le vecteur des paramètres de nuisance.

On remarquera que les paramètres de nuisance ne dépendent que du site viral i , et non du SNP testé j : c'est là tout l'intérêt de la méthode. Le modèle nul est ajusté q fois — une fois par phénotype viral — alors que $p \times q$ tests sont effectués. Le coût dominant, l'estimation des composantes de la variance (σ_v^2, σ_h^2) , est donc factorisé entre les p SNP.

On rappelle que l'hypothèse testée est $H_0 : \beta_{ij} = 0$ contre $H_1 : \beta_{ij} \neq 0$. On note $\tilde{\theta}_i = (0, \hat{\gamma}_i)$ l'estimateur du maximum de vraisemblance *constraint*, c'est-à-dire l'ajustement du modèle nul, où $\hat{\gamma}_i$ maximise $\gamma \mapsto \ell_i(0, \gamma)$.

Détails :

Le score et la matrice d'information de Fisher se décomposent par blocs à cause de θ_{ij} :

$$U(\theta_{ij}) = \begin{pmatrix} U_\beta \\ U_\gamma \end{pmatrix}, \quad \mathcal{I}(\theta_{ij}) = \begin{pmatrix} \mathcal{I}_{\beta\beta} & \mathcal{I}_{\beta\gamma} \\ \mathcal{I}_{\gamma\beta} & \mathcal{I}_{\gamma\gamma} \end{pmatrix}.$$

Par définition de $\hat{\gamma}_i$, la composante de nuisance du score s'annule au point contraint :

$$U_\gamma(\tilde{\theta}_i) = 0. \quad (1)$$

On introduit l'*information efficace* relative à β_{ij} , définie comme le complément de Schur du bloc de nuisance et évaluée en $\tilde{\theta}_i$:

$$V_{ij} = \mathcal{I}_{\beta\beta} - \mathcal{I}_{\beta\gamma} \mathcal{I}_{\gamma\gamma}^{-1} \mathcal{I}_{\gamma\beta}. \quad (2)$$

Elle mesure l'information disponible sur β_{ij} une fois retirée la part partagée avec les effets fixes et les effets aléatoires. La formule d'inversion par blocs donne $[\mathcal{I}^{-1}]_{\beta\beta} = V_{ij}^{-1}$, et la statistique du score s'écrit alors

$$T_{ij} = \frac{U_{ij}^2}{V_{ij}} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \chi_1^2 \quad \text{sous } H_0, \quad U_{ij} \equiv U_\beta(\tilde{\theta}_i). \quad (3)$$

Proposition 4.1 (Approximation de Newton–Raphson en une itération). *Une itération de l'algorithme de Newton–Raphson initialisée au point contraint $\tilde{\theta}_i$ fournit l'approximation*

$$\boxed{\hat{\beta}_{ij} = \frac{U_{ij}}{V_{ij}}, \quad \widehat{\text{SE}}(\hat{\beta}_{ij}) = \frac{1}{\sqrt{V_{ij}}}} \quad (4)$$

Démonstration. L'itération de Newton–Raphson appliquée à l'équation de vraisemblance $U(\theta) = 0$ à partir de $\tilde{\theta}_i$ s'écrit $\hat{\theta}^{(1)} = \tilde{\theta}_i + \mathcal{I}(\tilde{\theta}_i)^{-1} U(\tilde{\theta}_i)$. En extrayant la composante en β , et en utilisant successivement (1) puis l'inversion par blocs :

$$\hat{\beta}_{ij} = \underbrace{0}_{\text{valeur initiale}} + [\mathcal{I}^{-1}]_{\beta\beta} U_{ij} + [\mathcal{I}^{-1}]_{\beta\gamma} \underbrace{U_\gamma(\tilde{\theta}_i)}_{=0} = \frac{U_{ij}}{V_{ij}}.$$

L'annulation du second terme est essentielle : c'est elle qui rend l'estimateur indépendant d'une mise à jour simultanée des paramètres de nuisance, et donc calculable sans réajuster le modèle mixte. $\square$

Remarque 4.2 (Interprétation). De façon équivalente, l'estimateur revient à remplacer la log-vraisemblance profilée par son approximation quadratique au voisinage de $\beta_{ij} = 0$: son développement de Taylor à l'ordre 1, $\partial \ell_i^{\text{prof}} / \partial \beta \simeq U_{ij} - V_{ij} \beta$, s'annule exactement en U_{ij}/V_{ij} . Le score U_{ij} donne la pente de la vraisemblance en 0, l'information V_{ij} sa courbure, et leur rapport localise le sommet de la parabole ainsi ajustée.

Cohérence avec les p-values déjà calculées. En reportant (4) dans la statistique de Wald, on obtient

$$z_{\text{Wald}} = \frac{\hat{\beta}_{ij}}{\widehat{\text{SE}}(\hat{\beta}_{ij})} = \frac{U_{ij}/V_{ij}}{V_{ij}^{-1/2}} = \frac{U_{ij}}{\sqrt{V_{ij}}} = z_{\text{score}}, \quad (5)$$

c'est-à-dire exactement la racine signée de (3). Les coefficients reconstruits sont donc rigoureusement compatibles avec les p-values issues du criblage : l'approximation n'introduit aucune incohérence dans les résultats déjà produits, et le signe de U_{ij} fournit directement le sens de l'association.

Expression opérationnelle dans le modèle mixte. Dans l'implémentation *GMMAT*, le modèle nul est ajusté par quasi-vraisemblance pénalisée. En notant $\hat{\pi}^{(i)}$ le vecteur des probabilités prédites sous H_0 pour le site viral i , $D_i = \text{diag}(\hat{\pi}_k^{(i)}(1 - \hat{\pi}_k^{(i)}))$, et

$$\Sigma_i = D_i^{-1} + \hat{\sigma}_v^2 K_v + \hat{\sigma}_h^2 K_h, \quad P_i = \Sigma_i^{-1} - \Sigma_i^{-1} W (W^\top \Sigma_i^{-1} W)^{-1} W^\top \Sigma_i^{-1},$$

le score et sa variance prennent la forme

$$U_{ij} = X_j^\top P_i \tilde{Y}_i, \quad V_{ij} = X_j^\top P_i X_j, \quad (6)$$

où $\tilde{Y}_i$ désigne le vecteur de travail associé au site viral i . La matrice de projection P_i est la forme opérationnelle de l'information efficace (2) : elle retire simultanément de X_j la part expliquée par les covariables W et celle absorbée par les structures de parenté K_v et K_h . Cruciale pour le coût de calcul, P_i ne dépend que de i : elle est calculée une seule fois par site viral, et chaque SNP ne coûte plus que deux produits matrice-vecteur.

Domaine de validité. L'estimateur (4) est *efficace au premier ordre* : sous les alternatives locales $\beta_{ij} = h/\sqrt{n}$, il est asymptotiquement équivalent au maximum de vraisemblance et partage sa loi limite. Cette propriété repose toutefois sur la proximité entre le point d'initialisation $\beta_{ij} = 0$ et la valeur vraie, ce qui reste vérifié pour l'immense majorité des $p \times q$ paires testées, dont l'effet est nul ou faible. La qualité de l'approximation se dégrade en revanche dans trois situations :

- **effets de forte amplitude** — l'approximation quadratique de la vraisemblance induit une atténuation de $|\hat{\beta}_{ij}|$ vers zéro. Paradoxalement, ce sont donc les associations les plus significatives, celles qui nous intéressent, qui sont les moins bien estimées ;
- **variants rares ou sites viraux déséquilibrés** — lorsque la fréquence allélique du SNP ou celle du variant viral est faible, la courbure de la vraisemblance est mal décrite par V_{ij} , et la convergence vers la loi χ_1^2 de (3) est elle-même lente ;
- **quasi-séparation** — le maximum de vraisemblance diverge alors que $\hat{\beta}_{ij}$ reste fini, l'écart devenant arbitrairement grand.

À ces limites propres à l'approximation s'ajoute le biais connu de la quasi-vraisemblance pénalisée pour les réponses binaires, dont $\hat{\beta}_{ij}$ hérite.

Stratégie retenue. Ces considérations conduisent à une procédure en deux temps, qui prolonge naturellement celle décrite plus haut :

1. **Criblage.** Les $p \times q$ tests du score fournissent, à coût nul, les estimations $\hat{\beta}_{ij} = \text{SCORE}/\text{VAR}$. Celles-ci sont utilisées pour l'exploration — sens et amplitude relative des effets, ordonnancement des associations, représentations de type *volcano plot* — usages pour lesquels une précision au premier ordre est amplement suffisante.
2. **Confirmation.** Les paires franchissant le seuil de significativité après correction pour tests multiples font l'objet d'un réajustement complet du modèle mixte, via `glmm.wald()`. Le nombre de modèles concernés étant réduit de plusieurs ordres de grandeur, le surcoût est négligeable au regard du criblage initial. Cette étape fournit les estimations

et intervalles de confiance rapportés dans les résultats, précisément dans le régime où l'approximation (4) est la moins fiable.

Ce dispositif combine ainsi le gain computationnel du test du score, seul praticable à l'échelle de $p \times q$ paires, et l'exactitude du maximum de vraisemblance là où elle est nécessaire.

5 Résultats et discussion

5.1 Choix du codage

Le choix du codage des données du virus est un point qui a longtemps été discuté pendant ce stage. En effet, le codage initial des données est binaire : 0 pour l'absence de mutation et 1 pour la présence de mutation par rapport à la séquence de référence (majoritaire au jeu de donnée). Ceci afin de pouvoir garantir suffisamment de puissance statistique pour les tests d'association. Les sites viraux sont très variables puisque il est à ARN. Mais certains sites sont très conservés et ne présentent que très peu de mutations. Il est donc nécessaire dans un premier temps de filtrer les sites viraux afin de ne garder que ceux présentant une variabilité suffisante. Les sites viraux présentant une variabilité de moins de 5% ont été retirés du jeu de données.

A ce stade, plusieurs codages ont été envisagés pour le jeu de données du virus. Le codage initial binaire et un codage par transition d'acide aminé.

Avec le codage binaire, on ne prend pas en compte la nature de la mutation. On ne sait pas si la mutation est grave ou non. Puisque passer d'un acide aminé à un autre pourrait avoir un impact sur la structure de la protéine et donc sur son rôle pouvant induire des comportements différents du virus. Mais celui-ci présente l'avantage de pouvoir garder un maximum de sites viraux et donc de pouvoir garder une puissance statistique suffisante pour les tests d'association.

Au final, après filtrage des sites viraux, on a pu garder 427 sites viraux pour le codage binaire.

Avec le codage par transition d'acide aminé, on prend en compte la nature de la mutation. On encode les mutations par rapport à une matrice de substitution qui permet de savoir si la mutation est conservatrice ou non. Il s'agit de la matrice de Grantham. Mais celui-ci présente l'inconvénient de réduire le nombre de sites viraux et donc de réduire la puissance statistique pour les tests d'association. Ainsi, le fait de passer à un codage continu baisse le nombre de sites viraux et la précision des tests d'association.

5.1.1 Description des données hépatite C

Pour ce stage, on possède un jeu de donnée de l'Hépatite C (HCV) de genotype 3a. Il est constitué de n individus infectés par le virus de l'hépatite C. Pour chaque individu, on possède des données sur le virus et sur l'hôte. On possède pour chaque individu en plus des informations supplémentaires sur l'âge, le sexe, la charge virale, le groupe ethnique, et la provenance géographique des séquences.

On possède une grande quantité d'individus provenant d'Angleterre. Mais surtout une grande quantité d'individus de groupe ethnique blanc et avec pour certains pays une proportion plus modérée de groupe ethnique asiatique.

Cirrhosis maladie

5.1.2 Description des données Dengue




FIGURE 7 – Distribution de l'âge des individus




FIGURE 8 – Boxplot

5.2 Modèles linéaire généralisé avec effets aléatoires

5.2.1 Codage binaire sur l'HCV

L'implémentation du modèle a été réalisée à l'aide du package *GMMAT* de R, sur le cluster *ITROP*. Le nombre de tests d'association à effectuer correspond au produit du nombre de SNPs de l'hôte par le nombre de sites viraux polymorphes retenus, soit environ 10^9 tests. Sans parallélisation, le temps de calcul est estimé à deux jours. Le calcul a donc été partitionné sur 36 coeurs, ce qui ramène le temps d'exécution à environ une heure.

Le volume de tests impose une correction stricte du seuil de significativité. Nous retenons ici un seuil de 10^{-8} , qui correspond à la correction de Bonferroni appliquée à l'échelle d'un site viral

(soit environ 0,05 divisé par le nombre de SNPs testés). Cette correction reste conservatrice puisqu'elle suppose l'indépendance des tests, hypothèse mise en défaut par le déséquilibre de liaison entre SNPs voisins ; le nombre effectif de tests indépendants est en réalité plus faible. Nous obtenons un total de 287 couples (SNP de l'hôte, site viral) dépassant le seuil de 10^{-8} . Ce chiffre ne doit pas être interprété comme 287 signaux indépendants : un même locus, représenté par plusieurs SNPs corrélés, peut contribuer à de nombreuses paires significatives.

La figure 9 résume l'ensemble des associations détectées. Les chromosomes de l'hôte sont disposés sur une partie de la circonférence, les protéines virales sur l'autre ; chaque lien relie un SNP à un site viral. Les liens gris correspondent aux associations dépassant le seuil de Bonferroni, les liens rouges à celles dépassant un seuil plus strict de 10^{-10} .




FIGURE 9 – Cercle d'association entre les SNPs de l'hôte et les sites viraux

Trois observations se dégagent de cette représentation. Premièrement, les associations ne se répartissent pas uniformément sur le génome viral : la protéine NS3 concentre la majorité des liens, et la quasi-totalité des liens rouges. Cette concentration doit toutefois être relativisée par la taille de la protéine : NS3 étant l'une des plus longues du génome du VHC, elle contribue mécaniquement à un plus grand nombre de sites testés. Une normalisation par le nombre de sites polymorphes effectivement testés dans chaque protéine permettrait de distinguer un enrichissement biologique d'un simple effet de longueur.

Deuxièmement, du côté de l'hôte, les associations convergent massivement vers le chromosome 6. Cette structure en éventail, où un même faisceau de SNPs se projette vers de nombreux sites viraux, traduit à la fois la corrélation entre SNPs voisins et le fait qu'un même locus de l'hôte

exerce une pression de sélection sur plusieurs positions du génome viral.

Troisièmement, cette redondance d'un même segment chromosomique associé à plusieurs sites viraux est cohérente avec les résultats publiés par ANSARI *et al.*, dont nous retrouvons plusieurs associations, notamment celle impliquant le site viral 1450.

Site viral 1450. La figure 10 présente le *Manhattan plot* associé au site viral 1450 : chaque point représente un SNP de l'hôte, positionné selon sa localisation génomique en abscisse et selon $-\log_{10}(p)$ en ordonnée.




FIGURE 10 – Manhattan plot pour le site viral 1450

Le signal est très largement dominé par un pic unique sur le chromosome 6, atteignant $-\log_{10}(p) \approx 19$, soit plusieurs ordres de grandeur au-delà du seuil de significativité. Ce pic n'est pas porté par un SNP isolé mais par un ensemble de marqueurs contigus, ce qui constitue la signature attendue d'une association réelle : en raison du déséquilibre de liaison, les SNPs proches du variant causal sont partiellement corrélés à celui-ci et présentent donc des p-values également faibles. Une association portée par un point isolé serait au contraire suspecte et évoquerait davantage un artefact de génotypage.

En dehors de ce pic, le nuage de points reste plat et homogène le long du génome, sans excès de signal résiduel. C'est un indicateur favorable de la calibration du modèle : l'effet aléatoire apparenté (matrice de parenté) semble absorber correctement la structure de population, qui aurait sinon provoqué une élévation générale des statistiques de test. Un unique point sur le chromosome 2 émerge légèrement, sans atteindre le seuil, et ne peut donc pas être retenu.

Le *QQ plot* de la figure 11 confirme cette lecture. Les p-values observées suivent la diagonale attendue sous l'hypothèse nulle sur la quasi-totalité de leur distribution, et ne s'en écartent que dans la queue extrême. Ce profil, caractérisé par une déviation tardive et abrupte, correspond à celui d'un signal localisé : seule une faible fraction de tests s'écarte du modèle nul. Une inflation observable dès les faibles valeurs de $-\log_{10}(p)$ aurait au contraire signalé une structure de




FIGURE 11 – QQ plot pour le site viral 1450

population résiduelle ou un modèle mal spécifié. L’amplitude de la déviation, avec des valeurs observées atteignant 19 pour des valeurs attendues de l’ordre de 6, mesure directement la force du signal.

Cette position sur le chromosome 6 correspond à la région du complexe majeur d’histocompatibilité, dont l’implication dans la présentation antigénique et donc dans la pression de sélection exercée sur le virus est bien documentée.

Site viral 1276. Le modèle capture une seconde association d’intérêt, portant sur le site viral 1276 (figure 12).

Le SNP *rs11758515*, situé sur le chromosome 6, est ici le variant le plus fortement associé, avec $-\log_{10}(p) \approx 11,5$. Il est le seul à franchir nettement le seuil de significativité (ligne rouge), les autres marqueurs annotés se situant entre 4 et 6, c’est-à-dire dans la zone dite suggestive (ligne bleue) qui ne permet pas de conclure. Le signal est donc plus modéré et plus isolé que pour le site 1450 : le pic est moins large, ce qui suggère un bloc de déséquilibre de liaison plus étroit autour du variant. Ce variant ne possède pas d’implication médicale documentée ni de fonction connue recensée dans les principales bases de données annotées ; son interprétation fonctionnelle reste donc ouverte, et mériterait d’être complétée par l’examen des gènes situés à proximité de sa position.

Le *QQ plot* correspondant (figure 13) présente à nouveau une distribution conforme à l’hypothèse nulle sur l’essentiel de son étendue, avec une déviation restreinte à la queue. On y observe une structure en marches d’escalier : plusieurs groupes de SNPs partagent des p-values quasiment identiques. Ce phénomène s’explique par le déséquilibre de liaison, des marqueurs en corrélation quasi parfaite produisant des statistiques de test redondantes. Le nombre de paliers donne ainsi une indication approximative du nombre de signaux réellement indépendants, nettement inférieur au nombre de points situés au-dessus de la diagonale.




FIGURE 14 – arbre phylogénétique des différents serotypes de la dengue

5.2.3 Avec un codage continu sur l’HCV

L’implémentation du modèle a été faite à l’aide du package *GMMAT* de R sur le cluster *ITROP*. Le temps de calcul est le même que pour le codage binaire puisque les ressources utilisées sont les mêmes.

Le recodage des sites viraux a été fait à l’aide de la matrice de Grantham. Le codage est donc continu et permet de prendre en compte la nature de la mutation et donc d’éliminer des mutations conservatrices. Mais le codage continu réduit le nombre de sites viraux considérés et donc réduit les chances de trouver de nouvelles associations.

Au final, nous obtenons un total de 30 interactions significatives dépassant un seuil de p-value de 10^{-8} .

Contrairement au codage binaire et de l’ensemble des interaction sur la figure 15, les interactions sont beaucoup plus dispersées sur l’ensemble du génome viral et moins concentrées sur la protéines NS3. De plus, du côté de l’hôte, les interactions ne sont plus autant concentrées sur le chromosome 6 mais sont plus dispersées sur l’ensemble du génome de l’hôte.

Il se pourrait que le codage continu permette de détecter des interactions qui ne sont pas forcément liées à la région HLA du chromosome 6 mais à d’autres régions du génome de l’hôte. Cependant, le nombre d’interactions significatives est beaucoup plus faible que pour le codage binaire. Il est donc difficile de conclure sur la pertinence de ce codage.

Site viral 1613. Avec le codage continu, on observe que le site viral 1613 réapparaît plusieurs fois dans les associations significatives.

On observe sur le manhattan plot 16 que le signal est porté par un SNP rs11802399 situé sur le chromosome 1 et le SNP rs79221421 du chromosome 11. Comparé au codage binaire et aux interactions sur le site 1450, le signal est beaucoup plus faible et ne dépasse pas autant le seuil de significativité. Cependant, il est intéressant de noter que ce site viral réapparaît dans les interactions significatives avec le codage continu.




FIGURE 15 – Cercle d'association entre les SNPs de l'hôte et les sites viraux avec codage continu




FIGURE 16 – Manhattan plot pour le site viral 1613




FIGURE 17 – QQ plot pour le site viral 1613

On peut observer sur le QQplot 17 que la distribution des p-values est conforme à l'hypothèse nulle sur l'essentiel de son étendue.

Site viral 1961. Sur cette position, on observe sur le graph 18 un signal porté par le SNP rs893184 situé sur le chromosome 19.




FIGURE 18 – Manhattan plot pour le site viral 1961

Pour cette position, on possède un peu plus d'informations. Elle se situe sur le chromosome 19 et code pour la protéine CDC42BPA. Cette dernière serait responsable d'un processus qui permettrait de couper des morceaux de protéines. Bien que le signal soit faible, celui-ci n'apparaît pas comme étant significatif dans l'étude de Ansari et al. Il pourrait donc s'agir d'une nouvelle association qui n'avait pas été détectée avec le codage binaire.




FIGURE 19 – QQ plot pour le site viral 1961

5.2.4 Avec un codage continu sur la dengue

5.3 Performances du modèle retenu

Le modèle avec un codage binaire sur l’HCV est celui qui permet de détecter le plus d’interactions significatives. Bien que celui-ci ne prenne pas en compte la nature de la mutation, il permet de garder un maximum de sites viraux et donc de garder une puissance statistique suffisante pour les tests d’association.

En revanche, le codage continu permet de prendre en compte la nature de la mutation et donc d’éliminer des mutations conservatrices. Celui-ci réduit donc le nombre de sites viraux considérés. Bien que dans le cas de l’HCV, le codage continu permette de détecter des interactions qui ne sont pas forcément liées à la région HLA du chromosome 6 mais à d’autres régions du génome de l’hôte, le nombre d’interactions significatives est beaucoup plus faible que pour le codage binaire. Il est donc difficile de conclure sur la pertinence de ce codage.

Néanmoins, il reste pertinent de tester les nouvelles associations trouvées comme le site viral 1961 associé au SNP rs893184.

Il est donc envisageable d’étendre l’analyse afin de trouver des explications biologiques à ces nouvelles associations. Il est possible que ces associations soient liées à des mécanismes de défense de l’hôte ou à des mécanismes de réplication du virus.

Ainsi, les deux modèles sont pertinents et permettent de détecter des interactions significatives mais différents entre les SNPs de l’hôte et les sites viraux. Bien que le codage continu se repose sur des bases physiques et chimiques via la matrice de grantham, il est possible de changer et de considérer d’autres matrices de substitution se basant sur d’autres critères afin de trouver d’autres associations significatives. Par exemple, la matrice PAM250 qui est construite de façon empirique à partir de divers alignements de séquences pourrait être envisagée.

6 Conclusion et perspectives

7 Annexes

7.1 Annexe 1




FIGURE 20 – Volcano plot des résultats du modèle avec codage binaire

8 Bibliographie