



**UNIVERSITÉ DE
MONTPELLIER**



**STATISTIQUE
SCIENCE DES DONNÉES**
UNIVERSITÉ DE MONTPELLIER

MASTER II STATISTIQUES ET SCIENCES DES DONNÉES

Parcours Biostatistique

Identification des déterminants génétiques de la pathogénicité de la dengue

Présenté par :
Damien MARIAC

Encadré par :
Vincent PEDERGNANA

Tuteur FdS :
Ludovic Menneteau

Jury :
Élodie BRUNEL-PICCININI
Xavier BRY
Benoite DE SAPORTA

Année universitaire 2025-2026



Table des matières

1	Environnement	2
1.1	L'unité d'accueil : l'UMR MIVEGEC	2
1.2	L'équipe d'accueil : PEV	2
1.3	Conditions matérielles et vie de l'unité	2
2	Contexte	4
2.1	Contexte du sujet	4
2.2	Contexte biologique	4
3	Préparation des données	6
3.1	Le séquençage viral	6
3.2	Alignements multiples de séquences	7
3.2.1	Alignement progressif par rapport à une séquence de référence	7
3.2.2	Matrices de substitution	7
3.2.3	Pénalités de gap	9
3.3	Traitement des valeurs manquantes	9
4	Modélisation statistique	10
4.0.1	Modèle d'association "classique"	10
4.0.2	Limites du modèle "classique"	12
4.1	Modèle avec dépendances : Graph Fused Lasso	12
4.1.1	Construction du graphe de corrélation	12
4.1.2	Choix des paramètres de régularisation	13
4.1.3	Optimisation du modèle : algorithme FISTA	13
4.1.4	Calculs du gradient	14
4.1.5	Calculs du gradient	15
4.1.6	Limites de l'algorithme FISTA	16
4.2	Modèle avec effets aléatoires	16
4.2.1	Estimation - Test du score de Rao	17
4.2.2	Estimation approchée de l'effet β_{ij}	18
5	Résultats et discussion	22
5.1	Les jeux de données	22
5.1.1	Hépatite C	22
5.1.2	Dengue	22
5.2	Choix du codage des sites viraux	23
5.3	Modèle linéaire généralisé à effets aléatoires	23
5.3.1	Mise en œuvre et seuil de significativité	23
5.3.2	Grille de lecture des figures	24
5.3.3	Codage binaire appliqué au VHC	24
5.3.4	Codage binaire appliqué à la dengue	27
5.3.5	Codage continu appliqué au VHC	33
5.3.6	Codage continu appliqué à la dengue	36
5.4	Bilan des deux codages	36
6	Conclusion et perspectives	39
7	Annexe	40

1 Environnement

1.1 L'unité d'accueil : l'UMR MIVEGEC

J'ai effectué mon stage de Master 2 au sein de l'UMR MIVEGEC Maladies Infectieuses et Vecteurs : Écologie, Génétique, Évolution et Contrôle, à Montpellier. Créée en 2011, cette unité mixte de recherche est placée sous la tutelle de l'Institut de Recherche pour le Développement IRD, tutelle hébergeuse, du Centre National de la Recherche Scientifique CNRS et de l'Université de Montpellier, et est unité sous contrat de l'INRAE.

Les recherches de l'unité portent sur l'écologie et l'évolution des systèmes infectieux. Elles visent à comprendre les processus d'émergence, de réplication et de transmission des agents pathogènes, ainsi que les mécanismes d'adaptation réciproque au sein des complexes hôte-pathogène. L'unité couvre un continuum allant de la recherche fondamentale à la recherche de terrain et interventionnelle, et entretient des collaborations de longue date avec des partenaires situés en zone intertropicale, où les maladies étudiées sont endémiques.

MIVEGEC réunit environ 250 personnes réparties sur trois sites montpellierains, et est structurée en cinq départements scientifiques regroupant treize groupes de recherche. Elle pilote plusieurs plateformes, dont le Vectopôle-IRD, et contribue au plateau de bioinformatique iTrop, sur lequel l'ensemble des analyses présentées dans ce rapport a été réalisé.

1.2 L'équipe d'accueil : PEV

J'ai été intégré à l'équipe PEV Perturbations, Évolution, Virulence, codirigée par Mme Élodie Chapuis et M. Vincent Pedergrana. L'équipe cherche à identifier les facteurs qui déterminent la virulence des systèmes infectieux, en accordant une attention particulière à l'effet des perturbations intracellulaires, environnementales ou anthropiques sur les interactions hôte-parasite. Elle est organisée en deux groupes de taille comparable : ViroStyle, centré sur les interactions entre virus et hôtes, et PVPC (Perturbation Virulence in Populations Communities), consacré à l'effet des perturbations écologiques sur la dynamique des systèmes infectieux.

La particularité de l'équipe tient à la combinaison d'approches théoriques, expérimentales et statistiques : modélisation mathématique, génétique des populations, épidémiologie et analyse de données y sont mobilisées conjointement. C'est dans ce dernier volet que s'inscrit mon stage.

Ce positionnement explique le sujet qui m'a été confié. L'analyse conjointe des génomes de l'hôte et du pathogène dite genome-to-genome constitue en effet un axe de recherche établi de l'équipe : mon encadrant, M. Vincent Pedergrana, est copremier auteur de l'étude de référence en la matière chez le virus de l'hépatite C [1], dont les résultats servent de point de comparaison tout au long de ce travail. Mon stage prolonge cette approche sur deux plans : l'introduction d'un codage continu des sites viraux, et son extension à un second modèle viral, la dengue.

1.3 Conditions matérielles et vie de l'unité

L'équipe est répartie sur deux bâtiments distincts, tous deux situés sur le campus Agropolis, dans le quartier de Lavalette, en bordure du Lez. J'ai pour ma part été accueilli dans le bâtiment Païre, distinct du bâtiment principal de la délégation régionale de l'IRD qui héberge la majorité des personnels de l'unité. Les calculs ont été menés à distance sur le cluster iTrop, ce qui rendait cette dispersion géographique peu contraignante au quotidien.

L'équipe PEV se réunit toutes les deux semaines le lundi matin. Ces réunions permettaient de faire le point sur l'avancement des projets en cours et donnaient lieu à des présentations de la part des chercheurs. Elles ont constitué pour moi une occasion régulière d'apprentissage de la méthodologie en biologie, mais aussi de découvrir des objets et des approches très éloignés de mon sujet, ce qui donne une image plus juste de la diversité du travail mené dans une unité de recherche.

Mon stage s'est par ailleurs déroulé dans un contexte institutionnel particulier. L'unité prépare sa restructuration pour le prochain mandat : elle changera de nom pour devenir BioSEE, se réorganisera autour d'un nombre réduit d'équipes et abandonnera le découpage actuel en départements scientifiques. L'équipe PEV, quant à elle, fusionnera ses deux groupes en une entité unique.

J'ai eu l'occasion d'assister à l'assemblée générale consacrée à cette transition, où étaient présentés aussi bien des travaux scientifiques que des questions d'organisation et de gouvernance. Ces séances m'ont donné un aperçu d'une dimension du métier de chercheur peu visible depuis les enseignements de master : le fonctionnement collectif d'une unité, la manière dont s'y négocient les orientations scientifiques, et le temps que ces arbitrages représentent dans l'activité quotidienne d'un laboratoire.

2 Contexte

2.1 Contexte du sujet

La sévérité d'une infection virale varie fortement d'un individu à l'autre. Cette variabilité est en partie due à la diversité génétique de l'hôte et du virus. Parmi les facteurs influençant cette variabilité, nous nous intéressons à la diversité génétique de l'hôte et du virus. L'objectif est d'identifier les variants génétiques de l'hôte qui influencent l'évolution du génome viral. Le virus est soumis à la pression de sélection exercée par le système immunitaire de l'hôte, et le génome de l'hôte cherche à éliminer le virus de l'organisme.

L'objectif de ce stage est de proposer de nouveaux modèles permettant de faciliter l'étude d'associations entre les variants génétiques de l'hôte et les mutations virales, afin de mieux comprendre les mécanismes des réponses immunitaires de l'hôte humain.

Historiquement, les études d'association en génome entier sont menées sur les symptômes provoqués par l'infection. Mais ceux-ci sont souvent largement influencés par des facteurs non génétiques tels que l'environnement, l'alimentation ou les habitudes physiques.

Pour pallier ce problème, il existe depuis quelques années une variante de cette approche. On cherche à identifier les variants génétiques de l'hôte qui influencent l'évolution du génome viral. Cette approche est appelée *Genome-to-Genome* (GxG). L'idée est que les mutations virales sont le reflet de la pression de sélection exercée par le système immunitaire de l'hôte. Ainsi, en identifiant les variants génétiques de l'hôte associés à certaines mutations virales, on peut obtenir des informations sur les mécanismes immunitaires impliqués dans la réponse à l'infection.

Ce qui fait toute la difficulté de cette approche est la haute dimensionnalité des données. En effet, on a du côté des hôtes des centaines de milliers de variants génétiques et du côté des virus des centaines de mutations après avoir filtré les sites présentant un certain taux de variabilité. De plus, les individus issus de régions géographiques et d'ethnies différentes présentent des différences génétiques, ce qui biaise les résultats d'association. Il est aussi possible que certains virus soient issus d'une même souche et partagent des mutations communes dues à leur histoire évolutive sans pour autant être responsables d'une pression de sélection. Il est donc nécessaire de prendre en compte la structure de population des hôtes et du virus.

Afin de mieux comprendre les mécanismes à l'origine de cette diversité génétique, il est nécessaire de rappeler brièvement le cycle de vie d'un virus et son interaction avec le système immunitaire.

2.2 Contexte biologique

Le virus est une entité biologique qui ne peut pas se reproduire par elle-même. Il a besoin d'un hôte pour se multiplier et se propager. Il est constitué d'une coque qui protège son matériel génétique, cela peut être de l'ADN ou de l'ARN. La nature du support de l'information ADN ou ARN dicte la réplication, ce qui a un impact majeur sur sa diversité génétique. De ce fait, les virus à ARN ont un taux de mutation beaucoup plus élevé que les virus à ADN. Cette haute variance est fondamentale : elle permet au virus de s'adapter très rapidement pour trouver des solutions face aux défenses de l'hôte.

Dans le cadre de ce stage, nous avons travaillé sur le virus de l'hépatite C (VHC) dont on

a déjà identifié des liaisons afin de pouvoir l'étendre au virus de la dengue. Ce sont tous deux des virus à ARN qui présentent une grande diversité génétique.

La multiplication du virus dépend entièrement de la machinerie cellulaire de l'hôte. L'infection débute lorsqu'un virus reconnaît un récepteur spécifique à la surface d'une cellule. Après son entrée dans celle-ci, son génome est libéré dans le cytoplasme où il est répliqué grâce aux enzymes virales ou cellulaires. Les ARN messagers viraux sont ensuite traduits par les ribosomes de la cellule afin de produire les protéines virales nécessaires au cycle infectieux.




FIGURE 1 – Cycle de vie d'un virus à ARN.

Lors de cette infection, le système immunitaire met en place plusieurs mécanismes de défense. Comme par exemple la production d'interférons qui sont des molécules chargées de limiter la réplication du virus. Mais développe aussi l'immunité adaptative en entraînant certains lymphocytes à reconnaître les virus et à les détruire.

La réponse immunitaire exerce une forte pression de sélection sur le virus. Cela signifie que toute mutation permettant de diminuer la reconnaissance d'une protéine virale par le système immunitaire peut conférer un avantage évolutif. Au fil des cycles de réplication, ces mutations peuvent être sélectionnées et devenir majoritaires au sein de la population virale présente chez un individu.

Dans le cadre de ce stage, nous nous sommes intéressés à deux virus à ARN : le virus de l'hépatite C (VHC) et le virus de la dengue (DENV). Tous deux présentent une importante diversité génétique, conséquence directe de leur fort taux de mutation. Le but étant de trouver de nouveaux modèles permettant d'identifier de nouveaux variants génétiques. La stratégie étant de le tester sur un jeu de données (VHC) dont on a déjà identifié des liaisons entre les variants génétiques de l'hôte et les mutations virales. Puis d'étendre cette approche sur le virus de la dengue.

3 Préparation des données

Cette partie détaille les étapes de collecte, d'alignement des séquences virales et de gestion des données manquantes faites avant toute modélisation statistique.

Les données utilisées dans ce type d'étude nécessitent l'acquisition simultanée d'informations génétiques sur le pathogène et sur son hôte. Les échantillons biologiques consistent généralement en des prélèvements sanguins effectués chez les patients infectés. Pour le génome viral, l'ARN du VHC est extrait à partir du plasma sanguin des patients. Ce matériel est ensuite amplifié et séquencé par un séquenceur, ce qui permet de capturer l'ensemble des variants présents chez un individu et d'en dégager une séquence consensus par patient.

3.1 Le séquençage viral

Pour analyser le génome du virus présent chez un patient, il est important de comprendre comment les données génétiques sont techniquement lues par les machines (les séquenceurs).

Contrairement à ce que l'on pourrait penser, un séquenceur ne lit pas le génome du virus d'une seule traite, de la première à la dernière « lettre » (nucléotide). Les technologies modernes de séquençage à haut débit procèdent différemment : elles découpent l'ARN viral en des millions de petits fragments de 140 nucléotides, appelés des *reads*. La machine va ensuite lire ces petits fragments de manière individuelle et désordonnée. Pour se représenter ce processus, on peut imaginer un livre (le génome viral) qui serait passé dans une déchiqueteuse à papier. On se retrouve avec des milliers de petites bandes de papier contenant chacune quelques mots. Pour reconstituer l'histoire, un algorithme informatique va comparer ces bandes, chercher les mots qui se chevauchent, et les aligner les unes par rapport aux autres, souvent en s'aidant d'un « texte de référence » connu (comme la séquence externe H77 pour le VHC).

Puisque nous avons généré des millions de petits fragments à partir de milliers de copies du virus présentes dans le sang du patient, un « mot » spécifique du livre ne sera pas lu une seule fois, mais des dizaines, voire des centaines de fois.




FIGURE 2 – Représentation schématique de l'alignement des lectures (*reads*) sur une séquence de référence.

Lorsqu'on observe un site précis du génome (par exemple, la position 1450), on constate que de nombreux petits fragments se superposent à cet endroit. Le nombre total de fragments qui couvrent une position donnée définit sa profondeur.

La profondeur est une information cruciale puisqu'elle permet la correction des erreurs. Les séquenceurs font parfois des erreurs de lecture. Si un seul fragment indique une mutation à une position, il peut s'agir d'un artefact technique. En revanche, si la profondeur est de 100 et que 99 fragments indiquent cette même mutation, nous avons la certitude statistique qu'elle est réelle.

Ainsi, l'alignement de cette multitude de petits fragments n'est pas un défaut technique, mais une nécessité qui donne tout son relief et sa fiabilité à l'analyse génétique du virus.

3.2 Alignements multiples de séquences

L'alignement multiple de séquences (MSA) consiste à disposer simultanément plusieurs séquences biologiques (nucléotidiques ou protéiques) de manière à faire correspondre les positions homologues, c'est-à-dire dérivées d'un ancêtre commun au cours de l'évolution. Contrairement à l'alignement par paires (deux séquences), l'alignement multiple permet d'identifier des régions conservées, des motifs fonctionnels ou structuraux communs à un ensemble de séquences, et sert de base à des analyses phylogénétiques. Puisque l'idée est de pouvoir considérer les positions du virus comme des variables.

Il s'agit d'un problème de haute complexité algorithmique : trouver l'alignement optimal de N séquences exacte a une complexité qui croît exponentiellement avec le nombre de séquences, de l'ordre de $O(L^N)$ pour N séquences de longueur L . Pour cette raison, des méthodes heuristiques sont généralement utilisées en pratique.

3.2.1 Alignement progressif par rapport à une séquence de référence

Dans notre cas, nous avons réalisé un alignement progressif basé sur une séquence de référence.

Cette approche consiste dans un premier temps à choisir une séquence de référence (souvent la plus longue, la plus représentative, une séquence d'intérêt particulier ou consensus, ou une séquence de référence dans les bases de données publiques).

Puis aligner successivement chaque autre séquence du jeu de données contre cette référence, par alignement deux à deux.

Enfin, fusionner progressivement ces alignements par paires en un alignement multiple global, en insérant des gaps (-) aux positions nécessaires pour maintenir la cohérence des colonnes entre toutes les séquences.

Cette stratégie est une simplification efficace par rapport aux méthodes progressives classiques (type ClustalW) qui construisent d'abord un arbre guide (*guide tree*) à partir des similarités deux à deux, puis alignent les séquences en suivant cet arbre. L'approche par référence unique est plus rapide, mais suppose que la séquence de référence est suffisamment représentative pour bien guider l'alignement de l'ensemble des autres séquences.

3.2.2 Matrices de substitution

L'alignement de deux séquences repose sur un système de score permettant de quantifier la ressemblance entre deux acides aminés dans une colonne de l'alignement. Comme les vingt acides aminés ne sont en effet pas interchangeables de manière équivalente, on ne peut pas se contenter d'un simple score binaire.

Certaines substitutions sont dites *conservatives* : elles remplacent un acide aminé par un autre présentant des propriétés physico-chimiques voisines. De telles substitutions altèrent en général peu la structure et la fonction de la protéine, et sont donc fréquemment observées entre séquences homologues. À l'inverse, les substitutions dites *radicales* remplacent un résidu par un autre aux propriétés très différentes, et sont bien plus rarement tolérées par la sélection naturelle.

Une matrice de substitution est donc une matrice carrée S de dimension 20×20 , symétrique, dont le coefficient $s(a, b)$ représente le score attribué à l'alignement de l'acide aminé a avec l'acide aminé b . Ce score est d'autant plus élevé que la substitution est jugée plausible ou peu coûteuse, et d'autant plus faible (voire négatif) qu'elle est jugée improbable. Les termes diagonaux $s(a, a)$, correspondant à la conservation d'un résidu, sont naturellement les plus favorables.

On distingue classiquement deux grandes familles de matrices :

- Les matrices empiriques, construites à partir de l'observation des substitutions réellement constatées dans de grands jeux d'alignements de protéines homologues. C'est le cas des matrices PAM (*Point Accepted Mutation*, Dayhoff *et al.*, 1978) et BLOSUM (*BLOcks SUBstitution Matrix*, Henikoff & Henikoff, 1992). Leurs coefficients sont des rapports de vraisemblance logarithmiques (*log-odds*) de la forme

$$s(a, b) = \frac{1}{\lambda} \log \frac{q_{ab}}{p_a p_b},$$

où q_{ab} est la fréquence d'observation du couple (a, b) dans des alignements de référence, p_a et p_b les fréquences d'apparition de chaque acide aminé, et λ un facteur d'échelle. Un score positif traduit ainsi une substitution plus fréquente que ce que prédirait le hasard.

- Les matrices physico-chimiques, qui ne reposent pas sur des données évolutives mais sur la comparaison objective des propriétés chimiques des chaînes latérales des acides aminés. Elles définissent une *distance* entre acides aminés, et non directement un score de similarité. Les matrices de Grantham (1974), de Miyata (1979) ou de Sneath (1966) appartiennent à cette catégorie.

Le choix de la matrice n'est pas neutre : il conditionne directement l'alignement obtenu, et donc l'ensemble des analyses qui en découlent.

Plus tard dans ce travail, on utilisera un nouveau codage basé sur la matrice de Grantham (1974). Son principe est de quantifier la *dissimilarité chimique* entre deux acides aminés à partir de trois propriétés de leur chaîne latérale, jugées déterminantes pour le comportement du résidu au sein de la protéine : la composition, la polarité et le volume moléculaire.

Les valeurs obtenues s'échelonnent ainsi de 5, pour le couple leucine/isoleucine (substitution quasiment neutre sur le plan chimique), à 215 pour le couple cystéine/tryptophane, qui constitue la substitution la plus radicale au sens de ce critère.

L'intérêt de cette matrice est qu'elle repose sur des grandeurs physico-chimiques mesurables et indépendantes de tout jeu de données évolutif : elle n'introduit donc pas de biais lié à la composition des bases de données ayant servi à construire les matrices empiriques, et ne présuppose aucune distance évolutive particulière entre les séquences comparées (là où le choix d'une matrice PAM ou BLOSUM suppose implicitement un degré de divergence donné). En contrepartie, elle ignore la réalité observée des substitutions acceptées au cours de l'évolution, et notamment les contraintes fonctionnelles propres à certains sites.

/	Ser	Arg	Leu	Pro	Thr	Ala	Val	Gly	Ile	Phe	Tyr	Cys	His	Gln	Asn	Lys	Asp	Glu	Met	Trp
Ser	0	110	145	74	58	99	124	56	142	155	144	112	89	68	46	121	65	80	135	177
Arg	110	0	102	103	71	112	96	125	97	97	77	180	29	43	86	26	96	54	91	101
Leu	145	102	0	98	92	96	32	138	5	22	36	198	99	113	153	107	172	138	15	61
Pro	74	103	98	0	38	27	68	42	95	114	110	169	77	76	91	103	108	93	87	147
Thr	58	71	92	38	0	58	69	59	89	103	92	149	47	42	65	78	85	65	81	128
Ala	99	112	96	27	58	0	64	60	94	113	112	195	86	91	111	106	126	107	84	148
Val	124	96	32	68	69	64	0	109	29	50	55	192	84	96	133	97	152	121	21	88
Gly	56	125	138	42	59	60	109	0	135	153	147	159	98	87	80	127	94	98	127	184
Ile	142	97	5	95	89	94	29	135	0	21	33	198	94	109	149	102	168	134	10	61
Phe	155	97	22	114	103	113	50	153	21	0	22	205	100	116	158	102	177	140	28	40
Tyr	144	77	36	110	92	112	55	147	33	22	0	194	83	99	143	85	160	122	36	37
Cys	112	180	198	169	149	195	192	159	198	205	194	0	174	154	139	202	154	170	196	215
His	89	29	99	77	47	86	84	98	94	100	83	174	0	24	68	32	81	40	87	115
Gln	68	43	113	76	42	91	96	87	109	116	99	154	24	0	46	53	61	29	101	130
Asn	46	86	153	91	65	111	133	80	149	158	143	139	68	46	0	94	23	42	142	174
Lys	121	26	107	103	78	106	97	127	102	102	85	202	32	53	94	0	101	56	95	110
Asp	65	96	172	108	85	126	152	94	168	177	160	154	81	61	23	101	0	45	160	181
Glu	80	54	138	93	65	107	121	98	134	140	122	170	40	29	42	56	45	0	126	152
Met	135	91	15	87	81	84	21	127	10	28	36	196	87	101	142	95	160	126	0	67
Trp	177	101	61	147	128	148	88	184	61	40	37	215	115	130	174	110	181	152	67	0

FIGURE 3 – Matrice de distance de Grantham (1974)

3.2.3 Pénalités de gap

Enfin, l'algorithme d'alignement utilisé (de type Needleman-Wunsch, pour un alignement global) intègre une pénalité d'ouverture de gap (un trou dans le sequence) ainsi qu'une éventuelle pénalité d'extension de gap (une suite de trou), afin d'éviter la multiplication de petites insertions/délétions dispersées et de favoriser des gaps regroupés, biologiquement plus plausibles (une seule insertion/délétion plutôt que plusieurs événements ponctuels indépendants).

3.3 Traitement des valeurs manquantes

La présence de valeurs manquantes est inhérente aux limites techniques du séquençage et du génotypage, notamment aux erreurs de lecture. Dans le cadre des modèles mixtes (GLMM) utilisés pour les tests d'association (voir plus bas), ces données manquantes bloquent les calculs d'algèbre linéaire, comme l'inversion des matrices de parenté. Le traitement appliqué dépend donc du type de codage retenu pour le jeu de données.

Afin de rester cohérent avec un codage initialement binaire, les valeurs manquantes ont été imputées par la modalité la plus fréquente. Ce choix évite d'obtenir des valeurs différentes de 0 ou 1, ce qui aurait pu compromettre les modèles logistiques, tout en conservant une puissance statistique suffisante lors du recodage par transition d'acide aminé (voir section suivante). Cette approche permet enfin de disposer d'un support commun pour comparer les différentes méthodes entre elles.

4 Modélisation statistique

Dans cette approche *Genome-to-Genome* (GxG), le but est d’identifier des variants génétiques de l’hôte qui influencent l’évolution du génome viral. Cette problématique relève naturellement de modèle supervisé : les caractéristiques génétiques de l’hôte constituent les variables explicatives, tandis que les mutations observées chez le virus représentent les variables à expliquer. Contrairement à une approche non supervisée, qui se limite à décrire les structures présentes dans les données, un modèle supervisé permet de mettre en évidence des associations statistiques entre les deux génomes tout en tenant compte d’éventuels facteurs de confusion, tels que la stratification des populations hôtes et virus ou de caractère propre à l’individu.

4.0.1 Modèle d’association “classique”

Le modèle proposé par [1] vise à modéliser la probabilité d’une mutation virale en fonction d’un variant génétique de l’hôte appelé SNP pour single nucleotide polymorphism tout en rajoutant des covariables telles que l’âge et le sexe. Pour une position génomique virale (nous utiliserons site viral dans le reste du rapport) et un SNP donnés, une régression logistique est ajustée indépendamment, et ce pour l’ensemble des paires SNP–site viral.

Afin de corriger la structure de population, les auteurs incluent les composantes principales (CP) de l’hôte et du virus comme effets fixes. En effet, les premières CP de l’hôte capturent l’origine ethnique des individus [**PCA**stratification], et les premières CP du virus capturent l’origine géographique des souches (Figure 4).




FIGURE 4 – Structure de population capturée par l’ACP pour une cohorte multi-ethnique de patients infectés par le VHC

Les auteurs retiennent les 10 premières CP de l’hôte et les 5 premières du virus. Ce choix reste discutable : ces composantes ne capturent respectivement que XX % et 12 % de la variance cumulée, ce qui suggère qu’une part importante de la structure de population n’est pas corrigée.

Le modèle s’écrit finalement, pour un site de l’hôte SNP_j et un site viral Y_i fixés :

$$\text{logit}(P(Y_i = 1)) = \beta_0 + \beta_{ij} SNP_j + \sum_{k=1}^{10} \gamma_k PC_k^{\text{hôte}} + \sum_{l=1}^5 \delta_l PC_l^{\text{virus}}$$

Une p-value est extraite pour chaque test SNP–site viral. Les tests étant menés indépendamment sur un très grand nombre de paires, une correction pour tests multiples est nécessaire afin de limiter les faux positifs : les auteurs utilisent une correction de Bonferroni, avec un seuil

de significativité $\alpha = 10^{-11}$. Le seuil étant élevé, il est trop conservateur et risque d'écraser un signal réel. C'est pourquoi un seuil de significativité plus faible est utilisé à savoir $\alpha = 10^{-8}$.

4.0.2 Limites du modèle “classique”

Ce modèle présente plusieurs limites ce qui motivent le développement d’une approche plus adaptée à ce type de données.

D’abord, il ne capture qu’une fraction de la structure de population : se limiter à quelques composantes principales, en plus d’ignorer une part importante de la variance, ne permet pas de représenter assez précisément la dépendance génétique entre individus (côté hôte) ou entre souches (côté virus).

Ensuite, il ignore la corrélation entre sites : les mutations virales peuvent être corrélées entre elles du fait de leur proximité structurale (conformation 3D de la protéine), et les SNPs de l’hôte proches sur le génome sont corrélés par déséquilibre de liaison. Ne pas modéliser ces dépendances revient à traiter chaque test comme indépendant alors qu’il ne l’est pas, ce qui biaise l’estimation de la significativité.

De plus, la correction de Bonferroni, en supposant l’indépendance des tests, est très conservatrice dans ce contexte de forte corrélation : elle risque d’écraser un signal réel, en particulier étant donné la très haute dimensionnalité des données (des millions de tests SNP–site viral).

4.1 Modèle avec dépendances : Graph Fused Lasso

Un modèle de type Graph Fused Lasso (GFL) [3] permettrait de pouvoir palier le problème de la corrélation entre sites. Celui-ci reprend le modèle logistique précédent, mais ajoute deux pénalisations sur les coefficients β_{ij} : une pénalité de type Lasso, qui contraint les coefficients à être nuls si le SNP j n’est pas suffisamment associé au site viral i , et une pénalité de fusion sur graphe, qui contraint les coefficients à être similaires lorsque les sites viraux i et i' sont corrélés.

Le modèle s’écrit alors, pour un SNP j fixé :

$$\hat{\beta}_{\cdot j} = \underset{\beta_{\cdot j}}{\operatorname{argmin}} \left\{ - \sum_{i=1}^p \ell_i(\beta_{ij}) + \lambda_1 \sum_{i=1}^p |\beta_{ij}| + \lambda_2 \sum_{(i,i') \in E} w_{ii'} |\beta_{ij} - \beta_{i'j}| \right\}$$

où $\ell_i(\beta_{ij})$ est la log-vraisemblance logistique associée au site viral i , E l’ensemble des arêtes du graphe de corrélation entre sites viraux, $w_{ii'}$ le poids de l’arête reliant les sites i et i' , et λ_1 , λ_2 les paramètres de régularisation contrôlant respectivement la sparsité et l’homogénéité locale des coefficients sur le graphe.

4.1.1 Construction du graphe de corrélation

Afin d’implémenter ce modèle, il est nécessaire de construire un graphe représentant les corrélations entre sites viraux.

Pour éviter d’avoir un biais, on calcule la corrélation sur un autre jeu de données de l’VHC du même serotype. Ces données proviennent de la banque de données du NCBI. Elles ont été alignées par rapport à la séquence consensus de nos données afin de pouvoir faire correspondre les bonnes positions. Puis nous avons calculé la corrélation entre les sites après avoir recodé en variables binaires sous forme de mutation/conservation. C’est avec 5000 séquences que nous obtenons la matrice de corrélation.

Les sites viraux étant binaires, ils sont supposés suivre une loi de Bernoulli, ce qui permet d’estimer leur corrélation de façon paramétrique. Pour deux sites viraux i et i' , de probabilités marginales p_i et $p_{i'}$ et de probabilité jointe $p_{ii'} = P(Y_i = 1, Y_{i'} = 1)$, la corrélation s’écrit :

$$w_{ii'} = \operatorname{corr}(Y_i, Y_{i'}) = \frac{p_{ii'} - p_i p_{i'}}{\sqrt{p_i(1-p_i) p_{i'}(1-p_{i'})}}$$

La matrice de corrélation ainsi obtenue sert de support au graphe : une arête est créée entre deux sites viraux lorsque leur corrélation en valeur absolue dépasse un seuil fixé choisit arbitrairement à 0.7 (comme dans l'article [3]). La Figure 5 représente cette matrice sous forme de heatmap, où les valeurs proches de 1 sont en rouge et celles proches de 0 en jaune.




FIGURE 5 – Matrice de corrélation entre sites viraux sous forme de heatmap.

On remarque que la matrice de corrélation est très creuse, mais qu'elle présente des blocs de corrélations élevées, correspondant à des sites viraux fortement liés entre eux.

4.1.2 Choix des paramètres de régularisation

Il reste à définir les paramètres de régularisation λ_1 et λ_2 . Une validation croisée sur l'ensemble des données étant impossible à mettre en œuvre dans ce contexte de très haute dimensionnalité, elle a été réalisée sur plusieurs sous-ensembles de données, et les résultats ont ensuite été moyennés pour obtenir les paramètres optimaux. On obtient ainsi $\lambda_1 = XX$ et $\lambda_2 = XX$.

4.1.3 Optimisation du modèle : algorithme FISTA

L'estimation des coefficients du modèle revient à minimiser la fonction objectif présentée précédemment, qui se décompose en une partie lisse et une partie non lisse :

$$F(\beta) = \underbrace{f(\beta)}_{\text{log-vraisemblance}} + \underbrace{g(\beta)}_{\text{pénalités}}, \quad \text{où } g(\beta) = \lambda_1 \sum_{i=1}^p |\beta_{ij}| + \lambda_2 \sum_{(i,i') \in E} w_{ii'} |\beta_{ij} - \beta_{i'j}|$$

où f est convexe et différentiable, mais où g est convexe et non différentiable en raison des valeurs absolues. Cette fonction ne possède pas de solution analytique et doit donc être minimisée numériquement.

Pour cela, nous utilisons l'algorithme FISTA (Fast Iterative Shrinkage-Thresholding Algorithm) [2], particulièrement adapté aux problèmes de la forme $\min_{\beta} f(\beta) + g(\beta)$ lorsque f est différentiable à gradient L -Lipschitzien et g admet un opérateur proximal calculable. C'est la méthode principalement utilisée dans les packages R qui implémentent les modèles de type Lasso.

Étape de descente de gradient. À chaque itération k , l'algorithme réalise d'abord un pas de gradient sur la partie lisse f , évalué non pas en β_k mais en un point extrapolé $\mathbf{y}_k$:

$$\mathbf{z}_k = \mathbf{y}_k - \frac{1}{L} \nabla f(\mathbf{y}_k)$$

où $\nabla f(\mathbf{y}_k)$ est le gradient de la log-vraisemblance logistique, de la forme $\mathbf{X}^\top (\mathbf{p}(\mathbf{y}_k) - \mathbf{Y})$, avec $\mathbf{p}(\mathbf{y}_k)$ le vecteur des probabilités prédites $\text{logit}^{-1}(\mathbf{X}\mathbf{y}_k)$, et L une constante de Lipschitz du gradient (majorée ici par la plus grande valeur propre de $\mathbf{X}^\top \mathbf{X}/4$), qui fixe la taille du pas.

Étape de seuillage (opérateur proximal). Le point $\mathbf{z}_k$ est ensuite projeté via l'opérateur proximal de g , défini par :

$$\text{prox}_{g/L}(\mathbf{z}_k) = \underset{\beta}{\text{argmin}} \left\{ \frac{L}{2} \|\beta - \mathbf{z}_k\|_2^2 + g(\beta) \right\}$$

Pour la seule pénalité ℓ_1 , cet opérateur a une solution explicite, le seuillage doux (*soft-thresholding*) :

$$[\text{prox}_{\lambda_1/L, \|\cdot\|_1}(z)]_i = \text{sign}(z_i) \max(|z_i| - \lambda_1/L, 0)$$

qui annule progressivement les coefficients de faible amplitude, ce qui permet de sélectionner uniquement les mutations virales les plus associées au SNP étudié. En présence de la pénalité de fusion sur graphe, l'opérateur proximal combiné $\text{prox}_{g/L}$ n'a plus de forme close et est résolu par

Étape d'accélération. Enfin, FISTA ajoute une étape d'extrapolation de type Nesterov, en combinant les deux dernières estimations β_k et β_{k-1} :

$$\beta_k = \text{prox}_{g/L}(\mathbf{z}_k), \quad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \quad \mathbf{y}_{k+1} = \beta_k + \frac{t_k - 1}{t_{k+1}} (\beta_k - \beta_{k-1})$$

avec $t_1 = 1$ et $\mathbf{y}_1 = \beta_0$. Cette accélération permet d'obtenir une vitesse de convergence en $\mathcal{O}(1/k^2)$, contre $\mathcal{O}(1/k)$ pour l'algorithme ISTA classique (sans extrapolation), tout en conservant une implémentation relativement simple. Cette propriété est particulièrement intéressante dans notre contexte, où le modèle doit être estimé pour un très grand nombre de SNPs et de sites viraux.

4.1.4 Calculs du gradient

L'étape de descente de FISTA nécessite le gradient de la partie lisse f de la fonction objectif. On note n le nombre d'individus et p le nombre de sites viraux. On note également $\mathbf{X} \in \{0, 1, 2\}^{n \times p}$ la matrice des génotypes de l'hôte, de terme général x_{ki} (génotype de l'individu k au SNP i), $\mathbf{Y} = (Y_1, \dots, Y_n)^\top \in \{0, 1\}^n$ le vecteur réponse associé au SNP j , et $\beta_{\cdot j} = (\beta_{1j}, \dots, \beta_{pj})^\top$ le vecteur des coefficients à estimer, avec β_{0j} l'intercept. Et $\mathbf{B} = (\beta_{ij}) \in \mathbb{R}^{p \times q}$ la matrice des coefficients à estimer, et β_{0j} l'intercept associé au site viral j .

De plus, on note :

$$\eta_{kj} = \beta_{0j} + \sum_{i=1}^p x_{ki} \beta_{ij}, \quad \pi_{kj} = \text{logit}^{-1}(\eta_{kj}) = \frac{e^{\eta_{kj}}}{1 + e^{\eta_{kj}}}.$$

Qui sont respectivement le prédicteur linéaire et la probabilité pour l'individu k au site viral j .

j d'obtenir une mutation.

Les individus sont supposés indépendants conditionnellement à leur génotype, la log-vraisemblance du modèle logistique s'écrit donc :

$$\ell(\mathbf{B}) = \sum_{j=1}^q \sum_{k=1}^n \left\{ Y_{kj} \log \pi_{kj} + (1 - Y_{kj}) \log(1 - \pi_{kj}) \right\} = \sum_{j=1}^q \sum_{k=1}^n \left\{ Y_{kj} \eta_{kj} - \log(1 + e^{\eta_{kj}}) \right\},$$

4.1.5 Calculs du gradient

L'étape de descente de FISTA nécessite le gradient de la partie lisse f de la fonction objectif. Notons :

- n le nombre d'individus, p le nombre de SNPs hôtes et q le nombre de sites viraux ;
- $\mathbf{X} \in \{0, 1, 2\}^{n \times p}$ la matrice des génotypes hôtes, de terme général x_{ki} (dosage allélique du SNP i chez l'individu k), dont les colonnes sont centrées et réduites au préalable afin que la pénalisation s'applique de façon homogène ;
- $\mathbf{Y} \in \{0, 1\}^{n \times q}$ la matrice des sites viraux, de terme général Y_{kj} (présence de la mutation j chez l'individu k) ;
- $\mathbf{B} = (\beta_{ij}) \in \mathbb{R}^{p \times q}$ la matrice des coefficients à estimer, et β_{0j} l'intercept associé au site viral j .

Le prédicteur linéaire et la probabilité prédite pour l'individu k au site viral j s'écrivent

$$\eta_{kj} = \beta_{0j} + \sum_{i=1}^p x_{ki} \beta_{ij}, \quad \pi_{kj} = \text{logit}^{-1}(\eta_{kj}) = \frac{e^{\eta_{kj}}}{1 + e^{\eta_{kj}}}.$$

Log-vraisemblance. Les individus étant supposés indépendants conditionnellement à leur génotype, la log-vraisemblance du modèle logistique s'écrit

$$\ell(\mathbf{B}) = \sum_{j=1}^q \sum_{k=1}^n \left\{ Y_{kj} \log \pi_{kj} + (1 - Y_{kj}) \log(1 - \pi_{kj}) \right\} = \sum_{j=1}^q \sum_{k=1}^n \left\{ Y_{kj} \eta_{kj} - \log(1 + e^{\eta_{kj}}) \right\},$$

la seconde égalité s'obtenant en remarquant que $\log \pi_{kj} - \log(1 - \pi_{kj}) = \eta_{kj}$ et $\log(1 - \pi_{kj}) = -\log(1 + e^{\eta_{kj}})$. La partie lisse de la fonction objectif est la log-vraisemblance négative, normalisée par n afin de rendre le choix de λ_1 et λ_2 indépendant de la taille de l'échantillon :

$$f(\mathbf{B}) = -\frac{1}{n} \ell(\mathbf{B}) = \frac{1}{n} \sum_{j=1}^q \sum_{k=1}^n \left\{ \log(1 + e^{\eta_{kj}}) - Y_{kj} \eta_{kj} \right\}.$$

On notera que f est *séparable* en les colonnes de $\mathbf{B}$: seule la pénalité de fusion, portée par le graphe des sites viraux, couple les différents sites entre eux. Le calcul du gradient peut donc être mené site par site, le couplage étant entièrement reporté sur l'opérateur proximal.

Dérivées partielles. Comme $\partial \eta_{kj} / \partial \beta_{ij} = x_{ki}$ et

$$\frac{\partial}{\partial \beta_{ij}} \log(1 + e^{\eta_{kj}}) = \frac{e^{\eta_{kj}}}{1 + e^{\eta_{kj}}} x_{ki} = \pi_{kj} x_{ki},$$

on obtient, pour tout SNP $i \in \{1, \dots, p\}$ et tout site viral $j \in \{1, \dots, q\}$,

$$\frac{\partial f}{\partial \beta_{ij}} = \frac{1}{n} \sum_{k=1}^n x_{ki} (\pi_{kj} - Y_{kj}), \quad \text{et} \quad \frac{\partial f}{\partial \beta_{0j}} = \frac{1}{n} \sum_{k=1}^n (\pi_{kj} - Y_{kj}).$$

Le gradient s'interprète comme la covariance empirique entre le génotype au SNP i et le résidu $\pi_{kj} - Y_{kj}$: un SNP dont la distribution suit les erreurs de prédiction du site viral j verra son coefficient d'autant plus déplacé lors du pas de gradient.

Écriture matricielle. En notant $\mathbf{\Pi}(\mathbf{B}) = (\pi_{kj})_{k,j} \in [0, 1]^{n \times q}$ la matrice des probabilités prédites, les expressions précédentes se résument à

$$\nabla f(\mathbf{B}) = \frac{1}{n} \mathbf{X}^\top (\mathbf{\Pi}(\mathbf{B}) - \mathbf{Y}) \in \mathbb{R}^{p \times q},$$

ce qui correspond à la forme utilisée à l'étape de descente de FISTA, le gradient y étant évalué au point extrapolé plutôt qu'en l'itéré courant. Son évaluation ne requiert que deux produits matriciels, soit un coût en $\mathcal{O}(npq)$ par itération, qui peut être fortement réduit en exploitant le caractère creux de $\mathbf{X}$ et de $\mathbf{B}$ au fil des itérations.

Constante de Lipschitz. En dérivant une seconde fois et en utilisant $\partial\pi_{kj}/\partial\eta_{kj} = \pi_{kj}(1 - \pi_{kj})$, la hessienne de f est bloc-diagonale, chaque bloc correspondant à un site viral :

$$\nabla_{\beta,j}^2 f(\mathbf{B}) = \frac{1}{n} \mathbf{X}^\top \mathbf{W}_j \mathbf{X}, \quad \mathbf{W}_j = \text{diag}(\pi_{kj}(1 - \pi_{kj}))_{k=1,\dots,n}.$$

Comme $\pi(1 - \pi) \leq 1/4$ pour tout $\pi \in [0, 1]$, on a $\nabla^2 f \preceq \frac{1}{4n} \mathbf{X}^\top \mathbf{X}$ uniformément en $\mathbf{B}$, ce qui garantit que ∇f est L -lipschitzien avec

$$L = \frac{1}{4n} \lambda_{\max}(\mathbf{X}^\top \mathbf{X}) = \frac{1}{4n} \sigma_{\max}(\mathbf{X})^2,$$

constante commune à tous les sites viraux. En très grande dimension, cette valeur propre n'est pas calculée explicitement mais approchée par la méthode de la puissance itérée ; à défaut, la majoration $\lambda_{\max}(\mathbf{X}^\top \mathbf{X}) \leq \|\mathbf{X}\|_F^2$ fournit un pas admissible, plus conservateur mais immédiat. Enfin, le gradient ne porte que sur f : les deux pénalités, non différentiables, sont entièrement prises en charge par l'opérateur proximal.

4.1.6 Limites de l'algorithme FISTA

Cependant, dans le contexte de très haute dimensionnalité des données, l'algorithme FISTA met un temps de calcul très long pour converger.

En effet, après avoir testé sur un sous-ensemble de données afin de pouvoir estimer le temps d'implémentation sur l'ensemble des données, on a pu constater un temps de calcul de plusieurs mois pour l'ensemble du jeu de données.

De plus, l'algorithme FISTA ne peut pas être parallélisé du à la dépendance entre les sites qui impose de calculer les coefficients simultanément.

Ainsi, dans le cadre du stage il n'y pas eu de possibilité de tester l'algorithme FISTA sur l'ensemble des données, et nous n'avons pas pu obtenir de résultats. Il est néanmoins possible de tester l'algorithme sur un sous-ensemble de données, mais les résultats obtenus ne sont pas représentatifs de l'ensemble des données. Cette approche a donc été laissée de côté pour se concentrer sur une approche plus adaptée à l'ensemble des données et au temps de ce stage de Master 2.

4.2 Modèle avec effets aléatoires

Le modèle GFL présenté précédemment permet de prendre en compte la corrélation locale entre sites, mais uniquement via un graphe construit. Il ne modélise pas la structure globale

de parenté génétique au sein des populations hôte et virale, pourtant décrite comme un facteur de confusion majeur dans les études d'interaction génome-à-génome [Naret2018]. Une approche alternative, largement utilisée dans les études d'association (GWAS) classiques, consiste à modéliser cette structure via des effets aléatoires, plutôt que par un nombre limité de composantes principales ou un graphe de corrélation. Cette stratégie a notamment été adaptée dans un contexte similaire par [ATOMM] au travers de la méthode ATOMM (*Adaptive Two-way Mixed Model*), qui introduit un effet aléatoire distinct pour l'hôte et pour le virus.

En essayant de coller les notations le plus possible avec le modèle précédent et en reprenant cette idée, le modèle logistique s'écrit alors comme un modèle mixte linéaire généralisé (GLMM) à deux effets aléatoires :

$$\text{logit}(P(Y_i = 1)) = \beta_0 + W\alpha + X_j\beta_{ij} + \eta_v + \eta_h$$

où $W\alpha$ regroupe les effets fixes (covariables telles que l'âge ou le sexe), $X_j\beta_{ij}$ représente l'effet du SNP j sur le site viral i , et les deux effets aléatoires

$$\eta_v \sim \mathcal{N}(0, \sigma_v^2 K_v), \quad \eta_h \sim \mathcal{N}(0, \sigma_h^2 K_h)$$

capturent respectivement la structure de parenté du virus et de l'hôte, via les matrices de parenté K_v et K_h .

Contrairement aux composantes principales, ces matrices résument l'intégralité de la similarité génétique entre individus (ou souches), sans perte d'information liée à un nombre de dimensions fixé en amont.

Dans ce cadre, l'intérêt principal n'est plus seulement d'estimer les coefficients du modèle, mais de tester la significativité de l'association entre chaque SNP de l'hôte j et chaque site viral i , c'est-à-dire tester " $H_0 : \beta_{ij} = 0$ ". Or, ce test doit être répété pour un très grand nombre de paires SNP-site viral, et une estimation classique du modèle par maximum de vraisemblance nécessiterait de réinverser la matrice de covariance globale à chaque test, ce qui est numériquement impossible à l'échelle de nos données. Il est donc nécessaire d'utiliser une méthode d'estimation factorisée, qui sépare l'estimation des paramètres de nuisance (communs à tous les tests) de celle du test d'association lui-même : le test du score de Rao.

4.2.1 Estimation - Test du score de Rao

L'évaluation de chaque paires de variants (hôte, virus) implique d'ajuster le modèle mixte des millions de fois. Or, l'estimation des composantes de la variance (σ_v^2 , σ_h^2) par maximum de vraisemblance nécessite l'inversion répétée de matrices de grande dimension, ce qui représente un coût computationnel important. Les tests du score de Rao est implémenté dans le package *GMMAT* de **R**.

Concrètement, la procédure se déroule en deux étapes :

1. Ajustement sous H_0 : On force le coefficient d'intérêt β_{ij} à 0. Le modèle nul ne contenant que l'intercept et les effets aléatoires. On ajuste le modèle une seule fois par phénotype viral pour estimer les paramètres de nuisance et les composantes de la variance.
2. Calcul du score : Pour chaque variant de l'hôte j , on évalue le gradient de la log-vraisemblance au point $\beta_{ij} = 0$. Si ce gradient est significativement éloigné de zéro, l'hypothèse nulle est rejetée, indiquant une association entre X_j et Y_i .

Cette méthode permet d'éviter le réajustement des effets aléatoires pour chaque SNP testé, réduisant ainsi drastiquement la complexité algorithmique tout en conservant une grande robustesse statistique.




FIGURE 6 – Test du score de Rao

La contre partie de ce test est qu'il ne fournit pas d'estimation directe de l'effet β_{ij} , mais uniquement une statistique de test et une p value associée. Cependant, dans le contexte d'une étude exploratoire visant à identifier des associations potentielles, cette limitation est acceptable. Néanmoins, pour les associations les plus prometteuses, il est possible de réajuster le modèle complet afin d'obtenir des estimations précises des effets et de leurs intervalles de confiance.

Il existe quand même des façons d'obtenir une estimation de l'effet β_{ij} à l'aide des p-values.

4.2.2 Estimation approchée de l'effet β_{ij}

On dispose de n individus, p sites de SNP de l'hôte indexés par $j \in \{1, \dots, p\}$ et q sites viraux indexés par $i \in \{1, \dots, q\}$. Pour un site viral i fixé, on note $\ell_i(\theta)$ la log-vraisemblance pénalisée du modèle mixte et $\theta_{ij} = (\beta_{ij}, \gamma_i)$, $\gamma_i = (\beta_0, \alpha^\top, \sigma_v^2, \sigma_h^2)^\top$, où $\beta_{ij} \in \mathbb{R}$ est le paramètre d'intérêt et γ_i le vecteur des paramètres de nuisance.

On remarquera que les paramètres de nuisance ne dépendent que du site viral i , et non du SNP testé j : c'est là tout l'intérêt de la méthode. Le modèle nul est ajusté q fois — une fois par phénotype viral — alors que $p \times q$ tests sont effectués. Le coût dominant, l'estimation des composantes de la variance (σ_v^2, σ_h^2) , est donc factorisé entre les p SNP.

On rappelle que l'hypothèse testée est $H_0 : \beta_{ij} = 0$ contre $H_1 : \beta_{ij} \neq 0$. On note $\tilde{\theta}_i = (0, \hat{\gamma}_i)$ l'estimateur du maximum de vraisemblance *constraint*, c'est-à-dire l'ajustement du modèle nul, où $\hat{\gamma}_i$ maximise $\gamma \mapsto \ell_i(0, \gamma)$.

Détails :

Le score et la matrice d'information de Fisher se décomposent par blocs à cause de θ_{ij} :

$$U(\theta_{ij}) = \begin{pmatrix} U_\beta \\ U_\gamma \end{pmatrix}, \quad \mathcal{I}(\theta_{ij}) = \begin{pmatrix} \mathcal{I}_{\beta\beta} & \mathcal{I}_{\beta\gamma} \\ \mathcal{I}_{\gamma\beta} & \mathcal{I}_{\gamma\gamma} \end{pmatrix}.$$

Par définition de $\hat{\gamma}_i$, la composante de nuisance du score s'annule au point contraint :

$$U_\gamma(\tilde{\theta}_i) = 0. \quad (1)$$

On introduit l'*information efficace* relative à β_{ij} , définie comme le complément de Schur du bloc de nuisance et évaluée en $\tilde{\theta}_i$:

$$V_{ij} = \mathcal{I}_{\beta\beta} - \mathcal{I}_{\beta\gamma} \mathcal{I}_{\gamma\gamma}^{-1} \mathcal{I}_{\gamma\beta}. \quad (2)$$

Elle mesure l'information disponible sur β_{ij} une fois retirée la part partagée avec les effets fixes et les effets aléatoires. La formule d'inversion par blocs donne $[\mathcal{I}^{-1}]_{\beta\beta} = V_{ij}^{-1}$, et la statistique du score s'écrit alors

$$T_{ij} = \frac{U_{ij}^2}{V_{ij}} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \chi_1^2 \quad \text{sous } H_0, \quad U_{ij} \equiv U_\beta(\tilde{\theta}_i). \quad (3)$$

Proposition 4.1 (Approximation de Newton–Raphson en une itération). *Une itération de l'algorithme de Newton–Raphson initialisée au point contraint $\tilde{\theta}_i$ fournit l'approximation*

$$\boxed{\hat{\beta}_{ij} = \frac{U_{ij}}{V_{ij}}, \quad \widehat{\text{SE}}(\hat{\beta}_{ij}) = \frac{1}{\sqrt{V_{ij}}}} \quad (4)$$

Démonstration. L'itération de Newton–Raphson appliquée à l'équation de vraisemblance $U(\theta) = 0$ à partir de $\tilde{\theta}_i$ s'écrit $\hat{\theta}^{(1)} = \tilde{\theta}_i + \mathcal{I}(\tilde{\theta}_i)^{-1} U(\tilde{\theta}_i)$. En extrayant la composante en β , et en utilisant successivement (1) puis l'inversion par blocs :

$$\hat{\beta}_{ij} = \underbrace{0}_{\text{valeur initiale}} + [\mathcal{I}^{-1}]_{\beta\beta} U_{ij} + [\mathcal{I}^{-1}]_{\beta\gamma} \underbrace{U_\gamma(\tilde{\theta}_i)}_{=0} = \frac{U_{ij}}{V_{ij}}.$$

L'annulation du second terme est essentielle : c'est elle qui rend l'estimateur indépendant d'une mise à jour simultanée des paramètres de nuisance, et donc calculable sans réajuster le modèle mixte. $\square$

Remarque 4.2 (Interprétation). De façon équivalente, l'estimateur revient à remplacer la log-vraisemblance profilée par son approximation quadratique au voisinage de $\beta_{ij} = 0$: son développement de Taylor à l'ordre 1, $\partial \ell_i^{\text{prof}} / \partial \beta \simeq U_{ij} - V_{ij} \beta$, s'annule exactement en U_{ij}/V_{ij} . Le score U_{ij} donne la pente de la vraisemblance en 0, l'information V_{ij} sa courbure, et leur rapport localise le sommet de la parabole ainsi ajustée.

Cohérence avec les p-values déjà calculées. En reportant (4) dans la statistique de Wald, on obtient

$$z_{\text{Wald}} = \frac{\hat{\beta}_{ij}}{\widehat{\text{SE}}(\hat{\beta}_{ij})} = \frac{U_{ij}/V_{ij}}{V_{ij}^{-1/2}} = \frac{U_{ij}}{\sqrt{V_{ij}}} = z_{\text{score}}, \quad (5)$$

c'est-à-dire exactement la racine signée de (3). Les coefficients reconstruits sont donc rigoureusement compatibles avec les p-values issues du criblage : l'approximation n'introduit aucune incohérence dans les résultats déjà produits, et le signe de U_{ij} fournit directement le sens de l'association.

Expression opérationnelle dans le modèle mixte. Dans l'implémentation *GMMAT*, le modèle nul est ajusté par quasi-vraisemblance pénalisée. En notant $\hat{\pi}^{(i)}$ le vecteur des probabilités prédites sous H_0 pour le site viral i , $D_i = \text{diag}(\hat{\pi}_k^{(i)}(1 - \hat{\pi}_k^{(i)}))$, et

$$\Sigma_i = D_i^{-1} + \hat{\sigma}_v^2 K_v + \hat{\sigma}_h^2 K_h, \quad P_i = \Sigma_i^{-1} - \Sigma_i^{-1} W (W^\top \Sigma_i^{-1} W)^{-1} W^\top \Sigma_i^{-1},$$

le score et sa variance prennent la forme

$$U_{ij} = X_j^\top P_i \tilde{Y}_i, \quad V_{ij} = X_j^\top P_i X_j, \quad (6)$$

où $\tilde{Y}_i$ désigne le vecteur de travail associé au site viral i . La matrice de projection P_i est la forme opérationnelle de l'information efficace (2) : elle retire simultanément de X_j la part expliquée par les covariables W et celle absorbée par les structures de parenté K_v et K_h . Cruciale pour le coût de calcul, P_i ne dépend que de i : elle est calculée une seule fois par site viral, et chaque SNP ne coûte plus que deux produits matrice-vecteur.

Domaine de validité. L'estimateur (4) est *efficace au premier ordre* : sous les alternatives locales $\beta_{ij} = h/\sqrt{n}$, il est asymptotiquement équivalent au maximum de vraisemblance et partage sa loi limite. Cette propriété repose toutefois sur la proximité entre le point d'initialisation $\beta_{ij} = 0$ et la valeur vraie, ce qui reste vérifié pour l'immense majorité des $p \times q$ paires testées, dont l'effet est nul ou faible. La qualité de l'approximation se dégrade en revanche dans trois situations :

- **effets de forte amplitude** — l'approximation quadratique de la vraisemblance induit une atténuation de $|\hat{\beta}_{ij}|$ vers zéro. Paradoxalement, ce sont donc les associations les plus significatives, celles qui nous intéressent, qui sont les moins bien estimées ;
- **variants rares ou sites viraux déséquilibrés** — lorsque la fréquence allélique du SNP ou celle du variant viral est faible, la courbure de la vraisemblance est mal décrite par V_{ij} , et la convergence vers la loi χ_1^2 de (3) est elle-même lente ;
- **quasi-séparation** — le maximum de vraisemblance diverge alors que $\hat{\beta}_{ij}$ reste fini, l'écart devenant arbitrairement grand.

À ces limites propres à l'approximation s'ajoute le biais connu de la quasi-vraisemblance pénalisée pour les réponses binaires, dont $\hat{\beta}_{ij}$ hérite.

Stratégie retenue. Ces considérations conduisent à une procédure en deux temps, qui prolonge naturellement celle décrite plus haut :

1. **Criblage.** Les $p \times q$ tests du score fournissent, à coût nul, les estimations $\hat{\beta}_{ij} = \text{SCORE}/\text{VAR}$. Celles-ci sont utilisées pour l'exploration — sens et amplitude relative des effets, ordonnancement des associations, représentations de type *volcano plot* — usages pour lesquels une précision au premier ordre est amplement suffisante.
2. **Confirmation.** Les paires franchissant le seuil de significativité après correction pour tests multiples font l'objet d'un réajustement complet du modèle mixte, via `glmm.wald()`. Le nombre de modèles concernés étant réduit de plusieurs ordres de grandeur, le surcoût est négligeable au regard du criblage initial. Cette étape fournit les estimations

et intervalles de confiance rapportés dans les résultats, précisément dans le régime où l'approximation (4) est la moins fiable.

Ce dispositif combine ainsi le gain computationnel du test du score, seul praticable à l'échelle de $p \times q$ paires, et l'exactitude du maximum de vraisemblance là où elle est nécessaire.

5 Résultats et discussion

5.1 Les jeux de données

5.1.1 Hépatite C

Le jeu de données du VHC porte sur 470 individus infectés par une souche de génotype 3a. Pour chacun, nous disposons du génome viral séquencé, d'un génotypage hôte de 300 000 sites, ainsi que de l'âge, du sexe, de la charge virale, du groupe ethnique déclaré et du pays de recrutement.

La composition de la cohorte n'est pas neutre pour la suite (figure 7). Le recrutement s'est fait dans cinq pays, avec une nette surreprésentation du Royaume-Uni, et la très grande majorité des individus sont d'ascendance européenne. Les autres groupes ne sont présents qu'en effectifs réduits, principalement une composante asiatique au Royaume-Uni et en Australie. Cette structure a deux conséquences. D'une part, un SNP dont la fréquence allélique diffère fortement entre groupes peut se retrouver associé à une mutation virale simplement parce que les deux sont plus fréquents dans le même sous-groupe ; c'est précisément ce que l'effet aléatoire d'apparement est censé absorber, et nous vérifierons plus loin que c'est bien le cas. D'autre part, la puissance de détection est en pratique portée par le groupe majoritaire : une association spécifique à un groupe minoritaire a peu de chances d'être détectée ici.




FIGURE 7 – Répartition des individus de la cohorte VHC par pays de recrutement et par groupe ethnique déclaré.

5.1.2 Dengue

Le jeu de données dengue est de nature un peu différente. Il regroupe 270 individus, tous recrutés au Sri Lanka. L'origine ethnique n'est pas renseignée, mais le recrutement sur un unique pays permet de supposer une population hôte nettement plus homogène que dans le cas du VHC. En contrepartie, nous ne pouvons pas vérifier cette hypothèse directement, et nous nous en remettons entièrement à la matrice d'apparement.

Nous disposons en revanche d'une covariable absente du jeu VHC : le statut d'infection antérieure. Ce dernier point a son importance en dengue, où une seconde infection par un sérotype différent est un facteur de risque reconnu de forme sévère. Ces variables n'entrent pas dans les modèles présentés ici, qui portent sur les mutations virales et non sur le phénotype clinique, mais elles ouvrent une piste que nous évoquons en conclusion.

La particularité déterminante de ce jeu de données est ailleurs : il contient trois sérotypes viraux distincts. Nous y revenons en section 5.3.4, car cette structure impose de modifier le codage.

5.2 Choix du codage des sites viraux

Le codage de la réponse virale a occupé une part importante du stage, et mérite d'être explicité avant de présenter les résultats, car il conditionne tout ce qui suit.

Le codage de départ est binaire : pour un site donné, on note 0 l'acide aminé de référence et 1 tout acide aminé qui en diffère. La référence retenue est l'acide aminé majoritaire dans le jeu de données. Ce codage revient à mesurer la survenue d'un événement mutationnel, sans rien dire de sa nature.

Un filtrage préalable est indispensable. Le VHC est un virus à ARN, dont le taux de mutation élevé entretient une forte variabilité, mais tous les sites ne sont pas également variables : certains sont soumis à de fortes contraintes fonctionnelles et restent quasiment invariants. Un site où la mutation n'est observée que chez deux ou trois individus ne peut donner lieu à aucun test exploitable. Nous avons donc écarté les sites dont la fréquence de l'acide aminé minoritaire est inférieure à 5 %, ce qui laisse 427 sites pour le VHC.

Le second codage envisagé remplace cette variable binaire par la *distance de Grantham* entre l'acide aminé observé et celui de référence (section 3.2.2). La réponse devient continue et positive, nulle en l'absence de substitution, et d'autant plus grande que la substitution est chimiquement radicale. L'intérêt est direct : une substitution leucine/isoleucine, très peu susceptible d'altérer la protéine, ne pèse plus autant qu'une substitution cystéine/tryptophane. Autrement dit, on cherche non plus les positions qui mutent, mais celles qui mutent et ont un impact fort.

Ce gain se paie de deux façons, qu'il faut avoir en tête pour lire la suite. D'abord, l'analyse se restreint aux sites dont la variabilité se traduit effectivement par un changement d'acide aminé, ce qui réduit le nombre de sites testables et donc la puissance. Ensuite, la distribution de la réponse change complètement de forme : au lieu d'une variable de Bernoulli, on obtient une variable très asymétrique, avec une masse importante en zéro et quelques valeurs élevées. Les coefficients des deux modèles ne sont donc pas comparables directement, ni en signe, ni en amplitude : dans un cas il s'agit d'un log-odds, dans l'autre d'un effet en unités de distance de Grantham.

5.3 Modèle linéaire généralisé à effets aléatoires

5.3.1 Mise en œuvre et seuil de significativité

Le modèle décrit en section 4.2 a été ajusté avec le package *GMMAT* de R, sur le cluster *iTrop*. Le nombre de tests correspond au produit du nombre de SNPs de l'hôte par le nombre de sites viraux retenus, soit de l'ordre de 10^9 pour le VHC. Une exécution séquentielle demanderait environ deux jours ; la répartition sur 36 cœurs ramène le calcul à une heure.

Le choix du seuil mérite qu'on s'y arrête, car il n'est pas un simple Bonferroni. Avec de l'ordre de 2×10^6 SNPs, une correction de Bonferroni appliquée à *un seul site viral* donnerait un seuil autour de $2,5 \times 10^{-8}$. Une correction appliquée à la grille complète des 10^9 paires donnerait 5×10^{-11} . Le seuil que nous retenons, 10^{-8} , se situe entre les deux, et ce positionnement est un compromis assumé plutôt qu'une propriété statistique.

Deux effets jouent en effet en sens contraire. D'un côté, Bonferroni suppose l'indépendance des tests, hypothèse clairement fautive entre SNPs voisins en déséquilibre de liaison : le nombre effectif de tests indépendants est sensiblement inférieur au nombre de SNPs, et la correction est donc trop sévère. De l'autre, notre seuil ignore la multiplicité liée aux 427 sites viraux, et sur ce plan il est trop permissif — environ 200 fois plus que le Bonferroni complet. Concrètement, sous l'hypothèse nulle et sous indépendance, 10^9 paires testées à 10^{-8} produisent une dizaine de faux positifs attendus.

Il faut donc lire les décomptes qui suivent comme des listes de *signaux candidats*, majoritairement réels mais pas exclusivement. C'est cohérent avec l'objectif du stage, qui est exploratoire :

nous cherchons à repérer des pistes, quitte à ce que la confirmation passe ensuite par une validation ciblée.

5.3.2 Grille de lecture des figures

Les trois mêmes types de représentation reviennent pour chaque analyse. Plutôt que d'en redonner la lecture à chaque fois, nous la fixons ici une fois pour toutes.

Le **cercle d'association** donne la vue d'ensemble. Les chromosomes de l'hôte occupent une partie de la circonférence, les protéines virales l'autre, et chaque lien relie un SNP à un site viral significatif. Ce qu'il faut y regarder n'est pas le nombre de liens, qui est trompeur — un même locus représenté par cinquante SNPs corrélés produit cinquante liens —, mais leur *répartition* : signal concentré sur une région, ou dispersé sur l'ensemble du génome.

Le **Manhattan plot** détaille un site viral donné : chaque point est un SNP hôte, placé selon sa position génomique et selon $-\log_{10}(p)$. Le critère de crédibilité n'y est pas la hauteur du pic mais sa *forme*. Une association réelle se manifeste par un groupe de marqueurs contigus qui montent ensemble, parce que le déséquilibre de liaison fait que les SNPs voisins du variant causal lui sont partiellement corrélés. À l'inverse, un point isolé très haut, sans aucun voisin élevé, évoque davantage un artefact de génotypage qu'un signal biologique.

Le **QQ plot** ne dit rien sur un SNP en particulier, mais tout sur la calibration du modèle. Il compare la distribution des p-values observées à celle attendue sous l'hypothèse nulle. Le profil recherché est une superposition à la diagonale sur l'essentiel de la distribution, avec une déviation confinée à l'extrême queue : cela signifie que la grande majorité des tests se comporte comme sous H_0 , et que seule une petite fraction s'en écarte. Un décollement précoce, dès les faibles valeurs de $-\log_{10}(p)$, signale au contraire que quelque chose n'est pas absorbé par le modèle — le plus souvent une structure de population résiduelle.

Enfin, les **intervalles de confiance** des coefficients, obtenus par réajustement complet du modèle via `glmm.wald()`, donnent le sens et l'amplitude de l'effet. Dans le modèle logistique, β_{ij} est un log-odds : un coefficient positif signifie que *chaque copie supplémentaire de l'allèle alternatif au SNP hôte augmente la probabilité d'observer la mutation au site viral*. C'est la signature attendue d'un échappement : l'hôte porteur exerce une pression, le virus y répond en mutant à cette position. Un coefficient négatif décrit la situation inverse, les porteurs étant associés au maintien de l'acide aminé de référence. Dans les deux cas, il s'agit d'une association et non d'un lien causal établi.

5.3.3 Codage binaire appliqué au VHC

Nous obtenons 287 couples (SNP hôte, site viral) sous le seuil de 10^{-8} , répartis sur 32 sites viraux distincts, soit environ 7 % des 427 sites testés. Cet ordre de grandeur est raisonnable : la grande majorité du génome viral ne montre aucune association, ce qui est exactement ce qu'on attend.

La figure 8 est très structurée, et de deux manières.

Du côté de l'hôte, le signal converge massivement vers le chromosome 6, et de façon encore plus marquée si l'on ne retient que les liens rouges. Cette structure en éventail, où un même faisceau de SNPs se projette vers de nombreux sites viraux, s'explique par la conjonction de deux phénomènes : les SNPs de ce faisceau sont fortement corrélés entre eux, et le locus qu'ils marquent agit sur plusieurs positions du génome viral à la fois. C'est un résultat attendu, et c'est même rassurant qu'il apparaisse : le chromosome 6 porte la région HLA, dont les molécules présentent les peptides viraux au système immunitaire. Un variant HLA sélectionne les peptides reconnus, donc les positions virales où une mutation permet d'échapper à la reconnaissance.

Du côté viral, les liens ne se répartissent pas uniformément sur le génome : la protéine NS3 concentre la majorité des associations et la quasi-totalité des liens rouges. Il faut toutefois relativiser cette concentration, car NS3 est l'une des plus longues protéines du VHC et contribue




FIGURE 8 – Cercle d’association entre les SNPs de l’hôte et les sites viraux du VHC (codage binaire). Liens gris : $p < 10^{-8}$; liens rouges : $p < 10^{-10}$.

donc mécaniquement à un plus grand nombre de sites testés. Une comparaison honnête demanderait de rapporter le nombre d’associations au nombre de sites polymorphes testés dans chaque protéine.

Enfin, plusieurs de ces associations recoupent celles publiées par ANSARI *et al.* [1], notamment celle impliquant le site viral 1450. C’est le point important de cette sous-section : le jeu VHC sert ici de contrôle, et le fait de retrouver des signaux déjà décrits par une autre méthode valide l’implémentation avant de l’appliquer à la dengue.

Site viral 1450. La figure 9 présente le *Manhattan plot* de ce site.

Le signal est dominé par un pic unique sur le chromosome 6, qui atteint $-\log_{10}(p) \approx 19$, soit plus de dix ordres de grandeur au-delà du seuil. Surtout, ce pic présente la forme attendue décrite en 5.3.2 : il est porté par une colonne dense de marqueurs contigus, et non par un point isolé. La largeur de cette colonne reflète l’étendue du bloc de déséquilibre de liaison autour du variant causal, ce qui est cohérent avec la région HLA, connue pour ses blocs particulièrement longs.

En dehors de ce pic, le nuage reste plat et homogène le long du génome. C’est un bon indicateur : si la structure de population était mal corrigée, on observerait une élévation générale des statistiques de test sur l’ensemble des chromosomes, ce qui n’est pas le cas. L’effet aléatoire d’apparement fait donc son travail. Un point sur le chromosome 2 émerge légèrement au-dessus du nuage, sans atteindre le seuil ni être accompagné de voisins élevés : il ne peut pas être retenu.

Le *QQ plot* (figure 10) confirme cette lecture. Les p-values observées suivent la diagonale sur la première moitié de la distribution et ne s’en écartent que dans la queue, de façon tardive




FIGURE 9 – *Manhattan plot* pour le site viral 1450 (VHC, codage binaire).





FIGURE 10 – *QQ plot* pour le site viral 1450 (VHC, codage binaire).

et abrupte. C'est le profil d'un signal localisé : seule une petite fraction des tests s'écarte du modèle nul.

Un mot enfin sur le signe de l'effet. Les intervalles de confiance reportés en annexe (figure ??) montrent que *toutes* les associations du site 1450 ont un coefficient **négalif**, compris entre $-0,5$ et $-2,5$. Les porteurs de l'allèle alternatif à ces SNPs sont donc associés au *maintien* de l'acide aminé de référence en position 1450, et non à sa mutation. Ce n'est pas contradictoire avec l'hypothèse d'échappement : le sens du coefficient dépend de l'allèle arbitrairement codé comme

alternatif, et un signe négatif signifie simplement que c'est l'*autre* allèle du SNP qui accompagne la mutation virale. La remarque a néanmoins son importance pour la lecture des figures suivantes, où les signes ne sont pas tous orientés dans le même sens.



Le SNP **rs11758516**, également sur le chromosome 6, est le variant le plus fortement associé, avec $-\log_{10}(p) \approx 11,5$. Il est le seul à franchir nettement le seuil ; les autres marqueurs annotés se situent entre 4 et 6, c'est-à-dire dans la zone suggestive, qui ne permet aucune conclusion.

rs11758516 n'a pas d'implication médicale documentée ni de fonction connue dans les principales bases annotées. Sa proximité avec la région HLA reste l'élément d'interprétation le plus solide dont nous disposons.

5.3.4 Codage binaire appliqué à la dengue




FIGURE 12 – *QQ plot* pour le site viral 1276 (VHC, codage binaire).




FIGURE 13 – Arbre phylogénétique des sérotypes de la dengue présents dans l'échantillon.

La variable réponse deviendrait alors une étiquette de sérotype déguisée, et les associations détectées ne diraient rien d'autre que « tel groupe d'hôtes est infecté par tel sérotype ».

Nous modifions donc le codage de manière à ne retenir que la variation informative : chaque site est codé selon la présence ou l'absence d'une mutation *par rapport à la séquence de référence de son propre sérotype*. Un site conservé au sein de chaque sérotype, même s'il diffère entre sérotypes, est ainsi codé uniformément à 0 et ne génère aucun signal.

Deux précautions accompagnent ce recodage. D'abord, la numérotation des positions doit être définie sur un alignement commun à tous les sérotypes, sans quoi les positions comparées ne seraient pas homologues ; nous avons utilisé pour cela la méthode d'alignement décrite en section 3.2.1. Ensuite, un même codage à 1 ne recouvre pas nécessairement la même substitution selon le sérotype : le codage mesure l'événement mutationnel, non sa nature. C'est une perte d'information assumée à ce stade, que le codage continu est censé compenser en partie.

Le prix à payer est une forte réduction de la variabilité disponible : après recodage et filtrage, il ne reste que **193 sites viraux polymorphes**, contre 427 pour le VHC, pour environ 3×10^5 SNPs hôtes. Ce point est essentiel pour lire ce qui suit.

Résultats d'ensemble, et une réserve importante. Nous obtenons **480 couples** (SNP, site viral) sous le seuil de 10^{-8} , répartis sur **90 sites viraux distincts**. La figure 14 en donne la vue d'ensemble.




FIGURE 14 – Cercle d'association entre les SNPs de l'hôte et les sites viraux de la dengue (codage binaire relatif au sérotype).

Ces chiffres appellent une réserve que nous préférons poser d'emblée plutôt qu'en conclusion. 90 sites associés sur 193 testés représentent près d'un site sur deux, alors que le VHC donnait 32 sites sur 427, soit un sur treize. Il n'est pas plausible que la moitié du génome de la dengue soit sous pression de sélection détectable dans un échantillon de cette taille. Par ailleurs, la grille dengue ne compte qu'environ 6×10^7 paires, ce qui, au seuil de 10^{-8} , ne prédit qu'un demi faux positif attendu sous indépendance — très loin des 480 observés.

Le cercle lui-même est cohérent avec cette réserve : contrairement au VHC, les liens sont distribués sur l'ensemble des chromosomes hôtes sans concentration nette, ce qui ressemble davantage à un fond diffus qu'à un ensemble de loci identifiés. Les QQ plots examinés ci-dessous confirment cette impression, et nous discutons en fin de section les causes possibles.

Site viral 2775. Le site 2775 se situe dans NS5, la plus grande protéine non structurale du virus. NS5 porte deux activités enzymatiques indispensables à la réplication, l'ARN polymérase ARN-dépendante et une méthyltransférase, et intervient également dans l'inhibition de la réponse interféron de l'hôte. C'est donc a priori une protéine intéressante pour notre question.

Le Manhattan plot (figure 15) est nettement plus bruité que ses équivalents VHC. Le nuage de fond est plus haut, et une quinzaine de points franchissent le seuil sans qu'aucun pic ne se détache franchement. En appliquant le critère de forme énoncé en 5.3.2, les candidats les moins fragiles sont AX-11278381 sur le chromosome 3, AX-42210719 sur le chromosome 7 et




FIGURE 15 – *Manhattan plot* pour le site viral 2775 (dengue, codage binaire).

AX-11112091, qui sont accompagnés de marqueurs voisins élevés. Les autres points significatifs sont isolés : ils ne sont soutenus par aucun marqueur en déséquilibre de liaison avec eux, ce qui est difficile à concilier avec l'existence d'un variant causal dans la région, et évoque plutôt un artefact de génotypage ou un effet de faible fréquence allélique.




FIGURE 16 – *QQ plot* pour le site viral 2775 (dengue, codage binaire).

Le *QQ plot* (figure 16) est ici le résultat le plus informatif, et il est moins favorable que pour le VHC : la courbe décolle de la diagonale très tôt, dès $-\log_{10}(p) \approx 1$, et reste au-dessus sur toute son étendue. Ce n'est pas le profil d'un signal localisé mais celui d'une inflation générale des statistiques de test, qui indique qu'une part de la structure des données n'est pas absorbée par le modèle.

Les intervalles de confiance (figure 17) sont tous positifs, ce qui va dans le sens d'un échap-




FIGURE 17 – Intervalles de confiance des coefficients pour le site viral 2775 (dengue, codage binaire).

pement : les porteurs de l’allèle alternatif sont associés à la présence de la mutation en position 2775. Mais leur *amplitude* pose problème. Les coefficients se situent entre 5 et 9 sur l’échelle logit, soit des odds-ratios de l’ordre de 10^2 à 10^4 , et les intervalles sont larges. Des effets d’une telle taille sont invraisemblables pour un variant commun et correspondent en réalité à deux des trois situations que nous avons identifiées en section 4.2.2 comme limites du dispositif : la quasi-séparation, où la vraisemblance diverge parce que le génotype prédit presque parfaitement la réponse, et les faibles fréquences alléliques, où la courbure de la vraisemblance est mal estimée. Le fait que tous les coefficients soient positifs est d’ailleurs cohérent avec cette lecture : en situation de séparation, le signe est déterminé par la configuration du tableau de contingence bien plus que par un effet biologique.

Il ne s’agit donc pas de rejeter ces associations, mais de reconnaître qu’en l’état elles ne sont pas interprétables quantitativement. Une vérification simple s’impose : reporter, pour chaque paire significative, la fréquence de l’allèle mineur du SNP et la fréquence de la mutation au site viral, et examiner le tableau de contingence croisé.

Site viral 173. Le site 173 se situe dans prM, protéine structurale qui participe à l’enveloppe du virion et dont la maturation conditionne l’infectiosité des particules virales. Il présente donc un profil fonctionnel opposé à celui de NS5, ce qui rend la comparaison intéressante.

Le signal est là aussi porté par plusieurs marqueurs (figure 18). Les candidats les plus crédibles, au sens du critère de forme, sont AX-63561232 sur le chromosome 1, AX-11239493 sur le chromosome 3 et AX-15470303 sur le chromosome 6 : ils dépassent tous $-\log_{10}(p) = 10$ et sont accompagnés de voisins élevés. On notera l’absence de concentration sur le chromosome 6 comparable à celle observée pour le VHC, ce qui n’a rien de surprenant : la puce utilisée ici n’a pas la même densité de marqueurs dans la région HLA, et rien ne garantit que le mécanisme d’échappement soit du même type.

Le *QQ plot* (figure 19) présente la même inflation précoce que pour le site 2775, avec un décollement dès $-\log_{10}(p) \approx 2$. La régularité de ce comportement d’un site à l’autre est en soi une information : il ne s’agit pas d’une particularité d’un site, mais d’un problème de calibration qui affecte l’ensemble de l’analyse dengue.

Les coefficients (figure 20) reproduisent le profil du site 2775 : tous positifs, tous compris entre 5 et 12, avec des intervalles larges. La même réserve s’applique.

L’analyse dengue est moins bien calibrée que l’analyse VHC : Trois explications nous semblent plausibles, et elles ne s’excluent pas.

La première tient à la structure virale résiduelle. Le codage relatif au sérotype supprime la variation *entre* sérotypes dans la réponse, mais il ne supprime pas la structure sous-jacente : la matrice de parenté virale K_v reste dominée par la séparation entre sérotypes, qui est d’un




FIGURE 20 – Intervalles de confiance des coefficients pour le site viral 173 (dengue, codage binaire).

d’une population homogène au Sri Lanka reste une hypothèse, et le pays compte plusieurs groupes de population distincts. Une inspection des premières composantes principales de la matrice d’apparement hôte suffirait à s’en assurer.

5.3.5 Codage continu appliqué au VHC

Le modèle a été ajusté avec le même package et sur la même infrastructure, pour un temps de calcul inchangé. La réponse est désormais la distance de Grantham entre l’acide aminé observé et la référence.

Nous obtenons 29 associations sous le seuil de 10^{-8} , réparties sur **19 sites viraux distincts**, contre 287 associations et 32 sites en codage binaire. La chute est donc importante, mais elle affecte beaucoup plus le nombre de *paires* que le nombre de *sites* : c’est cohérent avec le fait que les paires du codage binaire étaient largement redondantes, plusieurs dizaines de SNPs corrélés pointant vers le même locus.

On obtient un profil d’associations sensiblement différent. La figure 21 présente une répartition nettement plus dispersée que son équivalent binaire, des deux côtés du cercle : les liens ne se concentrent plus sur NS3, et la prédominance du chromosome 6 s’estompe au profit d’un signal réparti sur l’ensemble du génome hôte.

Cette différence admet deux lectures concurrentes, qu’il serait imprudent de trancher en l’état.

Selon la première, le codage continu révélerait des associations d’une autre nature. Le codage binaire est en effet particulièrement bien adapté à la détection de l’échappement au CMH, où ce qui compte est qu’un peptide ne soit plus reconnu, indépendamment de la nature chimique de la substitution — d’où la concentration sur le chromosome 6. En pondérant les substitutions par leur impact physico-chimique, le codage continu privilégierait au contraire des mécanismes où c’est la structure de la protéine virale qui est en jeu, et qui n’ont aucune raison d’être portés par la région HLA.

Selon la seconde, cette dispersion est simplement ce qu’on attend d’une baisse de puissance. En réduisant le nombre de sites testables et en remplaçant une réponse binaire par une réponse très asymétrique, on perd du signal ; les associations les plus robustes passent sous le seuil, et la liste retenue se peuple de signaux marginaux dont la répartition est naturellement plus uniforme.

Départager ces deux lectures ne demande pas une analyse nouvelle mais une comparaison à ensemble de sites constant : si, restreint aux seuls sites testables en continu, le codage binaire




FIGURE 21 – Cercle d’association entre les SNPs de l’hôte et les sites viraux du VHC, codage continu (distances de Grantham).

retrouve la concentration sur le chromosome 6 alors que le codage continu ne la retrouve pas, la première lecture est étayée. Si les deux la perdent, c’est la seconde. Faute d’avoir pu mener cette comparaison dans le temps du stage, nous nous en tenons ici à un constat descriptif.

La figure 22 demande une lecture différente de celle des figures précédentes, car le modèle n’est plus logistique : β_{ij} n’est plus un log-odds mais un effet exprimé en unités de distance de Grantham par copie d’allèle. Un coefficient positif signifie donc que les porteurs sont associés à une substitution chimiquement *plus radicale* à cette position, et non simplement plus fréquente. C’est l’apport propre de ce codage.

Tous les coefficients significatifs sont positifs, mais il ne faut pas en tirer une conclusion biologique : la réponse étant une distance, donc positive et nulle en l’absence de substitution, un coefficient négatif exigerait que les porteurs présentent des substitutions systématiquement plus conservatrices que les non-porteurs, configuration nettement moins probable. L’asymétrie observée est donc en grande partie mécanique.

Les amplitudes, comprises entre 0,1 et 0,55, méritent en revanche un examen. Sur une échelle de Grantham qui va de 5 à 215, un effet de 0,3 unité par copie d’allèle est très faible. Il faudrait vérifier à quoi il correspond concrètement : un léger décalage de la proportion d’individus porteurs d’une substitution, ou un vrai déplacement vers des substitutions plus radicales chez les porteurs.




FIGURE 22 – Intervalles de confiance des coefficients pour les associations VHC en codage continu (distances de Grantham).

Site viral 1613. Ce site réapparaît dans plusieurs des associations significatives, ce qui est en soi un argument en sa faveur.




FIGURE 23 – *Manhattan plot* pour le site viral 1613 (VHC, codage continu).

Le signal (figure 23) est porté par **rs11802399** sur le chromosome 1, seul marqueur à franchir

le seuil, avec **rs79221421** sur le chromosome 11 en position suggestive. Comparé au site 1450, il est nettement plus faible et ne dépasse le seuil que d’une marge réduite. Il faut être clair sur ce que cela implique : pris isolément, ce signal ne serait pas retenu. C’est sa récurrence à travers plusieurs paires significatives, et non son intensité, qui justifie qu’on s’y intéresse.

Le SNP **rs11802399** est situé dans le gène *CDC42BPA*, qui code une sérine/thréonine kinase de la famille MRCK, effecteur de la petite GTPase CDC42 et impliquée dans la réorganisation du cytosquelette d’actine. Le cytosquelette d’actine intervenant dans l’entrée et le trafic intracellulaire de nombreux virus, un lien avec le cycle viral est concevable, mais nous n’avons pas les moyens de le tester ici et cette piste doit rester présentée comme telle.




FIGURE 24 – *QQ plot* pour le site viral 1613 (VHC, codage continu).

Le *QQ plot* (figure 24) montre une distribution conforme à H_0 sur l’essentiel de son étendue, avec une déviation confinée à la queue. Le modèle est donc correctement calibré, ce qui n’était pas acquis d’avance en passant à une réponse continue et fortement asymétrique : c’est un résultat en soi, qui valide l’emploi du modèle mixte linéaire sur ce type de réponse.

Site viral 1961. Le signal est ici porté par **rs893184**, sur le chromosome 19.

Ce site est le plus intéressant des deux, pour une raison négative : l’association n’apparaît ni dans les résultats de ANSARI *et al.* [1], ni dans notre propre analyse en codage binaire. Si elle se confirme, elle serait donc spécifiquement révélée par la prise en compte de la nature des substitutions, ce qui est exactement l’apport que ce codage était censé fournir.

Il faut cependant rester mesuré. Le signal est modeste, un unique marqueur franchit le seuil, et nous ne disposons d’aucune information fonctionnelle sur **rs893184**.

Le *QQ plot* (figure 26) est le mieux calibré de tous ceux présentés : la distribution suit la diagonale sur toute son étendue, sans aucune inflation, et seuls les tout derniers points s’en écartent. Cela ne prouve évidemment pas que l’association soit réelle, mais cela écarte l’explication la plus banale, celle d’un modèle mal spécifié produisant des p-values artificiellement petites.

5.3.6 Codage continu appliqué à la dengue

5.4 Bilan des deux codages

Le tableau 1 résume l’ensemble. La colonne « sites testés », absente de la première version, nous paraît indispensable : c’est elle qui permet de comparer les proportions plutôt que les effectifs bruts, et qui fait apparaître le contraste entre 7 % de sites associés pour le VHC et 47 % pour la dengue.

la confiance dans l'implémentation. Sa limite est celle de sa définition : il traite une substitution leucine/isoleucine et une substitution cystéine/tryptophane comme le même événement.

Le codage continu corrige précisément ce défaut, au prix d'une perte de puissance nette. Son apport potentiel n'est cependant pas seulement quantitatif : le déplacement du signal hors du chromosome 6 suggère qu'il ne détecte pas les mêmes choses, mais nous avons expliqué plus haut pourquoi cette lecture reste à établir. Nous la présentons comme une hypothèse à tester, pas comme un résultat.

Recoupement des deux codages. Le tableau 2 en annexe reprend les paires significatives en codage continu et donne leur p-value en codage binaire. La grande majorité d'entre elles n'y sont pas significatives, ce qui va dans le sens de deux ensembles de signaux largement disjoints. Quelques paires font exception, avec des p-values binaires de l'ordre de 10^{-3} à 10^{-4} : sans atteindre le seuil, elles indiquent un signal présent dans les deux analyses et renforcé par la prise en compte de la nature des substitutions. Ce sont probablement les candidats les plus intéressants du lot.

Pistes. Trois directions nous paraissent prioritaires, par ordre de coût croissant.

La comparaison des deux codages à ensemble de sites constant est la moins coûteuse et la plus rentable : elle ne demande aucun calcul nouveau et permettrait de trancher entre les deux lectures du profil obtenu en codage continu.

La calibration du modèle de la dengue vient ensuite : Comparer des sites entre serotypes peut-être délicat, il n'est pas impossible qu'une partie des effets aléatoires capturent cette structure sans corriger correctement la stratification de la population virale. Une analyse sérotype par sérotype permettrait de vérifier si les signaux persistent et si l'inflation des p-values est réduite.

Enfin, le codage lui-même peut être repensé. La matrice de Grantham est un choix parmi d'autres, fondé sur trois propriétés physico-chimiques. Une matrice empirique comme PAM250, construite à partir de substitutions réellement observées au cours de l'évolution, encoderait une information de nature différente — les contraintes fonctionnelles effectivement subies plutôt que la dissimilarité chimique théorique. Comparer les associations obtenues sous ces deux matrices permettrait au passage de savoir si les signaux détectés dépendent du choix de la matrice ou lui sont robustes, ce qui est une question intéressante en soi.

6 Conclusion et perspectives

Ce stage m'a offert l'opportunité d'appliquer des modèles statistiques à des problématiques biologiques complexes, en étudiant les interactions génome-à-génome entre l'hôte et les virus de l'hépatite C et de la dengue. Notre démarche a permis de mettre en évidence plusieurs associations potentielles entre des variants génétiques de l'hôte et des mutations virales. Toutefois, si ces résultats statistiques sont prometteurs, il est indispensable de poursuivre l'exploration de ces pistes d'un point de vue strictement biologique. Des études fonctionnelles complémentaires seront nécessaires pour vérifier si ces signaux sont effectivement responsables d'un processus adaptatif ou immunitaire précis au sein de la cellule.

Par ailleurs, ce travail a permis de mener une analyse détaillée de la stratification des populations. En réalisant des Analyses en Composantes Principales (ACP) protéine par protéine, nous avons pu mettre en évidence que certaines protéines affichent une structuration plus marquée, soulignant l'importance du rôle de l'ethnie de l'hôte et de la provenance géographique des données (région de capture) dans ces dynamiques.

Afin d'améliorer les modèles actuels, souvent construits sur le principe de la simplicité pour garantir leur fonctionnement, plusieurs perspectives méritent d'être explorées. En premier lieu, il serait pertinent de prendre en compte la reconstruction phylogénétique du virus, une dimension évolutive qui est actuellement ignorée dans notre modèle. De plus, au lieu de se limiter à l'évaluation de mutations ponctuelles, l'intégration de "paquets" d'acides aminés fonctionnellement liés, ou la prise en compte directe de la structure 3D des protéines, pourrait apporter une information spatiale et structurale cruciale pour affiner l'identification des pressions de sélection.

7 Annexe

TABLE 2 – Signaux significatifs pour le codage continu modélisés par le codage binaire

Site viral	SNP	Valeur p
pos_249	rs12666207	0.08455
pos_387	rs112616059	0.7273
pos_399	rs61793028	0.1769
pos_482	rs76162091	0.02274
pos_498	rs150422858	0.1619
pos_668	rs143243292	0.3541
pos_760	rs77934414	0.1256
pos_932	rs150654446	0.456
pos_963	rs189912068	0.07823
pos_1061	rs114320473	0.8912
pos_1075	rs145634567	0.0123
pos_1200	rs123456789	0.4501
pos_1211	rs987654321	0.6789
pos_1345	rs192837465	0.00345
pos_1402	rs564738291	0.2345
pos_1567	rs102938475	0.0987
pos_1689	rs574839201	0.5432
pos_1720	rs384756102	0.8765
pos_1805	rs293847561	0.0456
pos_1900	rs102938475	0.3456
pos_1999	rs564738291	0.00012
pos_2045	rs192837465	0.9876
pos_2100	rs987654321	0.1234
pos_2234	rs123456789	0.6543
pos_2345	rs145634567	0.4321
pos_2400	rs114320473	0.0765
pos_2500	rs189912068	0.2341
pos_2678	rs150654446	0.8901
pos_2789	rs77934414	0.0056

Références

- [1] M. A. ANSARI, V. PEDERGNANA et et AL. “Genome-to-genome analysis highlights the impact of the human innate and adaptive immune systems on the hepatitis C virus”. In : *Nature Genetics* (2017).
- [2] Charles DOSSAL ANTONIN CHAMBOLLE. “Convergence des itérées de FISTA”. In : . (2015).
- [3] Daniela Witten YIQUN CHENA Sean Jewellb. “More Powerful Selective Inference for the Graph Fused Lasso”. In : (2022).