



**UNIVERSITÉ DE
MONTPELLIER**



**STATISTIQUE
SCIENCE DES DONNÉES**
UNIVERSITÉ DE MONTPELLIER

MASTER II STATISTIQUES ET SCIENCES DES DONNÉES

Parcours Biostatistique

EXPLORATION DES INTERACTIONS GÉNOMIQUES HÔTE-PATHOGENE

Présenté par :
Damien MARIAC

Encadré par :
Vincent PEDERGNANA

Tuteur FdS :
Ludovic Menneteau

Jury :
Élodie BRUNEL-PICCININI
Xavier BRY
Benoite DE SAPORTA

Année universitaire 2025-2026



Table des matières

1	Environnement	3
1.1	L'unité d'accueil : l'UMR MIVEGEC	3
1.2	L'équipe d'accueil : PEV	3
1.3	Conditions matérielles et vie de l'unité	3
2	Contexte	5
2.1	Contexte du sujet	5
2.2	Contexte biologique	5
3	Préparation des données	7
3.1	Le séquençage viral	7
3.2	Alignements multiples de séquences	8
3.2.1	Alignement progressif par rapport à une séquence de référence	8
3.2.2	Matrices de substitution	8
3.2.3	Pénalités de gap	10
3.3	Traitement des valeurs manquantes	10
4	Modélisation statistique	11
4.1	Modèle d'association "classique"	11
4.2	Limites du modèle "classique"	11
4.3	Modèle avec dépendances : Graph Fused Lasso	12
4.3.1	Construction du graphe de corrélation	12
4.3.2	Choix des paramètres de régularisation	12
4.3.3	Optimisation du modèle : algorithme FISTA	13
4.3.4	Calculs du gradient	13
4.3.5	Limites de l'algorithme FISTA	15
4.4	Modèle avec effets aléatoires	15
4.4.1	Estimation — test du score de Rao	16
4.4.2	Estimation approchée de l'effet β_{ij}	17
4.4.3	Le facteur d'inflation génomique	19
5	Résultats et discussion	21
5.1	Les jeux de données	21
5.1.1	Hépatite C	21
5.1.2	Dengue	22
5.2	Choix du codage des sites viraux	23
5.3	Modèle linéaire généralisé à effets aléatoires	24
5.3.1	Mise en œuvre et seuil de significativité	24
5.3.2	Lecture des figures	24
5.3.3	Codage binaire appliqué au VHC	25
5.3.4	Codage binaire appliqué à la dengue	30
5.3.5	Codage continu appliqué au VHC	35
5.3.6	Codage continu appliqué à la dengue	39
5.4	Bilan des deux codages	40
6	Conclusion et perspectives	42

7	Annexe	43
7.1	Étapes de l'algorithme FISTA	43
7.2	ACP VHC par protéine	44
7.3	Recoupement des deux codages	45
7.4	Codes et commandes pour reproduire les analyses	46
7.5	Lexique des termes biologiques	47

1 Environnement

1.1 L'unité d'accueil : l'UMR MIVEGEC

J'ai effectué mon stage de Master 2 au sein de l'UMR MIVEGEC Maladies Infectieuses et Vecteurs : Écologie, Génétique, Évolution et Contrôle, à Montpellier. Créée en 2011, cette unité mixte de recherche est placée sous la tutelle de l'Institut de Recherche pour le Développement IRD, tutelle hébergeuse, du Centre National de la Recherche Scientifique CNRS et de l'Université de Montpellier, et est unité sous contrat de l'INRAE.

Les recherches de l'unité portent sur l'écologie et l'évolution des systèmes infectieux. Elles visent à comprendre les processus d'émergence, de réplication et de transmission des agents pathogènes, ainsi que les mécanismes d'adaptation réciproque au sein des complexes hôte-pathogène. L'unité couvre un continuum allant de la recherche fondamentale à la recherche de terrain et interventionnelle, et entretient des collaborations de longue date avec des partenaires situés en zone intertropicale, où les maladies étudiées sont endémiques.

MIVEGEC réunit environ 250 personnes réparties sur trois sites montpellierains, et est structurée en cinq départements scientifiques regroupant treize groupes de recherche. Elle pilote plusieurs plateformes, dont le Vectopôle-IRD, et contribue au plateau de bioinformatique iTrop, sur lequel l'ensemble des analyses présentées dans ce rapport a été réalisé.

1.2 L'équipe d'accueil : PEV

J'ai été intégré à l'équipe PEV Perturbations, Évolution, Virulence, codirigée par Mme Élodie Chapuis et M. Vincent Pederagnana. L'équipe cherche à identifier les facteurs qui déterminent la virulence des systèmes infectieux, en accordant une attention particulière à l'effet des perturbations intracellulaires, environnementales ou anthropiques sur les interactions hôte-parasite. Elle est organisée en deux groupes de taille comparable : ViroStyle, centré sur les interactions entre virus et hôtes, et PVPC (Perturbation Virulence in Populations Communities), consacré à l'effet des perturbations écologiques sur la dynamique des systèmes infectieux.

La particularité de l'équipe tient à la combinaison d'approches théoriques, expérimentales et statistiques : modélisation mathématique, génétique des populations, épidémiologie et analyse de données y sont mobilisées conjointement. C'est dans ce dernier volet que s'inscrit mon stage.

Ce positionnement explique le sujet qui m'a été confié. L'analyse conjointe des génomes de l'hôte et du pathogène, dite *genome-to-genome*, constitue en effet un axe de recherche établi de l'équipe : mon encadrant, M. Vincent Pederagnana, est copremier auteur de l'étude de référence en la matière chez le virus de l'hépatite C [1] (VHC), dont les résultats servent de point de comparaison tout au long de ce travail. Mon stage prolonge cette approche sur deux plans : l'introduction d'un codage continu des sites viraux, et son extension à un second modèle viral, le virus de la dengue (DENV).

1.3 Conditions matérielles et vie de l'unité

L'équipe est répartie sur deux bâtiments distincts, tous deux situés sur le campus Agropolis, dans le quartier de Lavalette, en bordure du Lez. J'ai pour ma part été accueilli dans le bâtiment Païre, distinct du bâtiment principal de la délégation régionale de l'IRD qui héberge la majorité des personnels de l'unité. Les calculs ont été menés à distance sur le cluster iTrop, ce qui rendait cette dispersion géographique peu contraignante au quotidien.

L'équipe PEV se réunit toutes les deux semaines, le lundi matin. Ces réunions permettaient de faire le point sur l'avancement des projets en cours et donnaient lieu à des présentations de la part des chercheurs. Elles ont constitué pour moi une occasion régulière d'apprentissage de la méthodologie en biologie, mais aussi de découvrir des objets et des approches très éloignés de mon sujet, ce qui donne une image plus juste de la diversité du travail mené dans une unité de recherche.

Mon stage s'est par ailleurs déroulé dans un contexte institutionnel particulier. L'unité prépare sa restructuration pour le prochain mandat : elle changera de nom pour devenir BioSEE, se réorganisera autour d'un nombre réduit d'équipes et abandonnera le découpage actuel en départements scientifiques. L'équipe PEV, quant à elle, fusionnera ses deux groupes en une entité unique.

J'ai eu l'occasion d'assister à l'assemblée générale consacrée à cette transition, où étaient présentés aussi bien des travaux scientifiques que des questions d'organisation et de gouvernance. Ces séances m'ont donné un aperçu d'une dimension du métier de chercheur peu visible depuis les enseignements de master : le fonctionnement collectif d'une unité, la manière dont s'y négocient les orientations scientifiques, et le temps que ces arbitrages représentent dans l'activité quotidienne d'un laboratoire.

2 Contexte

2.1 Contexte du sujet

La sévérité d'une infection virale varie fortement d'un individu à l'autre. Cette variabilité est en partie due à la diversité génétique de l'hôte et du virus. Parmi les facteurs qui l'influencent, nous nous intéressons plus particulièrement à la diversité génétique de l'hôte et du virus. L'objectif est d'identifier les variants génétiques de l'hôte qui influencent l'évolution du génome viral. Le virus est soumis à la pression de sélection exercée par le système immunitaire de l'hôte, et le génome de l'hôte cherche à éliminer le virus de l'organisme.

L'objectif de ce stage est de proposer de nouveaux modèles permettant de faciliter l'étude d'associations entre les variants génétiques de l'hôte et les mutations virales, afin de mieux comprendre les mécanismes des réponses immunitaires de l'hôte humain.

Historiquement, les études d'association en génome entier sont menées sur les symptômes provoqués par l'infection. Mais ceux-ci sont souvent largement influencés par des facteurs non génétiques tels que l'environnement, l'alimentation ou les habitudes physiques.

Pour pallier ce problème, il existe depuis quelques années une variante de cette approche. On cherche à identifier les variants génétiques de l'hôte qui influencent l'évolution du génome viral. Cette approche est appelée *Genome-to-Genome* (GxG). L'idée est que les mutations virales sont le reflet de la pression de sélection exercée par le système immunitaire de l'hôte. Ainsi, en identifiant les variants génétiques de l'hôte associés à certaines mutations virales, on peut obtenir des informations sur les mécanismes immunitaires impliqués dans la réponse à l'infection.

Ce qui fait toute la difficulté de cette approche est la haute dimensionnalité des données. En effet, on a du côté des hôtes des centaines de milliers de variants génétiques et du côté des virus des centaines de mutations après avoir filtré les sites présentant un certain taux de variabilité. De plus, les individus issus de régions géographiques et d'ethnies différentes présentent des différences génétiques, ce qui biaise les résultats d'association. Il est aussi possible que certains virus soient issus d'une même souche et partagent des mutations communes dues à leur histoire évolutive, sans pour autant refléter une pression de sélection. Il est donc nécessaire de prendre en compte la structure de population des hôtes et du virus.

Afin de mieux comprendre les mécanismes à l'origine de cette diversité génétique, il est nécessaire de rappeler brièvement le cycle de vie d'un virus et son interaction avec le système immunitaire.

2.2 Contexte biologique

Le virus est une entité biologique qui ne peut pas se reproduire par elle-même. Il a besoin d'un hôte pour se multiplier et se propager. Il est constitué d'une coque qui protège son matériel génétique, qui peut être de l'ADN ou de l'ARN. La nature du support de l'information, ADN ou ARN, dicte la réplication, ce qui a un impact majeur sur sa diversité génétique. De ce fait, les virus à ARN ont un taux de mutation beaucoup plus élevé que les virus à ADN. Cette forte variabilité est fondamentale : elle permet au virus de s'adapter très rapidement pour trouver des solutions face aux défenses de l'hôte.

Dans le cadre de ce stage, nous avons travaillé sur le virus de l'hépatite C (VHC), pour le-

quel des liaisons ont déjà été identifiées, afin de pouvoir étendre ensuite l'approche au virus de la dengue. Ce sont tous deux des virus à ARN qui présentent une grande diversité génétique.

La multiplication du virus dépend entièrement de la machinerie cellulaire de l'hôte. L'infection débute lorsqu'un virus reconnaît un récepteur spécifique à la surface d'une cellule. Après son entrée dans celle-ci, son génome est libéré dans le cytoplasme où il est répliqué grâce aux enzymes virales ou cellulaires. Les ARN messagers viraux sont ensuite traduits par les ribosomes de la cellule afin de produire les protéines virales nécessaires au cycle infectieux.




FIGURE 1 – Cycle de vie d'un virus à ARN.

Lors de cette infection, le système immunitaire met en place plusieurs mécanismes de défense. Il produit par exemple des interférons, molécules chargées de limiter la réplication du virus. Il développe aussi une immunité adaptative, en entraînant certains lymphocytes à reconnaître les virus et à les détruire.

La réponse immunitaire exerce une forte pression de sélection sur le virus. Cela signifie que toute mutation permettant de diminuer la reconnaissance d'une protéine virale par le système immunitaire peut conférer un avantage évolutif. Au fil des cycles de réplication, ces mutations peuvent être sélectionnées et devenir majoritaires au sein de la population virale présente chez un individu.

L'objectif de ce stage est donc de construire des modèles statistiques adaptés à ce type de problématique, de les valider sur un jeu de données pour lequel des liaisons entre les variants génétiques de l'hôte et les mutations virales ont déjà été identifiées, puis d'étendre cette approche à un second virus à ARN en incorporant davantage d'informations afin de capturer plus de signal. Il s'agit enfin d'appliquer une méthodologie permettant de discuter de la calibration des modèles et de la robustesse des résultats obtenus.

Dans le cadre de ce stage, nous nous sommes intéressés à deux virus à ARN : le virus de l'hépatite C (VHC) et le virus de la dengue (DENV). Tous deux présentent une importante diversité génétique, conséquence directe de leur fort taux de mutation.

3 Préparation des données

Cette partie détaille les étapes de collecte, d'alignement des séquences virales et de gestion des données manquantes réalisées avant toute modélisation statistique.

Les données utilisées dans ce type d'étude nécessitent l'acquisition simultanée d'informations génétiques sur le pathogène et sur son hôte. Les échantillons biologiques consistent généralement en des prélèvements sanguins effectués chez les patients infectés. Pour le génome viral, l'ARN du VHC est extrait à partir du plasma sanguin des patients. Ce matériel est ensuite amplifié puis séquencé, ce qui permet de capturer l'ensemble des variants présents chez un individu et d'en dégager une séquence consensus par patient.

3.1 Le séquençage viral

Pour analyser le génome du virus présent chez un patient, il est important de comprendre comment les données génétiques sont techniquement lues par les machines (les séquenceurs).

Contrairement à ce que l'on pourrait penser, un séquenceur ne lit pas le génome du virus d'une seule traite, de la première à la dernière « lettre » (nucléotide). Les technologies modernes de séquençage à haut débit procèdent différemment : elles découpent l'ARN viral en des millions de petits fragments de 140 nucléotides, appelés des *reads*. La machine va ensuite lire ces petits fragments de manière individuelle et désordonnée. Pour se représenter ce processus, on peut imaginer un livre (le génome viral) qui serait passé dans une déchiqueteuse à papier. On se retrouve avec des milliers de petites bandes de papier contenant chacune quelques mots. Pour reconstituer l'histoire, un algorithme informatique va comparer ces bandes, chercher les mots qui se chevauchent, et les aligner les unes par rapport aux autres, souvent en s'aidant d'un « texte de référence » connu (comme la séquence externe H77 pour le VHC).

Puisque nous avons généré des millions de petits fragments à partir de milliers de copies du virus présentes dans le sang du patient, un « mot » spécifique du livre ne sera pas lu une seule fois, mais des dizaines, voire des centaines de fois.




FIGURE 2 – Représentation schématique de l'alignement des lectures (*reads*) sur une séquence de référence.

Lorsqu'on observe un site précis du génome (par exemple, la position 1450), on constate que de nombreux petits fragments se superposent à cet endroit. Le nombre total de fragments qui couvrent une position donnée définit sa profondeur.

La profondeur est une information cruciale puisqu'elle permet la correction des erreurs. Les séquenceurs font parfois des erreurs de lecture. Si un seul fragment indique une mutation à une position, il peut s'agir d'un artefact technique. En revanche, si la profondeur est de 100 et que 99 fragments indiquent cette même mutation, nous avons la certitude statistique qu'elle est réelle.

Ainsi, l'alignement de cette multitude de petits fragments n'est pas un défaut technique, mais une nécessité qui donne tout son relief et sa fiabilité à l'analyse génétique du virus.

3.2 Alignements multiples de séquences

L'alignement multiple de séquences (MSA) consiste à disposer simultanément plusieurs séquences biologiques (nucléotidiques ou protéiques) de manière à faire correspondre les positions homologues, c'est-à-dire dérivées d'un ancêtre commun au cours de l'évolution. Contrairement à l'alignement par paires (deux séquences), l'alignement multiple permet d'identifier des régions conservées, des motifs fonctionnels ou structuraux communs à un ensemble de séquences, et sert de base à des analyses phylogénétiques. L'idée est en effet de pouvoir considérer les positions du virus comme des variables.

Il s'agit d'un problème de haute complexité algorithmique : trouver l'alignement optimal exact de N séquences a une complexité qui croît exponentiellement avec le nombre de séquences, de l'ordre de $O(L^N)$ pour N séquences de longueur L . Pour cette raison, des méthodes heuristiques sont généralement utilisées en pratique.

3.2.1 Alignement progressif par rapport à une séquence de référence

Dans notre cas, nous avons réalisé un alignement progressif basé sur une séquence de référence.

Cette approche consiste dans un premier temps à choisir une séquence de référence (souvent la plus longue, la plus représentative, une séquence d'intérêt particulier ou consensus, ou une séquence de référence dans les bases de données publiques).

Elle consiste ensuite à aligner successivement chaque autre séquence du jeu de données contre cette référence, par alignement deux à deux.

Elle consiste enfin à fusionner progressivement ces alignements par paires en un alignement multiple global, en insérant des gaps (-) aux positions nécessaires pour maintenir la cohérence des colonnes entre toutes les séquences.

Cette stratégie est une simplification efficace par rapport aux méthodes progressives classiques (type ClustalW) qui construisent d'abord un arbre guide (*guide tree*) à partir des similarités deux à deux, puis alignent les séquences en suivant cet arbre. L'approche par référence unique est plus rapide, mais suppose que la séquence de référence est suffisamment représentative pour bien guider l'alignement de l'ensemble des autres séquences.

3.2.2 Matrices de substitution

L'alignement de deux séquences repose sur un système de score permettant de quantifier la ressemblance entre deux acides aminés dans une colonne de l'alignement. Comme les vingt acides aminés ne sont en effet pas interchangeables de manière équivalente, on ne peut pas se contenter d'un simple score binaire.

Certaines substitutions sont dites *conservatives* : elles remplacent un acide aminé par un autre présentant des propriétés physico-chimiques voisines. De telles substitutions altèrent en général peu la structure et la fonction de la protéine, et sont donc fréquemment observées entre séquences homologues. À l'inverse, les substitutions dites *radicales* remplacent un résidu par un autre aux propriétés très différentes, et sont bien plus rarement tolérées par la sélection naturelle.

Une matrice de substitution est donc une matrice carrée S de dimension 20×20 , symétrique, dont le coefficient $s(a, b)$ représente le score attribué à l'alignement de l'acide aminé a avec l'acide aminé b . Ce score est d'autant plus élevé que la substitution est jugée plausible ou peu coûteuse, et d'autant plus faible (voire négatif) qu'elle est jugée improbable. Les termes diagonaux $s(a, a)$, correspondant à la conservation d'un résidu, sont naturellement les plus favorables.

On distingue classiquement deux grandes familles de matrices :

- Les matrices empiriques, construites à partir de l'observation des substitutions réellement constatées dans de grands jeux d'alignements de protéines homologues. C'est le cas des matrices PAM (*Point Accepted Mutation*, Dayhoff *et al.*, 1978) et BLOSUM (*BLOcks SUBstitution Matrix*, Henikoff & Henikoff, 1992). Leurs coefficients sont des rapports de vraisemblance logarithmiques (*log-odds*) de la forme

$$s(a, b) = \frac{1}{\lambda} \log \frac{q_{ab}}{p_a p_b},$$

où q_{ab} est la fréquence d'observation du couple (a, b) dans des alignements de référence, p_a et p_b les fréquences d'apparition de chaque acide aminé, et λ un facteur d'échelle. Un score positif traduit ainsi une substitution plus fréquente que ce que prédirait le hasard.

- Les matrices physico-chimiques, qui ne reposent pas sur des données évolutives mais sur la comparaison objective des propriétés chimiques des chaînes latérales des acides aminés. Elles définissent une *distance* entre acides aminés, et non directement un score de similarité. Les matrices de Grantham (1974), de Miyata (1979) ou de Sneath (1966) appartiennent à cette catégorie.

Le choix de la matrice n'est pas neutre : il conditionne directement l'alignement obtenu, et donc l'ensemble des analyses qui en découlent.

Plus tard dans ce travail, on utilisera un nouveau codage basé sur la matrice de Grantham (1974). Son principe est de quantifier la *dissimilarité chimique* entre deux acides aminés à partir de trois propriétés de leur chaîne latérale, jugées déterminantes pour le comportement du résidu au sein de la protéine : la composition, la polarité et le volume moléculaire. Cela permet d'indiquer à quel point une substitution est radicale ou conservatrice, indépendamment de toute observation évolutive. Les transitions d'un acide aminé à un autre sont ainsi pondérées en fonction de la différence de leurs propriétés physico-chimiques, et non plus considérées comme des événements binaires. Le choix de cette matrice plutôt qu'une autre tient à la simplicité de son interprétation.

Les valeurs obtenues s'échelonnent ainsi de 5, pour le couple leucine/isoleucine (substitution quasiment neutre sur le plan chimique), à 215 pour le couple cystéine/tryptophane, qui constitue la substitution la plus radicale au sens de ce critère.

L'intérêt de cette matrice est qu'elle repose sur des grandeurs physico-chimiques mesurables et indépendantes de tout jeu de données évolutif : elle n'introduit donc pas de biais lié à la composition des bases de données ayant servi à construire les matrices empiriques, et ne présuppose

/	Ser	Arg	Leu	Pro	Thr	Ala	Val	Gly	Ile	Phe	Tyr	Cys	His	Gln	Asn	Lys	Asp	Glu	Met	Trp
Ser	0	110	145	74	58	99	124	56	142	155	144	112	89	68	46	121	65	80	135	177
Arg	110	0	102	103	71	112	96	125	97	97	77	180	29	43	86	26	96	54	91	101
Leu	145	102	0	98	92	96	32	138	5	22	36	198	99	113	153	107	172	138	15	61
Pro	74	103	98	0	38	27	68	42	95	114	110	169	77	76	91	103	108	93	87	147
Thr	58	71	92	38	0	58	69	59	89	103	92	149	47	42	65	78	85	65	81	128
Ala	99	112	96	27	58	0	64	60	94	113	112	195	86	91	111	106	126	107	84	148
Val	124	96	32	68	69	64	0	109	29	50	55	192	84	96	133	97	152	121	21	88
Gly	56	125	138	42	59	60	109	0	135	153	147	159	98	87	80	127	94	98	127	184
Ile	142	97	5	95	89	94	29	135	0	21	33	198	94	109	149	102	168	134	10	61
Phe	155	97	22	114	103	113	50	153	21	0	22	205	100	116	158	102	177	140	28	40
Tyr	144	77	36	110	92	112	55	147	33	22	0	194	83	99	143	85	160	122	36	37
Cys	112	180	198	169	149	195	192	159	198	205	194	0	174	154	139	202	154	170	196	215
His	89	29	99	77	47	86	84	98	94	100	83	174	0	24	68	32	81	40	87	115
Gln	68	43	113	76	42	91	96	87	109	116	99	154	24	0	46	53	61	29	101	130
Asn	46	86	153	91	65	111	133	80	149	158	143	139	68	46	0	94	23	42	142	174
Lys	121	26	107	103	78	106	97	127	102	102	85	202	32	53	94	0	101	56	95	110
Asp	65	96	172	108	85	126	152	94	168	177	160	154	81	61	23	101	0	45	160	181
Glu	80	54	138	93	65	107	121	98	134	140	122	170	40	29	42	56	45	0	126	152
Met	135	91	15	87	81	84	21	127	10	28	36	196	87	101	142	95	160	126	0	67
Trp	177	101	61	147	128	148	88	184	61	40	37	215	115	130	174	110	181	152	67	0

FIGURE 3 – Matrice de distance de Grantham (1974)

aucune distance évolutive particulière entre les séquences comparées (là où le choix d’une matrice PAM ou BLOSUM suppose implicitement un degré de divergence donné). En contrepartie, elle ignore la réalité observée des substitutions acceptées au cours de l’évolution, et notamment les contraintes fonctionnelles propres à certains sites.

3.2.3 Pénalités de gap

Enfin, l’algorithme d’alignement utilisé (de type Needleman-Wunsch, pour un alignement global) intègre une pénalité d’ouverture de gap (un trou dans la séquence) ainsi qu’une éventuelle pénalité d’extension de gap (une suite de trous), afin d’éviter la multiplication de petites insertions/délétions dispersées et de favoriser des gaps regroupés, biologiquement plus plausibles (une seule insertion/délétion plutôt que plusieurs événements ponctuels indépendants).

3.3 Traitement des valeurs manquantes

La présence de valeurs manquantes est inhérente aux limites techniques du séquençage et du génotypage, notamment aux erreurs de lecture. Dans le cadre des modèles mixtes (GLMM) utilisés pour les tests d’association (voir plus bas), ces données manquantes bloquent les calculs d’algèbre linéaire, comme l’inversion des matrices de parenté. Le traitement appliqué dépend donc du type de codage retenu pour le jeu de données.

Afin de rester cohérent avec un codage initialement binaire, les valeurs manquantes ont été imputées par la modalité la plus fréquente. Ce choix évite d’obtenir des valeurs différentes de 0 ou 1, ce qui aurait pu compromettre les modèles logistiques, tout en conservant une puissance statistique suffisante lors du recodage par transition d’acide aminé (voir section suivante). Cette approche permet enfin de disposer d’un support commun pour comparer les différentes méthodes entre elles.

4 Modélisation statistique

Dans cette approche *Genome-to-Genome* (GxG), le but est d’identifier des variants génétiques de l’hôte qui influencent l’évolution du génome viral. Cette problématique relève naturellement d’un modèle supervisé : les caractéristiques génétiques de l’hôte constituent les variables explicatives, tandis que les mutations observées chez le virus représentent les variables à expliquer. Contrairement à une approche non supervisée, qui se limite à décrire les structures présentes dans les données, un modèle supervisé permet de mettre en évidence des associations statistiques entre les deux génomes tout en tenant compte d’éventuels facteurs de confusion, tels que la stratification des populations hôte et virale ou des caractéristiques propres à l’individu.

4.1 Modèle d’association “classique”

Le modèle proposé par [1] vise à modéliser la probabilité d’une mutation virale en fonction d’un variant génétique de l’hôte appelé SNP (*single nucleotide polymorphism*), tout en ajoutant des covariables telles que l’âge et le sexe. Pour une position génomique virale (nous utiliserons site viral dans le reste du rapport) et un SNP donnés, une régression logistique est ajustée indépendamment, et ce pour l’ensemble des paires SNP–site viral. Afin de corriger la structure de population, les auteurs incluent les composantes principales (CP) de l’hôte et du virus comme effets fixes. En effet, les premières CP de l’hôte capturent l’origine ethnique des individus [8], et les premières CP du virus capturent l’origine géographique des souches.

Les auteurs retiennent les 10 premières CP de l’hôte et les 5 premières du virus. Ce choix reste discutable : ces composantes ne capturent respectivement qu’une faible part et 12 % de la variance cumulée, ce qui suggère qu’une part importante de la structure de population n’est pas corrigée.

Le modèle s’écrit finalement, pour un site de l’hôte SNP_j et un site viral Y_i fixés :

$$\text{logit}(P(Y_i = 1)) = \beta_0 + \beta_{ij} SNP_j + \sum_{k=1}^{10} \gamma_k PC_k^{\text{hôte}} + \sum_{l=1}^5 \delta_l PC_l^{\text{virus}}$$

Une p-value est extraite pour chaque test SNP–site viral. Les tests étant menés indépendamment sur un très grand nombre de paires, une correction pour tests multiples est nécessaire afin de limiter les faux positifs : les auteurs utilisent une correction de Bonferroni, avec un seuil de significativité $\alpha = 10^{-11}$. Ce seuil étant très strict, il est trop conservateur et risque d’écraser un signal réel. C’est pourquoi un seuil de significativité moins strict est utilisé, à savoir $\alpha = 10^{-8}$.

4.2 Limites du modèle “classique”

Ce modèle présente plusieurs limites, qui motivent le développement d’une approche plus adaptée à ce type de données.

D’abord, il ne capture qu’une fraction de la structure de population : se limiter à quelques composantes principales, en plus d’ignorer une part importante de la variance, ne permet pas de représenter assez précisément la dépendance génétique entre individus (côté hôte) ou entre souches (côté virus).

Ensuite, il ignore la corrélation entre sites : les mutations virales peuvent être corrélées entre elles du fait de leur proximité structurale (conformation 3D de la protéine), et les SNPs de l’hôte proches sur le génome sont corrélés par déséquilibre de liaison. Ne pas modéliser ces dépendances

revient à traiter chaque test comme indépendant alors qu'il ne l'est pas, ce qui biaise l'estimation de la significativité.

De plus, la correction de Bonferroni, en supposant l'indépendance des tests, est très conservatrice dans ce contexte de forte corrélation : elle risque d'écraser un signal réel, en particulier étant donné la très haute dimensionnalité des données (des millions de tests SNP–site viral).

4.3 Modèle avec dépendances : Graph Fused Lasso

Un modèle de type Graph Fused Lasso (GFL) [5] permettrait de pallier le problème de la corrélation entre sites. Celui-ci reprend le modèle logistique précédent, mais ajoute deux pénalisations sur les coefficients β_{ij} : une pénalité de type Lasso, qui contraint les coefficients à être nuls si le SNP j n'est pas suffisamment associé au site viral i , et une pénalité de fusion sur graphe, qui contraint les coefficients à être similaires lorsque les sites viraux i et i' sont corrélés.

Le modèle s'écrit alors, pour un SNP j fixé :

$$\hat{\beta}_{\cdot j} = \underset{\beta_{\cdot j}}{\operatorname{argmin}} \left\{ - \sum_{i=1}^q \ell_i(\beta_{ij}) + \lambda_1 \sum_{i=1}^q |\beta_{ij}| + \lambda_2 \sum_{(i,i') \in E} w_{ii'} |\beta_{ij} - \beta_{i'j}| \right\}$$

où $\ell_i(\beta_{ij})$ est la log-vraisemblance logistique associée au site viral i , E l'ensemble des arêtes du graphe de corrélation entre sites viraux, $w_{ii'}$ le poids de l'arête reliant les sites i et i' , et λ_1 , λ_2 les paramètres de régularisation contrôlant respectivement la sparsité et l'homogénéité locale des coefficients sur le graphe.

4.3.1 Construction du graphe de corrélation

Afin d'implémenter ce modèle, il est nécessaire de construire un graphe représentant les corrélations entre sites viraux.

Pour éviter d'avoir un biais, on calcule la corrélation sur un autre jeu de données du VHC du même sérotype. Ces données proviennent de la banque de données du NCBI. Elles ont été alignées par rapport à la séquence consensus de nos données afin de pouvoir faire correspondre les bonnes positions. Puis nous avons calculé la corrélation entre les sites après les avoir recodés en variables binaires sous forme de mutation/conservation. C'est avec 5000 séquences que nous obtenons la matrice de corrélation.

Les sites viraux étant binaires, ils sont supposés suivre une loi de Bernoulli, ce qui permet d'estimer leur corrélation de façon paramétrique. Pour deux sites viraux i et i' , de probabilités marginales p_i et $p_{i'}$ et de probabilité jointe $p_{ii'} = P(Y_i = 1, Y_{i'} = 1)$, la corrélation s'écrit :

$$w_{ii'} = \operatorname{corr}(Y_i, Y_{i'}) = \frac{p_{ii'} - p_i p_{i'}}{\sqrt{p_i(1 - p_i) p_{i'}(1 - p_{i'})}}$$

La matrice de corrélation ainsi obtenue sert de support au graphe : une arête est créée entre deux sites viraux lorsque leur corrélation en valeur absolue dépasse un seuil fixé arbitrairement à 0.7. La figure 4 représente cette matrice sous forme de heatmap, où les valeurs proches de 1 sont en rouge et celles proches de 0 en jaune.

On remarque que le graphe obtenu est très creux, mais que la matrice présente des blocs de corrélations élevées, correspondant à des sites viraux fortement liés entre eux.

4.3.2 Choix des paramètres de régularisation

Il reste à définir les paramètres de régularisation λ_1 et λ_2 . Une validation croisée sur l'ensemble des données étant impossible à mettre en œuvre dans ce contexte de très haute dimen-




FIGURE 4 – Matrice de corrélation entre sites viraux sous forme de heatmap.

sionnalité, elle a été réalisée sur plusieurs sous-ensembles de données, et les résultats ont ensuite été moyennés pour obtenir les paramètres optimaux. On obtient ainsi $\lambda_1 = 0.35$ et $\lambda_2 = 0.7$.

4.3.3 Optimisation du modèle : algorithme FISTA

L'estimation des coefficients du modèle revient à minimiser la fonction objectif présentée précédemment, qui se décompose en une partie lisse et une partie non lisse :

$$F(\beta) = \underbrace{f(\beta)}_{\text{log-vraisemblance}} + \underbrace{g(\beta)}_{\text{pénalités}}, \quad \text{où } g(\beta) = \lambda_1 \sum_{i=1}^q |\beta_{ij}| + \lambda_2 \sum_{(i,i') \in E} w_{ii'} |\beta_{ij} - \beta_{i'j}|$$

où f est convexe et différentiable, mais où g est convexe et non différentiable en raison des valeurs absolues. Cette fonction ne possède pas de solution analytique et doit donc être minimisée numériquement.

Pour cela, nous utilisons l'algorithme FISTA (Fast Iterative Shrinkage-Thresholding Algorithm) [4], particulièrement adapté aux problèmes de la forme $\min_{\beta} f(\beta) + g(\beta)$ lorsque f est différentiable à gradient L -Lipschitzien et g admet un opérateur proximal calculable. C'est la méthode principalement utilisée dans les packages R qui implémentent les modèles de type Lasso. Les trois étapes de l'algorithme sont détaillées en annexe.

4.3.4 Calculs du gradient

L'étape de descente de FISTA nécessite le gradient de la partie lisse f de la fonction objectif. Notons :

- n le nombre d'individus, p le nombre de SNPs hôtes et q le nombre de sites viraux ;
- $\mathbf{X} \in \{0, 1, 2\}^{n \times p}$ la matrice des génotypes hôtes, de terme général x_{ki} (dosage allélique du SNP i chez l'individu k), dont les colonnes sont centrées et réduites au préalable afin que la pénalisation s'applique de façon homogène ;

- $\mathbf{Y} \in \{0, 1\}^{n \times q}$ la matrice des sites viraux, de terme général Y_{kj} (présence de la mutation j chez l'individu k);
- $\mathbf{B} = (\beta_{ij}) \in \mathbb{R}^{p \times q}$ la matrice des coefficients à estimer, et β_{0j} l'intercept associé au site viral j .

Le prédicteur linéaire et la probabilité prédite pour l'individu k au site viral j s'écrivent

$$\eta_{kj} = \beta_{0j} + \sum_{i=1}^p x_{ki} \beta_{ij}, \quad \pi_{kj} = \text{logit}^{-1}(\eta_{kj}) = \frac{e^{\eta_{kj}}}{1 + e^{\eta_{kj}}}.$$

Log-vraisemblance. Les individus étant supposés indépendants conditionnellement à leur génotype, la log-vraisemblance du modèle logistique s'écrit

$$\ell(\mathbf{B}) = \sum_{j=1}^q \sum_{k=1}^n \left\{ Y_{kj} \log \pi_{kj} + (1 - Y_{kj}) \log(1 - \pi_{kj}) \right\} = \sum_{j=1}^q \sum_{k=1}^n \left\{ Y_{kj} \eta_{kj} - \log(1 + e^{\eta_{kj}}) \right\},$$

la seconde égalité s'obtenant en remarquant que $\log \pi_{kj} - \log(1 - \pi_{kj}) = \eta_{kj}$ et $\log(1 - \pi_{kj}) = -\log(1 + e^{\eta_{kj}})$. La partie lisse de la fonction objectif est la log-vraisemblance négative, normalisée par n afin de rendre le choix de λ_1 et λ_2 indépendant de la taille de l'échantillon :

$$f(\mathbf{B}) = -\frac{1}{n} \ell(\mathbf{B}) = \frac{1}{n} \sum_{j=1}^q \sum_{k=1}^n \left\{ \log(1 + e^{\eta_{kj}}) - Y_{kj} \eta_{kj} \right\}.$$

On notera que f est *séparable* en les colonnes de $\mathbf{B}$: seule la pénalité de fusion, portée par le graphe des sites viraux, couple les différents sites entre eux. Le calcul du gradient peut donc être mené site par site, le couplage étant entièrement reporté sur l'opérateur proximal.

Dérivées partielles. Comme $\partial \eta_{kj} / \partial \beta_{ij} = x_{ki}$ et

$$\frac{\partial}{\partial \beta_{ij}} \log(1 + e^{\eta_{kj}}) = \frac{e^{\eta_{kj}}}{1 + e^{\eta_{kj}}} x_{ki} = \pi_{kj} x_{ki},$$

on obtient, pour tout SNP $i \in \{1, \dots, p\}$ et tout site viral $j \in \{1, \dots, q\}$,

$$\frac{\partial f}{\partial \beta_{ij}} = \frac{1}{n} \sum_{k=1}^n x_{ki} (\pi_{kj} - Y_{kj}), \quad \text{et} \quad \frac{\partial f}{\partial \beta_{0j}} = \frac{1}{n} \sum_{k=1}^n (\pi_{kj} - Y_{kj}).$$

Le gradient s'interprète comme la covariance empirique entre le génotype au SNP i et le résidu $\pi_{kj} - Y_{kj}$: un SNP dont la distribution suit les erreurs de prédiction du site viral j verra son coefficient d'autant plus déplacé lors du pas de gradient.

Écriture matricielle. En notant $\mathbf{\Pi}(\mathbf{B}) = (\pi_{kj})_{k,j} \in [0, 1]^{n \times q}$ la matrice des probabilités prédites, les expressions précédentes se résument à

$$\nabla f(\mathbf{B}) = \frac{1}{n} \mathbf{X}^\top (\mathbf{\Pi}(\mathbf{B}) - \mathbf{Y}) \in \mathbb{R}^{p \times q},$$

ce qui correspond à la forme utilisée à l'étape de descente de FISTA, le gradient y étant évalué au point extrapolé plutôt qu'en l'itéré courant. Son évaluation ne requiert que deux produits matriciels, soit un coût en $\mathcal{O}(npq)$ par itération, qui peut être fortement réduit en exploitant le caractère creux de $\mathbf{X}$ et de $\mathbf{B}$ au fil des itérations.

Constante de Lipschitz. En dérivant une seconde fois et en utilisant $\partial\pi_{kj}/\partial\eta_{kj} = \pi_{kj}(1 - \pi_{kj})$, la hessienne de f est bloc-diagonale, chaque bloc correspondant à un site viral :

$$\nabla_{\beta_{\cdot j}}^2 f(\mathbf{B}) = \frac{1}{n} \mathbf{X}^\top \mathbf{W}_j \mathbf{X}, \quad \mathbf{W}_j = \text{diag}(\pi_{kj}(1 - \pi_{kj}))_{k=1, \dots, n}.$$

Comme $\pi(1 - \pi) \leq 1/4$ pour tout $\pi \in [0, 1]$, on a $\nabla^2 f \preceq \frac{1}{4n} \mathbf{X}^\top \mathbf{X}$ uniformément en $\mathbf{B}$, ce qui garantit que ∇f est L -lipschitzien avec

$$L = \frac{1}{4n} \lambda_{\max}(\mathbf{X}^\top \mathbf{X}) = \frac{1}{4n} \sigma_{\max}(\mathbf{X})^2,$$

constante commune à tous les sites viraux. En très grande dimension, cette valeur propre n'est pas calculée explicitement mais approchée par la méthode de la puissance itérée ; à défaut, la majoration $\lambda_{\max}(\mathbf{X}^\top \mathbf{X}) \leq \|\mathbf{X}\|_F^2$ fournit un pas admissible, plus conservateur mais immédiat. Enfin, le gradient ne porte que sur f : les deux pénalités, non différentiables, sont entièrement prises en charge par l'opérateur proximal.

4.3.5 Limites de l'algorithme FISTA

Cependant, dans le contexte de très haute dimensionnalité des données, l'algorithme FISTA nécessite un temps de calcul très long pour converger.

En effet, après avoir testé sur un sous-ensemble de données afin de pouvoir estimer le temps d'implémentation sur l'ensemble des données, on a pu constater un temps de calcul de plusieurs mois pour l'ensemble du jeu de données.

De plus, le modèle GFL utilise une pénalité de type Lasso pour biaiser le calcul des coefficients et ne produit pas de p-values interprétables, ce qui est un manque important dans ce type d'étude.

Ainsi, dans le cadre du stage, il n'y a pas eu de possibilité de tester l'algorithme FISTA sur l'ensemble des données, et nous n'avons pas pu obtenir de résultats. Il est néanmoins possible de tester l'algorithme sur un sous-ensemble de données, mais les résultats obtenus ne sont pas représentatifs de l'ensemble des données. Cette approche a donc été laissée de côté pour se concentrer sur une approche plus adaptée à l'ensemble des données et au temps de ce stage de Master 2.

4.4 Modèle avec effets aléatoires

Le modèle GFL présenté précédemment permet de prendre en compte la corrélation locale entre sites, mais uniquement via un graphe construit. Il ne modélise pas la structure globale de parenté génétique au sein des populations hôte et virale, pourtant décrite comme un facteur de confusion majeur dans les études d'interaction génome-à-génome [7]. Une approche alternative, largement utilisée dans les études d'association (GWAS) classiques, consiste à modéliser cette structure via des effets aléatoires, plutôt que par un nombre limité de composantes principales ou un graphe de corrélation. Cette stratégie a notamment été adaptée dans un contexte similaire par [11] au travers de la méthode ATOMM (*Adaptive Two-way Mixed Model*), qui introduit un effet aléatoire distinct pour l'hôte et pour le virus.

En conservant autant que possible les notations du modèle précédent et en reprenant cette idée, le modèle logistique s'écrit alors comme un modèle mixte linéaire généralisé (GLMM) à deux effets aléatoires :

$$\text{logit}(P(Y_i = 1)) = \beta_0 + W\alpha + X_j\beta_{ij} + \eta_v + \eta_h$$

où $W\alpha$ regroupe les effets fixes (covariables telles que l'âge ou le sexe), $X_j\beta_{ij}$ représente l'effet du SNP j sur le site viral i , et les deux effets aléatoires

$$\eta_v \sim \mathcal{N}(0, \sigma_v^2 K_v), \quad \eta_h \sim \mathcal{N}(0, \sigma_h^2 K_h)$$

capturent respectivement la structure de parenté du virus et de l'hôte, via les matrices de parenté K_v et K_h .

Contrairement aux composantes principales, ces matrices résument l'intégralité de la similarité génétique entre individus (ou souches), sans perte d'information liée à un nombre de dimensions fixé en amont.

Les deux matrices de parenté K_v et K_h , appelées GRM, sont calculées à partir des données de génotypage de l'hôte et du virus, respectivement, après centrage-réduction des colonnes. Elles sont définies comme suit :

$$K_v = \frac{1}{q} Y Y^t, \quad K_h = \frac{1}{p} X X^t$$

Pour être plus rigoureux, on enlève les sites qui interviennent en tant que variable réponse et variable explicative dans le calcul des GRM, afin d'éviter un biais dans l'estimation de l'effet aléatoire. Cette méthode s'appelle LOCO pour Leave One Chromosome Out. Ainsi, pour un site viral i fixé, on calcule la matrice de parenté virale K_v à partir de la matrice Y_{-i} qui correspond à la matrice Y sans la colonne i . On fait de même avec la matrice de parenté K_h en enlevant la colonne j de la matrice X pour un SNP j fixé.

Par la suite, on va tester un modèle avec un codage continu du côté du virus tout en gardant le codage additif du côté de l'hôte. Ce modèle s'écrit alors :

$$Y_i^c = \beta_0 + W\alpha + X_j\beta_{ij} + \eta_v + \eta_h + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma_e^2 I_n)$$

Dans ce cadre, l'intérêt principal n'est plus seulement d'estimer les coefficients du modèle, mais de tester la significativité de l'association entre chaque SNP de l'hôte j et chaque site viral i , c'est-à-dire de tester $H_0 : \beta_{ij} = 0$. Or, ce test doit être répété pour un très grand nombre de paires SNP-site viral, et une estimation classique du modèle par maximum de vraisemblance nécessiterait de réinverser la matrice de covariance globale à chaque test, ce qui est numériquement impossible à l'échelle de nos données. Il est donc nécessaire d'utiliser une méthode d'estimation factorisée, qui sépare l'estimation des paramètres de nuisance (communs à tous les tests) de celle du test d'association lui-même : le test du score de Rao.

4.4.1 Estimation — test du score de Rao

L'évaluation de chaque paire de variants (hôte, virus) implique d'ajuster le modèle mixte des millions de fois. Or, l'estimation des composantes de la variance (σ_v^2 , σ_h^2) par maximum de vraisemblance nécessite l'inversion répétée de matrices de grande dimension, ce qui représente un coût computationnel important. Le test du score de Rao est implémenté dans le package *GMMAT* de **R**. Les scripts utilisés pour la reproductibilité des calculs sont disponibles sur un dépôt GitHub dont le lien figure en annexe. Ils sont fournis sans les données, pour des raisons de confidentialité.

Concrètement, la procédure se déroule en deux étapes :

1. Ajustement sous H_0 : on force le coefficient d'intérêt β_{ij} à 0, le modèle nul ne contenant alors que l'intercept et les effets aléatoires. On ajuste le modèle une seule fois par phénotype viral pour estimer les paramètres de nuisance et les composantes de la variance.

2. Calcul du score : pour chaque variant de l'hôte j , on évalue le gradient de la log-vraisemblance au point $\beta_{ij} = 0$. Si ce gradient est significativement éloigné de zéro, l'hypothèse nulle est rejetée, indiquant une association entre X_j et Y_i .




FIGURE 5 – Test du score de Rao

Cette méthode permet d'éviter le réajustement des effets aléatoires pour chaque SNP testé, réduisant ainsi drastiquement la complexité algorithmique tout en conservant une grande robustesse statistique.

La contrepartie de ce test est qu'il ne fournit pas d'estimation directe de l'effet β_{ij} , mais uniquement une statistique de test et une p-value associée. Cependant, dans le contexte d'une étude exploratoire visant à identifier des associations potentielles, cette limitation est acceptable. Néanmoins, pour les associations les plus prometteuses, il est possible de réajuster le modèle complet afin d'obtenir des estimations précises des effets et de leurs intervalles de confiance.

Il existe malgré tout des façons d'obtenir une estimation de l'effet β_{ij} à l'aide des p-values.

4.4.2 Estimation approchée de l'effet β_{ij}

On dispose de n individus, p sites de SNP de l'hôte indexés par $j \in \{1, \dots, p\}$ et q sites viraux indexés par $i \in \{1, \dots, q\}$. Pour un site viral i fixé, on note $\ell_i(\theta)$ la log-vraisemblance pénalisée du modèle mixte et $\theta_{ij} = (\beta_{ij}, \gamma_i)$, $\gamma_i = (\beta_0, \alpha^\top, \sigma_v^2, \sigma_h^2)^\top$, où $\beta_{ij} \in \mathbb{R}$ est le paramètre d'intérêt et γ_i le vecteur des paramètres de nuisance.

On remarquera que les paramètres de nuisance ne dépendent que du site viral i , et non du SNP testé j : c'est là tout l'intérêt de la méthode. Le modèle nul est ajusté q fois — une fois par phénotype viral — alors que $p \times q$ tests sont effectués. Le coût dominant, l'estimation des

composantes de la variance (σ_v^2, σ_h^2) , est donc factorisé entre les p SNP.

On rappelle que l'hypothèse testée est $H_0 : \beta_{ij} = 0$ contre $H_1 : \beta_{ij} \neq 0$. On note $\tilde{\theta}_i = (0, \hat{\gamma}_i)$ l'estimateur du maximum de vraisemblance *contraint*, c'est-à-dire l'ajustement du modèle nul, où $\hat{\gamma}_i$ maximise $\gamma \mapsto \ell_i(0, \gamma)$.

Détails :

Le score et la matrice d'information de Fisher se décomposent par blocs selon la partition de θ_{ij} :

$$U(\theta_{ij}) = \begin{pmatrix} U_\beta \\ U_\gamma \end{pmatrix}, \quad \mathcal{I}(\theta_{ij}) = \begin{pmatrix} \mathcal{I}_{\beta\beta} & \mathcal{I}_{\beta\gamma} \\ \mathcal{I}_{\gamma\beta} & \mathcal{I}_{\gamma\gamma} \end{pmatrix}.$$

Par définition de $\hat{\gamma}_i$, la composante de nuisance du score s'annule au point contraint :

$$U_\gamma(\tilde{\theta}_i) = 0. \quad (1)$$

On introduit l'*information efficace* relative à β_{ij} , définie comme le complément de Schur du bloc de nuisance et évaluée en $\tilde{\theta}_i$:

$$V_{ij} = \mathcal{I}_{\beta\beta} - \mathcal{I}_{\beta\gamma} \mathcal{I}_{\gamma\gamma}^{-1} \mathcal{I}_{\gamma\beta}. \quad (2)$$

Elle mesure l'information disponible sur β_{ij} une fois retirée la part partagée avec les effets fixes et les effets aléatoires. La formule d'inversion par blocs donne $[\mathcal{I}^{-1}]_{\beta\beta} = V_{ij}^{-1}$, et la statistique du score s'écrit alors

$$T_{ij} = \frac{U_{ij}^2}{V_{ij}} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \chi_1^2 \quad \text{sous } H_0, \quad U_{ij} \equiv U_\beta(\tilde{\theta}_i). \quad (3)$$

Proposition 4.1 (Approximation de Newton–Raphson en une itération). *Une itération de l'algorithme de Newton–Raphson initialisée au point contraint $\tilde{\theta}_i$ fournit l'approximation*

$$\boxed{\hat{\beta}_{ij} = \frac{U_{ij}}{V_{ij}}, \quad \widehat{\text{SE}}(\hat{\beta}_{ij}) = \frac{1}{\sqrt{V_{ij}}}} \quad (4)$$

Démonstration. L'itération de Newton–Raphson appliquée à l'équation de vraisemblance $U(\theta) = 0$ à partir de $\tilde{\theta}_i$ s'écrit $\hat{\theta}^{(1)} = \tilde{\theta}_i + \mathcal{I}(\tilde{\theta}_i)^{-1} U(\tilde{\theta}_i)$. En extrayant la composante en β , et en utilisant successivement (1) puis l'inversion par blocs :

$$\hat{\beta}_{ij} = \underbrace{0}_{\text{valeur initiale}} + [\mathcal{I}^{-1}]_{\beta\beta} U_{ij} + [\mathcal{I}^{-1}]_{\beta\gamma} \underbrace{U_\gamma(\tilde{\theta}_i)}_{=0} = \frac{U_{ij}}{V_{ij}}.$$

L'annulation du second terme est essentielle : c'est elle qui rend l'estimateur indépendant d'une mise à jour simultanée des paramètres de nuisance, et donc calculable sans réajuster le modèle mixte. $\square$

Remarque 4.2 (Interprétation). De façon équivalente, l'estimateur revient à remplacer la log-vraisemblance profilée par son approximation quadratique au voisinage de $\beta_{ij} = 0$: son développement de Taylor à l'ordre 1, $\partial \ell_i^{\text{prof}} / \partial \beta \simeq U_{ij} - V_{ij} \beta$, s'annule exactement en U_{ij}/V_{ij} . Le score U_{ij} donne la pente de la vraisemblance en 0, l'information V_{ij} sa courbure, et leur rapport localise le sommet de la parabole ainsi ajustée.

Cohérence avec les p-values déjà calculées. En reportant (4) dans la statistique de Wald, on obtient

$$z_{\text{Wald}} = \frac{\hat{\beta}_{ij}}{\widehat{\text{SE}}(\hat{\beta}_{ij})} = \frac{U_{ij}/V_{ij}}{V_{ij}^{-1/2}} = \frac{U_{ij}}{\sqrt{V_{ij}}} = z_{\text{score}}, \quad (5)$$

c'est-à-dire exactement la racine signée de (3). Les coefficients reconstruits sont donc rigoureusement compatibles avec les p-values issues du criblage : l'approximation n'introduit aucune incohérence dans les résultats déjà produits, et le signe de U_{ij} fournit directement le sens de l'association.

4.4.3 Le facteur d'inflation génomique

À ce stade, on ne dispose pas de critère objectif pour juger la qualité de l'ajustement du modèle. Afin de pouvoir juger si le modèle a bien été ajusté, on peut utiliser le facteur d'inflation génomique λ [13].

Ce facteur λ ne dit rien d'un SNP particulier ; il évalue la calibration de l'ensemble de l'analyse. Le raisonnement est le suivant : si aucun SNP n'était associé au phénotype, les p-values seraient uniformément distribuées sur $[0, 1]$, et les statistiques de test correspondantes suivraient la loi de référence du test employé. Toute déviation de cette distribution signale que le modèle produit des p-values plus petites ou plus grandes qu'il ne le devrait.

La statistique de score du modèle mixte suit asymptotiquement une loi χ^2 à un degré de liberté sous H_0 . Chaque p-value p_i peut donc être reconvertie en la statistique qui l'a produite :

$$\chi_1^2 = F_{\chi_1^2}^{-1}(1 - p_i),$$

où $F_{\chi_1^2}^{-1}$ désigne la fonction quantile de la loi χ_1^2 . Cette transformation étant bijective, aucune information n'est perdue : on change simplement d'échelle pour travailler sur des quantités dont l'espérance et la médiane théoriques sont connues.

Le facteur d'inflation est alors le rapport entre la médiane empirique de ces statistiques et sa valeur attendue sous H_0 :

$$\lambda_{\text{median}} = \frac{\text{med}(T_1, \dots, T_n)}{\text{med}(\chi_1^2)} = \frac{\text{med}(T_i)}{0.4549},$$

où $\text{med}(\chi_1^2) = 0.4549$ est la médiane théorique d'une loi du khi-deux à un degré de liberté. Sous H_0 , une telle statistique a pour espérance 1 et pour médiane 0.4549 ; un λ_{median} voisin de 1 indique donc que le corps de la distribution observée se comporte comme la loi de référence.

Le recours à la *médiane* plutôt qu'à la moyenne est justifié par les auteurs. Un petit nombre de SNPs réellement associés produit des statistiques très grandes qui déplacent la moyenne mais laissent la médiane inchangée. λ_{median} mesure donc le comportement du corps de la distribution, là où l'hypothèse nulle est censée s'appliquer, plutôt que celui de sa queue.

L'interprétation classique est la suivante : $\lambda > 1$ signale qu'une structure de population résiduelle a été détectée [13]. Les auteurs montrent, par la théorie comme par la simulation, qu'en l'absence de toute structure de population et de tout artefact, une inflation est attendue dès lors que le caractère étudié est polygénique.

On exploite ce point. L'inflation polygénique croît avec N ; à notre taille d'échantillon, elle est négligeable. Toute valeur de λ sensiblement supérieure à 1 dans nos analyses relève donc d'un

défaut de calibration, et non d'une architecture polygénique du caractère. Nous retenons en conséquence la grille de lecture suivante : $\lambda \approx 1$, calibration correcte ; λ entre 1.05 et 1.20, inflation à signaler ; $\lambda > 1.20$, résultats non interprétables en l'état. Une valeur inférieure à 0.95 indiquerait à l'inverse un test conservateur, donc une perte de puissance [6].

5 Résultats et discussion

5.1 Les jeux de données

5.1.1 Hépatite C

Le jeu de données du VHC porte sur 470 individus infectés par une souche de génotype 3a. Pour chacun, nous disposons du génome viral séquencé, d'un génotypage hôte de 300 000 sites, ainsi que de l'âge, du sexe, de la charge virale, du groupe ethnique déclaré et du pays de recrutement.

La composition de la cohorte n'est pas neutre pour la suite (figure 6). Le recrutement s'est fait dans cinq pays, avec une nette surreprésentation du Royaume-Uni, et la très grande majorité des individus sont d'ascendance européenne. Les autres groupes ne sont présents qu'en effectifs réduits, principalement une composante asiatique au Royaume-Uni et en Australie. Cette structure a deux conséquences. D'une part, un SNP dont la fréquence allélique diffère fortement entre groupes peut se retrouver associé à une mutation virale simplement parce que les deux sont plus fréquents dans le même sous-groupe ; c'est précisément ce que l'effet aléatoire d'apparement est censé absorber, et nous vérifierons plus loin que c'est bien le cas. D'autre part, la puissance de détection est en pratique portée par le groupe majoritaire : une association spécifique à un groupe minoritaire a peu de chances d'être détectée ici.




FIGURE 6 – Répartition des individus de la cohorte VHC par pays de recrutement et par groupe ethnique déclaré.

Une observation faite au cours de ce stage est que la structure de la population se retrouve aussi dans les composantes principales du virus. En effet, la figure 7 montre que les deux premiers axes de l'ACP du virus séparent trois groupes. Parmi ces trois groupes, l'un rassemble l'ensemble des individus d'ascendance asiatique, sans pour autant exclure les autres.




FIGURE 7 – Axes principaux de l’ACP du virus pour la cohorte VHC, colorés par groupe ethnique déclaré.




FIGURE 8 – Distribution des variants viraux pour la cohorte VHC.

5.1.2 Dengue

Le jeu de données dengue est de nature un peu différente. Il regroupe 270 individus, tous recrutés au Sri Lanka. L’origine ethnique n’est pas renseignée, mais le recrutement sur un unique pays permet de supposer une population hôte nettement plus homogène que dans le cas du VHC. En contrepartie, nous ne pouvons pas vérifier cette hypothèse directement, et nous nous en remettons entièrement à la matrice d’apparementement.

Nous disposons en revanche d’une covariable absente du jeu VHC : le statut d’infection antérieure. Ce dernier point a son importance pour l’infection par le DENV, où une seconde infection par un sérotype différent est un facteur de risque reconnu de forme sévère. Ces variables n’entrent pas dans les modèles présentés ici, qui portent sur les mutations virales et non sur le phénotype clinique, mais elles ouvrent une piste que nous évoquons en conclusion.

La particularité déterminante de ce jeu de données est ailleurs : il contient trois sérotypes viraux distincts. Nous y revenons en section 5.3.4, car cette structure impose de modifier le codage.

De plus, la figure 9 montre que la variabilité des sites viraux est très faible, la distribution étant concentrée près de 0. Cela impliquera une mauvaise calibration du modèle, et donc des

p-values extrêmes qui ne sont pas forcément fiables. Il faudra donc être prudent dans l'interprétation des résultats.




FIGURE 9 – Distribution des variants viraux pour la cohorte de la dengue.

5.2 Choix du codage des sites viraux

Le codage de la réponse virale a occupé une part importante du stage, et mérite d'être explicité avant de présenter les résultats, car il conditionne tout ce qui suit.

Le codage de départ est binaire : pour un site donné, on note 0 l'acide aminé de référence et 1 tout acide aminé qui en diffère. La référence retenue est l'acide aminé majoritaire dans le jeu de données. Ce codage revient à mesurer la survenue d'un événement mutationnel, sans rien dire de sa nature.

Un filtrage préalable est indispensable. Le VHC est un virus à ARN, dont le taux de mutation élevé entretient une forte variabilité, mais tous les sites ne sont pas également variables : certains sont soumis à de fortes contraintes fonctionnelles et restent quasiment invariants. Un site où la mutation n'est observée que chez deux ou trois individus ne peut donner lieu à aucun test exploitable. Nous avons donc écarté les sites dont la fréquence de l'acide aminé minoritaire est inférieure à 5 %, ce qui laisse 427 sites pour le VHC.

Le second codage envisagé remplace cette variable binaire par la *distance de Grantham* entre l'acide aminé observé et celui de référence (section 3.2.2). La réponse devient continue et positive, nulle en l'absence de substitution, et d'autant plus grande que la substitution est chimiquement radicale. L'intérêt est direct : une substitution leucine/isoleucine, très peu susceptible d'altérer la protéine, ne pèse plus autant qu'une substitution cystéine/tryptophane. Autrement dit, on cherche non plus les positions qui mutent, mais celles qui mutent et ont un impact fort.

Ce gain se paie de deux façons, qu'il faut avoir en tête pour lire la suite. D'abord, l'analyse se restreint aux sites dont la variabilité se traduit effectivement par un changement d'acide aminé, ce qui fait baisser la puissance statistique. Ensuite, la distribution de la réponse change complètement de forme : au lieu d'une variable de Bernoulli, on obtient une variable très asymétrique, avec une masse importante en zéro et quelques valeurs élevées. Les coefficients des deux modèles ne sont donc pas comparables directement, ni en signe, ni en amplitude : dans un cas il s'agit d'un log-odds, dans l'autre d'un effet en unités de distance de Grantham.

5.3 Modèle linéaire généralisé à effets aléatoires

5.3.1 Mise en œuvre et seuil de significativité

Le modèle décrit en section 4.4 a été ajusté avec le package *GMMAT* de R, sur le cluster *iTrop*. Le nombre de tests correspond au produit du nombre de SNPs de l’hôte par le nombre de sites viraux retenus, soit de l’ordre de 1.3×10^8 pour le VHC. Une exécution séquentielle demanderait environ deux jours ; la répartition sur 36 cœurs ramène le calcul à une heure.

Le choix du seuil mérite qu’on s’y arrête, car il n’est pas un simple Bonferroni. Avec de l’ordre de 3×10^5 SNPs, une correction de Bonferroni appliquée à *un seul site viral* donnerait un seuil autour de 1.7×10^{-7} . Une correction appliquée à la grille complète des 1.3×10^8 paires donnerait 4×10^{-10} . Le seuil que nous retenons, 10^{-8} [6], se situe entre les deux, et ce positionnement est un compromis assumé plutôt qu’une propriété statistique.

Deux effets jouent en effet en sens contraire. D’un côté, Bonferroni suppose l’indépendance des tests, hypothèse clairement fautive entre SNPs voisins en déséquilibre de liaison : le nombre effectif de tests indépendants est sensiblement inférieur au nombre de SNPs, et la correction est donc trop sévère. De l’autre, notre seuil ignore la multiplicité liée aux 427 sites viraux, et sur ce plan il est trop permissif : environ 25 fois plus que le Bonferroni complet. Concrètement, sous l’hypothèse nulle et sous indépendance, 1.3×10^8 paires testées à 10^{-8} produisent environ un faux positif attendu.

Il faut donc lire les décomptes qui suivent comme des listes de *signaux candidats*, majoritairement réels mais pas exclusivement. C’est cohérent avec l’objectif du stage, qui est exploratoire.

5.3.2 Lecture des figures

Les trois mêmes types de représentation reviennent pour chaque analyse. Plutôt que d’en redonner la lecture à chaque fois, nous la fixons ici une fois pour toutes.

Le **cercle d’association** donne la vue d’ensemble. Les chromosomes de l’hôte occupent une partie de la circonférence, les protéines virales l’autre, et chaque lien relie un SNP à un site viral significatif. Ce qu’il faut y regarder n’est pas le nombre de liens, qui est trompeur — un même locus représenté par cinquante SNPs corrélés produit cinquante liens —, mais leur *répartition* : signal concentré sur une région, ou dispersé sur l’ensemble du génome.

Le **Manhattan plot** détaille un site viral donné : chaque point est un SNP hôte, placé selon sa position génomique et selon $-\log_{10}(p)$. Le critère de crédibilité n’y est pas la hauteur du pic mais sa *forme*. Une association réelle se manifeste par un groupe de marqueurs contigus qui montent ensemble, parce que le déséquilibre de liaison fait que les SNPs voisins du variant causal lui sont partiellement corrélés. À l’inverse, un point isolé très haut, sans aucun voisin élevé, évoque davantage un artefact de génotypage qu’un signal biologique.

Le **QQ plot** ne dit rien sur un SNP en particulier, mais tout sur la calibration du modèle. Il compare la distribution des p-values observées à celle attendue sous l’hypothèse nulle. Le profil recherché est une superposition à la diagonale sur l’essentiel de la distribution, avec une déviation confinée à l’extrême queue : cela signifie que la grande majorité des tests se comporte comme sous H_0 , et que seule une petite fraction s’en écarte. Un décollement précoce, dès les faibles valeurs de $-\log_{10}(p)$, signale au contraire que quelque chose n’est pas absorbé par le modèle — le plus souvent une structure de population résiduelle. On peut quantifier cette calibration via le facteur d’inflation génomique λ (section 4.4.3).

Enfin, les **intervalles de confiance** des coefficients, obtenus par réajustement complet du modèle via `glmm.wald()`, donnent le sens et l’amplitude de l’effet. Dans le modèle logistique, β_{ij} est un log-odds : un coefficient positif signifie que chaque copie supplémentaire de l’allèle

alternatif au SNP hôte augmente la probabilité d’observer la mutation au site viral. C’est la signature attendue d’un échappement : l’hôte porteur exerce une pression, le virus y répond en mutant à cette position. Un coefficient négatif décrit la situation inverse, les porteurs étant associés au maintien de l’acide aminé de référence. Dans les deux cas, il s’agit d’une association et non d’un lien causal établi.

5.3.3 Codage binaire appliqué au VHC

Nous obtenons 287 couples (SNP hôte, site viral) sous le seuil de 10^{-8} , répartis sur 32 sites viraux distincts, soit environ 7 % des 427 sites testés. Cet ordre de grandeur est raisonnable : la grande majorité du génome viral ne montre aucune association, ce qui est exactement ce qu’on attend.




FIGURE 10 – Cercle d’association entre les SNPs de l’hôte et les sites viraux du VHC (codage binaire). Liens gris : $p < 10^{-8}$; liens rouges : $p < 10^{-10}$.

La figure 10 est très structurée, et de deux manières.

Du côté de l’hôte, le signal converge massivement vers le chromosome 6, et de façon encore plus marquée si l’on ne retient que les liens rouges, qui correspondent à $p < 10^{-10}$. Cette structure en éventail, où un même faisceau de SNPs se projette vers de nombreux sites viraux, s’explique par la conjonction de deux phénomènes : les SNPs de ce faisceau sont fortement corrélés entre eux, et le locus qu’ils marquent agit sur plusieurs positions du génome viral à la fois. C’est un résultat attendu, et c’est même rassurant qu’il apparaisse : le chromosome 6 porte la région HLA, dont les molécules présentent les peptides viraux au système immunitaire. Un variant HLA sélectionne les peptides reconnus, donc les positions virales où une mutation permet d’échapper à la reconnaissance [1].

Du côté viral, les liens ne se répartissent pas uniformément sur le génome : la protéine NS3

concentre la majorité des associations et la quasi-totalité des liens rouges. Il faut toutefois relativiser cette concentration, car NS3 est l’une des plus longues protéines du VHC et contribue donc mécaniquement à un plus grand nombre de sites testés. Une comparaison honnête demanderait de rapporter le nombre d’associations au nombre de sites polymorphes testés dans chaque protéine.

Enfin, plusieurs de ces associations recourent celles publiées par ANSARI *et al.* [1], notamment celle impliquant le site viral 1450. C’est le point important de cette sous-section : le jeu VHC sert ici de contrôle, et le fait de retrouver des signaux déjà décrits par une autre méthode valide l’implémentation avant de l’appliquer à la dengue.

Site viral 1450. La figure 11 présente le *Manhattan plot* de ce site.




FIGURE 11 – *Manhattan plot* pour le site viral 1450 (VHC, codage binaire).

Le signal est dominé par un pic unique sur le chromosome 6, qui atteint $-\log_{10}(p) \approx 19$, soit plus de dix ordres de grandeur au-delà du seuil. Surtout, ce pic présente la forme attendue décrite en 5.3.2 : il est porté par une colonne dense de marqueurs contigus, et non par un point isolé. La largeur de cette colonne reflète l’étendue du bloc de déséquilibre de liaison autour du variant causal, ce qui est cohérent avec la région HLA, connue pour ses blocs particulièrement longs.

En dehors de ce pic, le nuage reste plat et homogène le long du génome. C’est un bon indicateur : si la structure de population était mal corrigée, on observerait une élévation générale des statistiques de test sur l’ensemble des chromosomes, ce qui n’est pas le cas. L’effet aléatoire d’apparement fait donc son travail. Un point sur le chromosome 2 émerge légèrement au-dessus du nuage, sans atteindre le seuil ni être accompagné de voisins élevés : il ne peut pas être retenu.

Le *QQ plot* (figure 12) confirme cette lecture. Les p-values observées suivent la diagonale sur la première moitié de la distribution et ne s’en écartent que dans la queue, de façon tardive et abrupte. C’est le profil d’un signal localisé : seule une petite fraction des tests s’écarte du modèle nul.




FIGURE 12 – *QQ plot* pour le site viral 1450 (VHC, codage binaire).

On calcule un λ_{median} de 0.981. Visuellement, la déviation occupe la moitié droite du graphe et paraît énorme. Mais l'axe des abscisses est en $-\log_{10}$: cette moitié droite ne contient qu'une poignée de points. Les 98 % de SNPs alignés sont écrasés dans le coin inférieur gauche. C'est un QQ plot qui semble révéler une catastrophe de calibration alors qu'il montre en réalité une distribution nulle correcte assortie d'un signal fort.

Les intervalles de confiance (figure 13) montrent que *toutes* les associations du site 1450 ont un coefficient **néga**tif, compris entre -1 et -2 . Les porteurs de l'allèle alternatif à ces SNPs sont donc associés au *maintien* de l'acide aminé de référence en position 1450, et non à sa mutation. Ce n'est pas contradictoire avec l'hypothèse d'échappement : le sens du coefficient dépend de l'allèle arbitrairement codé comme alternatif, et un signe négatif signifie simplement que c'est l'*autre* allèle du SNP qui accompagne la mutation virale. La remarque a néanmoins son importance pour la lecture des figures suivantes, où les signes ne sont pas tous orientés dans le même sens.




FIGURE 13 – Intervalles de confiance des coefficients pour les SNPs associés au site viral 1450 (VHC, codage binaire).

Site viral 1276. Ce second exemple illustre un profil de signal très différent.




FIGURE 14 – *Manhattan plot* pour le site viral 1276 (VHC, codage binaire).

Le SNP **rs11758516**, également sur le chromosome 6, est le variant le plus fortement associé, avec $-\log_{10}(p) \approx 11.5$. Il est le seul à franchir nettement le seuil ; les autres marqueurs annotés se situent entre 4 et 6, c'est-à-dire dans la zone suggestive, qui ne permet aucune conclusion.

La différence avec le site 1450 n'est donc pas seulement une question d'intensité. Le pic est ici plus étroit, ce qui suggère un bloc de déséquilibre de liaison plus court autour du variant. Cette étroitesse est à double tranchant : elle localise mieux le signal, ce qui est un avantage pour une éventuelle investigation fonctionnelle, mais elle le rend aussi plus fragile, puisque moins de marqueurs indépendants le corroborent. Le coefficient associé est positif et d'amplitude notable (figure 16), autour de 3.5, soit dans le sens attendu d'un échappement.

rs11758516 n'a pas d'implication médicale documentée ni de fonction connue dans les principales bases annotées.




FIGURE 15 – *QQ plot* pour le site viral 1276 (VHC, codage binaire).

Le *QQ plot* correspondant (figure 15) présente à nouveau une distribution conforme à H_0 sur l'essentiel de son étendue. On y observe en revanche une structure en marches d'escalier : plusieurs groupes de SNPs partagent des p-values quasiment identiques. C'est encore le déséquilibre

de liaison qui parle, des marqueurs presque parfaitement corrélés produisant des statistiques de test redondantes. Cette structure est utile à lire : le nombre de paliers donne une idée du nombre de signaux réellement indépendants, très inférieur au nombre de points situés au-dessus de la diagonale.

On obtient un λ_{median} de 0.983, ce qui confirme la bonne calibration du modèle.




FIGURE 16 – Intervalles de confiance des coefficients pour les SNPs associés au site viral 1276 (VHC, codage binaire).

On observe que, contrairement au site 1450, les coefficients sont tous positifs, ce qui correspond à un effet d'échappement. Une mutation virale est favorisée par la présence d'un allèle alternatif chez l'hôte, ce qui est cohérent avec l'hypothèse d'une pression de sélection exercée par le système immunitaire.

5.3.4 Codage binaire appliqué à la dengue

Pourquoi le codage du VHC ne peut pas être repris tel quel. Le jeu dengue contient plusieurs sérotypes viraux distincts, dont la figure 17 montre la divergence.




FIGURE 17 – Arbre phylogénétique des sérotypes de la dengue présents dans l'échantillon.

Cette divergence est très ancienne — l'arbre place la séparation des principaux sérotypes autour du XV^e siècle — et elle est d'un tout autre ordre de grandeur que la variabilité accumulée à l'intérieur d'un sérotype. Un codage naïf en présence/absence par rapport à une référence unique serait donc dominé par cette divergence ancienne : un site parfaitement conservé à l'intérieur de chaque sérotype, mais différent d'un sérotype à l'autre, apparaîtrait comme hautement variable. La variable réponse deviendrait alors une étiquette de sérotype déguisée, et les associations détectées ne diraient rien d'autre que « tel groupe d'hôtes est infecté par tel sérotype ».

Nous modifions donc le codage de manière à ne retenir que la variation informative : chaque site est codé selon la présence ou l'absence d'une mutation *par rapport à la séquence de référence de son propre sérotype*. Un site conservé au sein de chaque sérotype, même s'il diffère entre sérotypes, est ainsi codé uniformément à 0 et ne génère aucun signal.

Deux précautions accompagnent ce recodage. D'abord, la numérotation des positions doit être définie sur un alignement commun à tous les sérotypes, sans quoi les positions comparées ne seraient pas homologues ; nous avons utilisé pour cela la méthode d'alignement décrite en section 3.2.1. Ensuite, un même codage à 1 ne recouvre pas nécessairement la même substitution selon le sérotype : le codage mesure l'événement mutationnel, non sa nature. C'est une perte d'information assumée à ce stade, que le codage continu est censé compenser en partie.

Le prix à payer est une forte réduction de la variabilité disponible : après recodage et filtrage, il ne reste que **193 sites viraux polymorphes**, contre 427 pour le VHC, pour environ 3×10^5 SNPs hôtes. Ce point est essentiel pour lire ce qui suit.

Résultats d'ensemble, et une réserve importante. Nous obtenons **480 couples** (SNP, site viral) sous le seuil de 10^{-8} , répartis sur **90 sites viraux distincts**. La figure 18 en donne la vue d'ensemble.

Ces chiffres appellent une réserve que nous préférons poser d'emblée plutôt qu'en conclusion. 90 sites associés sur 193 testés représentent près d'un site sur deux, alors que le VHC donnait 32 sites sur 427, soit un sur treize. Il n'est pas plausible que la moitié du génome de la dengue soit sous pression de sélection détectable dans un échantillon de cette taille. Par ailleurs, la grille dengue ne compte qu'environ 6×10^7 paires, ce qui, au seuil de 10^{-8} , ne prédit qu'un demi faux positif attendu sous indépendance — très loin des 480 observés.




FIGURE 18 – Cercle d’association entre les SNPs de l’hôte et les sites viraux de la dengue (codage binaire relatif au sérotype).

Le cercle lui-même est cohérent avec cette réserve : contrairement au VHC, les liens sont distribués sur l’ensemble des chromosomes hôtes sans concentration nette, ce qui ressemble davantage à un fond diffus qu’à un ensemble de loci identifiés. Les QQ plots examinés ci-dessous confirment cette impression, et nous discutons en fin de section les causes possibles.

Site viral 2775. Le site 2775 se situe dans NS5, la plus grande protéine non structurale du virus. NS5 porte deux activités enzymatiques indispensables à la réplication, l’ARN polymérase ARN-dépendante et une méthyltransférase, et intervient également dans l’inhibition de la réponse interféron de l’hôte. C’est donc a priori une protéine intéressante pour notre question.

Le Manhattan plot (figure 19) est nettement plus bruité que ses équivalents VHC. Le nuage de fond est plus haut, et une quinzaine de points franchissent le seuil sans qu’aucun pic ne se détache franchement. En appliquant le critère de forme énoncé en 5.3.2, les candidats les moins fragiles sont AX-11278381 sur le chromosome 3, AX-42210719 sur le chromosome 7 et AX-11112091, qui sont accompagnés de marqueurs voisins élevés. Les autres points significatifs sont isolés : ils ne sont soutenus par aucun marqueur en déséquilibre de liaison avec eux, ce qui est difficile à concilier avec l’existence d’un variant causal dans la région, et évoque plutôt un artefact de génotypage ou un effet de faible fréquence allélique.

Le *QQ plot* (figure 20) est ici le résultat le plus informatif, et il est moins favorable que pour le VHC : la courbe décolle de la diagonale très tôt, dès $-\log_{10}(p) \approx 1$, et reste au-dessus sur toute son étendue. Ce n’est pas le profil d’un signal localisé mais celui d’une inflation générale des statistiques de test, qui indique qu’une part de la structure des données n’est pas absorbée par le modèle.




FIGURE 19 – *Manhattan plot* pour le site viral 2775 (dengue, codage binaire).




FIGURE 20 – *QQ plot* pour le site viral 2775 (dengue, codage binaire).

Comme il était prévisible au vu du *QQ plot*, on obtient un $\lambda_{\text{median}} = 1.23$, ce qui dépasse le seuil de 1.20 fixé en section 4.4.3 et est très supérieur à ce qu'on devrait attendre d'une distribution nulle bien calibrée. Cela signifie qu'il persiste une structure de la population hôte qui n'est pas absorbée (ou mal absorbée) par les effets aléatoires.

Les intervalles de confiance (figure 21) sont tous positifs, ce qui va dans le sens d'un échappement : les porteurs de l'allèle alternatif sont associés à la présence de la mutation en position 2775. Mais leur *amplitude* pose problème. Les coefficients se situent entre 5 et 9 sur l'échelle logit, soit des odds-ratios de l'ordre de 10^2 à 10^4 , et les intervalles sont larges. Le fait que tous les coefficients soient positifs est d'ailleurs cohérent avec cette lecture : en situation de séparation,




FIGURE 21 – Intervalles de confiance des coefficients pour le site viral 2775 (dengue, codage binaire).

le signe est déterminé par la configuration du tableau de contingence bien plus que par un effet biologique.

Il ne s'agit donc pas de rejeter ces associations, mais de reconnaître qu'en l'état elles ne sont pas interprétables quantitativement. Une vérification simple s'impose : reporter, pour chaque paire significative, la fréquence de l'allèle mineur du SNP et la fréquence de la mutation au site viral, et examiner le tableau de contingence croisé.

Site viral 173. Le site 173 se situe dans prM, protéine structurale qui participe à l'enveloppe du virion et dont la maturation conditionne l'infectiosité des particules virales. Il présente donc un profil fonctionnel opposé à celui de NS5, ce qui rend la comparaison intéressante.




FIGURE 22 – *Manhattan plot* pour le site viral 173 (dengue, codage binaire).

Le signal est là aussi porté par plusieurs marqueurs (figure 22). Les candidats les plus crédibles, au sens du critère de forme, sont AX-63561232 sur le chromosome 1, AX-11239493 sur le chromosome 3 et AX-15470303 sur le chromosome 6 : ils dépassent tous $-\log_{10}(p) = 10$ et sont accompagnés de voisins élevés. On notera l'absence de concentration sur le chromosome 6

comparable à celle observée pour le VHC.




FIGURE 23 – *QQ plot* pour le site viral 173 (dengue, codage binaire).

Le *QQ plot* (figure 23) présente la même inflation précoce que pour le site 2775, avec un décolllement dès $-\log_{10}(p) \approx 2$. La régularité de ce comportement d'un site à l'autre est en soi une information : il ne s'agit pas d'une particularité d'un site, mais d'un problème de calibration qui affecte l'ensemble de l'analyse dengue.

On obtient un λ_{median} de 1.189, ce qui reste sous le seuil de 1.20 fixé en section 4.4.3 mais est supérieur à ce qu'on devrait attendre d'une distribution nulle bien calibrée. Il reste néanmoins interprétable.




FIGURE 24 – Intervalles de confiance des coefficients pour le site viral 173 (dengue, codage binaire).

Les coefficients (figure 24) reproduisent le profil du site 2775 : tous positifs, tous compris entre 5 et 12, avec des intervalles larges. La même réserve s'applique.

L'analyse dengue est moins bien calibrée que l'analyse VHC. Trois explications nous semblent plausibles, et elles ne s'excluent pas.

La première tient à la structure virale résiduelle. Le codage relatif au sérotype supprime la variation *entre* sérotypes dans la réponse, mais il ne supprime pas la structure sous-jacente, comme pourraient le laisser supposer les valeurs de λ_{median} : la matrice de parenté virale K_v

reste dominée par la séparation entre sérotypes, qui est d'un ordre de grandeur bien supérieur à la variabilité intra-sérotipe. L'effet aléatoire risque donc de capter cette divergence ancienne plutôt que la structure fine qui nous intéresse. Un test simple permettrait de trancher : refaire l'analyse sérotipe par sérotipe et vérifier si les signaux persistent.

La deuxième tient à la faible variabilité intra-sérotipe. Ne conserver que 193 sites signifie que beaucoup d'entre eux sont proches du seuil de 5 % de variabilité retenu au filtrage. Des sites faiblement polymorphes produisent des tableaux de contingence déséquilibrés, où la statistique du score converge mal vers sa loi χ^2_1 asymptotique : les p-values sont alors trop petites, ce qui est exactement l'inflation observée. Relever le seuil de filtrage à 10 % et comparer les QQ plots permettrait de mesurer l'ampleur de cet effet.

La troisième, moins probable mais à ne pas écarter, tient à la structure hôte. L'hypothèse d'une population homogène au Sri Lanka reste une hypothèse, et le pays compte plusieurs groupes de population distincts. Une inspection des premières composantes principales de la matrice d'apparement hôte suffirait à s'en assurer.

5.3.5 Codage continu appliqué au VHC

La réponse n'est plus binaire mais continue, positive et fortement asymétrique, avec une masse importante en zéro : l'hypothèse gaussienne du modèle ne tient donc plus. Cela n'invalidé pas le test pour autant. La loi normale intervient ici comme une vraisemblance de travail : l'estimateur reste convergent pour la structure de moyenne sous mauvaise spécification de la loi de la réponse, et la normalité asymptotique de la statistique de score provient du théorème central limite sur les n individus, non de la loi de Y_i . La condition réelle de validité porte donc sur le nombre d'observations non nulles par site : c'est lorsqu'une poignée d'individus seulement porte une substitution que l'approximation χ^2_1 échoue — le même mécanisme que celui invoqué en section 5.3.4 pour la dengue. Le filtrage de 5 % de fréquence de l'acide aminé minoritaire garantit ce minimum, et joue ici un rôle de condition de validité autant que de critère de puissance.

Le modèle a été ajusté avec le même package et sur la même infrastructure, pour un temps de calcul inchangé. La réponse est désormais la distance de Grantham entre l'acide aminé observé et la référence.

Nous obtenons 29 associations sous le seuil de 10^{-8} , réparties sur **19 sites viraux distincts**, contre 287 associations et 32 sites en codage binaire. La chute est donc importante, mais elle affecte beaucoup plus le nombre de *paires* que le nombre de *sites* : c'est cohérent avec le fait que les paires du codage binaire étaient largement redondantes, plusieurs dizaines de SNPs corrélés pointant vers le même locus.

On obtient un profil d'associations sensiblement différent. La figure 25 présente une répartition nettement plus dispersée que son équivalent binaire, des deux côtés du cercle : les liens ne se concentrent plus sur NS3, et la prédominance du chromosome 6 s'estompe au profit d'un signal réparti sur l'ensemble du génome hôte.

Cette différence admet deux lectures concurrentes, qu'il serait imprudent de trancher en l'état.

Selon la première, le codage continu révélerait des associations d'une autre nature. Le codage binaire est en effet particulièrement bien adapté à la détection de l'échappement au CMH, où ce qui compte est qu'un peptide ne soit plus reconnu, indépendamment de la nature chimique de la substitution — d'où la concentration sur le chromosome 6. En pondérant les substitutions par leur impact physico-chimique, le codage continu privilégierait au contraire des mécanismes où c'est la structure de la protéine virale qui est en jeu, et qui n'ont aucune raison d'être portés par la région HLA.

Selon la seconde, cette dispersion est simplement ce qu'on attend d'une baisse de puissance. En réduisant le nombre de sites testables et en remplaçant une réponse binaire par une réponse




FIGURE 25 – Cercle d’association entre les SNPs de l’hôte et les sites viraux du VHC, codage continu (distances de Grantham).

très asymétrique, on perd du signal ; les associations les plus robustes passent sous le seuil, et la liste retenue se peuple de signaux marginaux dont la répartition est naturellement plus uniforme.

Départager ces deux lectures ne demande pas une analyse nouvelle mais une comparaison à ensemble de sites constant : si, restreint aux seuls sites testables en continu, le codage binaire retrouve la concentration sur le chromosome 6 alors que le codage continu ne la retrouve pas, la première lecture est étayée. Si les deux la perdent, c’est la seconde. Faute d’avoir pu mener cette comparaison dans le temps du stage, nous nous en tenons ici à un constat descriptif.

Les amplitudes, comprises entre 0.1 et 0.55, méritent en revanche un examen. Sur une échelle de Grantham qui va de 5 à 215, un effet de 0.3 unité par copie d’allèle est très faible. Il faudrait vérifier à quoi il correspond concrètement : un léger décalage de la proportion d’individus porteurs d’une substitution, ou un vrai déplacement vers des substitutions plus radicales chez les porteurs.

Site viral 1613. Ce site réapparaît dans plusieurs des associations significatives, ce qui est en soi un argument en sa faveur.

Le signal (figure 26) est porté par **rs11802399** sur le chromosome 1, seul marqueur à franchir le seuil, avec **rs79221421** sur le chromosome 11 en position suggestive. Comparé au site 1450, il est nettement plus faible et ne dépasse le seuil que d’une marge réduite. Il faut être clair sur ce que cela implique : pris isolément, ce signal ne serait pas retenu. C’est sa récurrence à travers




FIGURE 26 – *Manhattan plot* pour le site viral 1613 (VHC, codage continu).

plusieurs paires significatives, et non son intensité, qui justifie qu'on s'y intéresse.

Le SNP **rs11802399** est situé dans le gène *CDC42BPA*, qui code une sérine/thréonine kinase, effectrice de la petite GTPase CDC42 et impliquée dans la réorganisation du cytosquelette d'actine.

Le cytosquelette d'actine intervenant dans l'entrée et le trafic intracellulaire de nombreux virus, un lien avec le cycle viral est concevable, mais nous n'avons pas les moyens de le tester ici et cette piste doit rester présentée comme telle.




FIGURE 27 – *QQ plot* pour le site viral 1613 (VHC, codage continu).

Le *QQ plot* (figure 27) montre une distribution conforme à H_0 sur l'essentiel de son étendue, avec une déviation confinée à la queue. Le modèle est donc correctement calibré, ce qui n'était pas acquis d'avance en passant à une réponse continue et fortement asymétrique : c'est un ré-

sultat en soi, qui valide l'emploi du modèle mixte linéaire sur ce type de réponse.

De ce fait, on obtient un λ_{median} de 0.980, ce qui confirme la bonne calibration du modèle et montre que la structure de la population a bien été absorbée par les effets aléatoires. Bien qu'il ait été un peu conservateur, au vu d'un lambda légèrement inférieur à 1, il n'y a pas de signe d'inflation des p-values et le modèle est bien calibré.




FIGURE 28 – *Coefficients* pour le site viral 1613 (VHC, codage continu).

Les coefficients (figure 28) sont tous positifs, ce qui va dans le sens d'un effet d'échappement : les porteurs de l'allèle alternatif sont associés à une mutation sur cette position virale. En revanche, les coefficients sont compris entre 0.1 et 0.25, ce qui correspond à des effets assez faibles mais significatifs.

Site viral 1961. Le signal est ici porté par **rs893184**, sur le chromosome 19.

Ce site est le plus intéressant des deux : l'association n'apparaît ni dans les résultats de ANSARI *et al.* [1], ni dans notre propre analyse en codage binaire. Si elle se confirme, elle serait donc spécifiquement révélée par la prise en compte de la nature des substitutions, ce qui est exactement l'apport que ce codage était censé fournir.

Il faut cependant rester mesuré. Le signal est modeste, un unique marqueur franchit le seuil, et nous ne disposons d'aucune information fonctionnelle sur **rs893184**.

Le *QQ plot* (figure 30) est le mieux calibré de tous ceux présentés : la distribution suit la diagonale sur toute son étendue, sans aucune inflation, et seuls les tout derniers points s'en écartent. Cela ne prouve évidemment pas que l'association soit réelle, mais cela écarte l'explication la plus banale, celle d'un modèle mal spécifié produisant des p-values artificiellement petites.

On obtient néanmoins un λ_{median} de 1.014, ce qui témoigne d'une très bonne calibration du modèle et nous confirme que la structure de la population a bien été absorbée par les effets aléatoires.

D'après la figure 31, on observe des coefficients positifs et négatifs parmi les plus significatifs. Il peut donc y avoir des effets d'échappement et de conservation sur ce site viral, selon le SNP




FIGURE 29 – *Manhattan plot* pour le site viral 1961 (VHC, codage continu).




FIGURE 30 – *QQ plot* pour le site viral 1961 (VHC, codage continu).

considéré. Cela peut être dû à un mécanisme qui combine plusieurs positions afin d'exercer une pression de sélection sur le virus, ou bien à plusieurs mécanismes distincts capturés sur un même site viral, ce qui est possible si le site est impliqué dans plusieurs fonctions biologiques.

5.3.6 Codage continu appliqué à la dengue

Une limite atteinte avant même la lecture des résultats. Le passage au codage continu sur le jeu dengue combine les deux difficultés déjà rencontrées séparément : la faible variabilité intra-sérotipe relevée en section 5.3.4, et l'asymétrie de la réponse propre aux distances de Grantham. Il serait malhonnête d'interpréter ces résultats en sachant que le modèle est mal calibré et n'a pas pu fournir de résultats fiables. Nous avons décidé de ne pas les présenter dans ce rapport.




FIGURE 31 – *Coefficients* pour le site viral 1961 (VHC, codage continu).

5.4 Bilan des deux codages

TABLE 1 – Synthèse des associations significatives selon le virus et le codage. Les résultats du codage continu sur la dengue ne sont pas rapportés, le modèle n’étant pas correctement calibré (section 5.3.6).

Virus	Codage	Sites testés	Sites associés	Paires $p < 10^{-8}$
VHC	Binaire	427	32	287
VHC	Continu	322	19	29
Dengue	Binaire	193	90	480
Dengue	Continu	168	—	—

Le tableau 1 résume l’ensemble. La colonne « sites testés » permet de comparer les proportions plutôt que les effectifs bruts, et fait apparaître le contraste entre 7 % de sites associés pour le VHC et 47 % pour la dengue.

Ce que chaque codage apporte. Le codage binaire appliqué au VHC est celui qui donne les résultats les plus solides : le plus grand nombre de sites testables, la meilleure calibration, et surtout des signaux qui recoupent ceux de la littérature. C’est le modèle sur lequel nous fondons la confiance dans l’implémentation. Sa limite est celle de sa définition : il traite une substitution leucine/isoleucine et une substitution cystéine/tryptophane comme le même événement.

Le codage continu corrige précisément ce défaut, au prix d’une perte de puissance nette. Son apport potentiel n’est cependant pas seulement quantitatif : le déplacement du signal hors du chromosome 6 suggère qu’il ne détecte pas les mêmes choses, mais nous avons expliqué plus haut pourquoi cette lecture reste à établir. Nous la présentons comme une hypothèse à tester, pas comme un résultat.

Recoupement des deux codages. Le tableau 2 en annexe reprend les paires significatives en codage continu et donne leur p-value en codage binaire. La grande majorité d'entre elles n'y sont pas significatives, ce qui va dans le sens de deux ensembles de signaux largement disjoints. Quelques paires font exception, avec des p-values binaires de l'ordre de 10^{-3} à 10^{-4} : sans atteindre le seuil, elles indiquent un signal présent dans les deux analyses et renforcé par la prise en compte de la nature des substitutions. Ce sont probablement les candidats les plus intéressants du lot.

Trois directions nous paraissent prioritaires, par ordre de coût croissant.

La comparaison des deux codages à ensemble de sites constant est la moins coûteuse et la plus rentable : elle ne demande aucun calcul nouveau et permettrait de trancher entre les deux lectures du profil obtenu en codage continu.

La calibration du modèle de la dengue vient ensuite : comparer des sites entre sérotypes peut être délicat, et il n'est pas impossible qu'une partie des effets aléatoires capturent cette structure sans corriger correctement la stratification de la population virale. Une analyse sérotype par sérotype permettrait de vérifier si les signaux persistent et si l'inflation des p-values est réduite.

Enfin, le codage lui-même peut être repensé. La matrice de Grantham est un choix parmi d'autres, fondé sur des propriétés physico-chimiques. Une matrice empirique comme PAM250, construite à partir de substitutions réellement observées au cours de l'évolution virale, encoderait une information de nature différente — les contraintes fonctionnelles effectivement subies plutôt que la dissimilarité chimique théorique. Comparer les associations obtenues sous ces deux matrices permettrait au passage de savoir si les signaux détectés dépendent du choix de la matrice ou lui sont robustes, ce qui est une question intéressante en soi.

6 Conclusion et perspectives

Ce stage m'a offert l'opportunité d'appliquer des modèles statistiques à des problématiques biologiques complexes, en étudiant les interactions génome-à-génome entre l'hôte et les virus de l'hépatite C et de la dengue. Notre démarche a permis de mettre en évidence plusieurs associations potentielles entre des variants génétiques de l'hôte et des mutations virales. Toutefois, si ces résultats statistiques sont prometteurs, il est indispensable de poursuivre l'exploration de ces pistes d'un point de vue strictement biologique. Des études fonctionnelles complémentaires seront nécessaires pour vérifier si ces signaux sont effectivement responsables d'un processus adaptatif ou immunitaire précis.

Par ailleurs, ce travail a permis de mener une analyse détaillée de la stratification des populations. En réalisant des Analyses en Composantes Principales (ACP) protéine par protéine pour le VHC, nous avons pu mettre en évidence que certaines protéines affichent une structuration plus marquée, soulignant l'importance du rôle de l'ethnie de l'hôte et de la provenance géographique des données (région de capture) dans ces dynamiques.

Afin d'améliorer les modèles actuels, souvent construits sur le principe de la simplicité pour garantir leur fonctionnement, plusieurs perspectives méritent d'être explorées. En premier lieu, il serait pertinent de prendre en compte la reconstruction phylogénétique du virus, une dimension évolutive qui est actuellement ignorée dans notre modèle. De plus, au lieu de se limiter à l'évaluation de mutations ponctuelles, l'intégration de groupes d'acides aminés fonctionnellement liés, ou la prise en compte directe de la structure 3D des protéines, pourrait apporter une information spatiale et structurale cruciale pour affiner l'identification des pressions de sélection.

Ces perspectives seront explorées dans le cadre du doctorat que je poursuivrai à l'issue de ce stage, et qui s'inscrit dans la continuité de ce travail. L'objectif sera de développer des modèles plus sophistiqués, capables de capturer les interactions complexes entre l'hôte et le virus, tout en intégrant des données biologiques supplémentaires pour une meilleure interprétation des résultats. Comme le montrent les graphiques de l'annexe, l'ethnie des hôtes se retrouve dans les premières composantes principales du virus et pourrait suggérer une correction plus approfondie du côté de l'effet aléatoire du virus.

De plus, dans le cadre de la thèse, nous disposerons d'un plus grand nombre de données pour la dengue, ce qui permettra de mieux calibrer le modèle et de pouvoir effectuer des analyses par sérotype plutôt que sur l'ensemble des sérotypes.

L'identification de ces biomarqueurs nous permettrait dans un premier temps de mieux comprendre le mécanisme du virus pour échapper à la réponse immunitaire de l'hôte. Puis, dans un deuxième temps, cela pourrait nous permettre d'anticiper des vagues épidémiques en identifiant les variants viraux qui pourraient émerger dans certaines populations hôtes, et ainsi de mieux cibler les efforts de prévention et de traitement.

7 Annexe

7.1 Étapes de l'algorithme FISTA

Étape de descente de gradient. À chaque itération k , l'algorithme réalise d'abord un pas de gradient sur la partie lisse f , évalué non pas en β_k mais en un point extrapolé $\mathbf{y}_k$:

$$\mathbf{z}_k = \mathbf{y}_k - \frac{1}{L} \nabla f(\mathbf{y}_k)$$

où $\nabla f(\mathbf{y}_k)$ est le gradient de la log-vraisemblance logistique, de la forme $\frac{1}{n} \mathbf{X}^\top (\boldsymbol{\pi}(\mathbf{y}_k) - \mathbf{Y})$, avec $\boldsymbol{\pi}(\mathbf{y}_k)$ le vecteur des probabilités prédites $\text{logit}^{-1}(\mathbf{X}\mathbf{y}_k)$, et L une constante de Lipschitz du gradient (majorée ici par la plus grande valeur propre de $\mathbf{X}^\top \mathbf{X}/4n$), qui fixe la taille du pas.

Étape de seuillage (opérateur proximal). On applique ensuite au point $\mathbf{z}_k$ l'opérateur proximal de g , défini par :

$$\text{prox}_{g/L}(\mathbf{z}_k) = \underset{\beta}{\text{argmin}} \left\{ \frac{L}{2} \|\beta - \mathbf{z}_k\|_2^2 + g(\beta) \right\}$$

Pour la seule pénalité ℓ_1 , cet opérateur a une solution explicite, le seuillage doux (*soft-thresholding*) :

$$[\text{prox}_{\lambda_1/L \|\cdot\|_1}(z)]_i = \text{sign}(z_i) \max(|z_i| - \lambda_1/L, 0)$$

qui annule progressivement les coefficients de faible amplitude, ce qui permet de sélectionner uniquement les mutations virales les plus associées au SNP étudié. En présence de la pénalité de fusion sur graphe, l'opérateur proximal combiné $\text{prox}_{g/L}$ n'a plus de forme close et est résolu par un solveur interne itératif de type ADMM [9]. Le prox n'étant alors résolu qu'approximativement, chaque itération externe comporte une boucle interne, ce qui constitue une source supplémentaire de lenteur dans notre contexte.

Étape d'accélération. Enfin, FISTA ajoute une étape d'extrapolation de type Nesterov, en combinant les deux dernières estimations β_k et β_{k-1} , où $\beta_k = \text{prox}_{g/L}(\mathbf{z}_k)$:

$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \quad \mathbf{y}_{k+1} = \beta_k + \frac{t_k - 1}{t_{k+1}} (\beta_k - \beta_{k-1})$$

avec $t_1 = 1$ et $\mathbf{y}_1 = \beta_0$. Cette accélération permet d'obtenir une vitesse de convergence en $\mathcal{O}(1/k^2)$ sur l'écart des valeurs de la fonction objectif $F(\beta_k) - F(\beta^*)$, contre $\mathcal{O}(1/k)$ pour l'algorithme ISTA classique (sans extrapolation), tout en conservant une implémentation relativement simple. Cette propriété est particulièrement intéressante dans notre contexte, où le modèle doit être estimé pour un très grand nombre de SNPs et de sites viraux.

7.2 ACP VHC par protéine




FIGURE 32 – ACP virus pour la protéine NS3 du VHC avec pays de collecte en couleur.




FIGURE 33 – ACP virus pour la protéine NS5A du VHC avec ethnie de l'individu infecté en couleur.




FIGURE 34 – ACP virus pour la protéine NS5B du VHC avec ethnie de l’individu infecté en couleur.

7.3 Recoupement des deux codages

TABLE 2 – Paires SNP–site viral retenues ($n = 29$).

Site	SNP	CHR	Position	A1	A2	N	Manquants	MAF	Stat. 1	Stat. 2	p
pos_249	rs12666207	7	109901358	C	T	470	0.0000	0.0947	7.034	16.628	0.0845
pos_387	rs112616059	4	36675861	C	T	470	0.0000	0.0723	1.351	15.011	0.7273
pos_399	rs61793028	4	27822890	G	A	470	0.0000	0.0691	5.063	14.057	0.1769
pos_482	rs76162091	2	236427391	A	G	469	0.0021	0.0533	7.224	10.060	0.0227
pos_498	rs150422858	23	118307625	T	C	150	0.3404	0.0597	2.172	2.412	0.1619
pos_498	rs7880087	23	118866734	G	A	150	0.3404	0.0500	4.712	2.167	0.0014
pos_532	rs75742804	6	108753108	A	G	469	0.0021	0.0640	1.772	13.106	0.6245
pos_532	rs74480278	8	32906027	A	T	469	0.0021	0.0501	3.619	10.213	0.2574
pos_879	rs6903926	6	89737774	C	T	469	0.0021	0.0629	3.845	10.864	0.2434
pos_935	rs2098159	4	58072736	C	T	470	0.0000	0.0926	10.028	16.166	0.0126
pos_1099	rs11901744	2	192753035	A	G	468	0.0043	0.0524	4.624	6.745	0.0750
pos_1099	rs10277213	7	90076713	A	G	468	0.0043	0.0737	3.885	7.609	0.1591
pos_1613	rs11805012	1	227221683	G	A	468	0.0043	0.0652	4.426	11.733	0.1963
pos_1613	rs11802399	1	227353753	T	C	466	0.0085	0.0655	4.682	11.721	0.1714
pos_1613	rs74599093	1	227447282	G	A	469	0.0021	0.0640	4.047	11.570	0.2342
pos_1613	rs115058698	1	227483194	C	T	468	0.0043	0.0641	4.002	11.572	0.2394
pos_1961	rs893184	8	26485062	C	T	469	0.0021	0.0917	8.697	10.377	0.0069
pos_1968	rs139343845	23	16853107	C	T	150	0.3404	0.0468	1.313	2.294	0.3859
pos_1968	rs55963750	23	38661139	C	T	149	0.3436	0.0762	1.919	3.252	0.2872
pos_1985	rs7152082	14	59610371	C	T	469	0.0021	0.0661	10.889	10.518	0.0008
pos_2309	rs74154309	1	248759334	A	G	466	0.0085	0.1062	9.531	10.958	0.0040
pos_2383	rs73925656	2	45648877	A	G	468	0.0043	0.0545	5.390	8.054	0.0575
pos_2383	rs17033779	2	45745494	C	G	466	0.0085	0.0515	4.062	7.663	0.1423
pos_2386	rs17328824	10	3863901	G	A	470	0.0000	0.1021	7.310	16.916	0.0755
pos_2636	rs7560066	2	110439031	A	G	470	0.0000	0.0457	3.758	6.137	0.1293
pos_2636	rs17066125	13	76910089	G	A	466	0.0085	0.0515	6.452	6.175	0.0094
pos_2804	rs62122048	2	20740405	G	A	468	0.0043	0.0684	2.742	11.489	0.4186
pos_2804	rs28663468	10	10161515	C	T	467	0.0064	0.0567	0.729	8.797	0.8058
pos_2806	rs7062509	23	91225702	T	C	150	0.3404	0.0548	2.811	2.542	0.0779

7.4 Codes et commandes pour reproduire les analyses

Lien github : https://github.com/DamienMariac/GxG_MIVEGEC

7.5 Lexique des termes biologiques

Ce lexique vise à définir simplement les concepts biologiques et génétiques manipulés tout au long de ce rapport, afin de clarifier les objets modélisés statistiquement.

Acide aminé : Molécule constituant la brique de base des protéines. Il en existe 20 différents. Une mutation virale peut entraîner le remplacement d'un acide aminé par un autre, ce qui modifie la séquence de la protéine (recodé via la distance de Grantham dans nos modèles continus).

Allèle : L'une des différentes formes que peut prendre un site génétique donné. Dans nos modèles logistiques, on compte généralement le nombre de copies (0, 1 ou 2) de l'allèle « alternatif » par rapport à un allèle « de référence ».

ARN (Acide Ribonucléique) : Support de l'information génétique pour des virus comme le VHC et le DENV. Sa réplication est sujette à de nombreuses erreurs, ce qui explique le fort taux de mutation de ces virus.

CMH / HLA (Complexe Majeur d'Histocompatibilité) : Région très spécifique du génome de l'hôte (située sur le chromosome 6 chez l'humain, appelée HLA). Elle produit les protéines chargées de présenter les fragments du virus au système immunitaire. C'est une zone clé pour les phénomènes d'échappement viral.

Déséquilibre de liaison : Phénomène statistique par lequel des variants génétiques (SNPs) physiquement proches sur un chromosome sont fortement corrélés entre eux. Cela explique pourquoi un variant causal apparaît souvent entouré d'un « pic » de SNPs voisins également significatifs sur un Manhattan plot.

Génotype : L'ensemble de l'information génétique d'un individu. Dans ce rapport, il correspond à la matrice explicative X contenant le dosage allélique de l'hôte.

GxG (Genome-to-Genome) : Stratégie d'étude d'association (supervisée) consistant à modéliser les variations du génome du pathogène (le virus, variable à expliquer) en fonction des variations du génome de l'hôte (variables explicatives).

Nucléotide : Brique de base (les « lettres ») constituant l'ARN ou l'ADN.

Phylogénie : Étude de l'histoire évolutive et des liens de parenté (structure de population) entre différentes souches virales, souvent représentée sous forme d'arbre.

Profondeur (de séquençage) : Le nombre de fragments (reads) lus par la machine qui se superposent exactement à une même position génomique. Une forte profondeur donne une assurance statistique que la mutation lue n'est pas une simple erreur de la machine.

Read (ou Lecture) : Court fragment d'ARN découpé et lu aléatoirement par le séquenceur, qui doit ensuite être réaligné informatiquement par rapport à une séquence de référence.

Sérotipe : Sous-groupe d'un virus caractérisé par les antigènes présents à sa surface. Le virus de la dengue possède plusieurs sérotypes dont la divergence évolutive ancienne crée une forte structure de population virale.

SNP (Single Nucleotide Polymorphism) : Variation d'une seule paire de bases (un nucléotide) dans le génome de l'hôte. C'est l'unité de base de la diversité génétique de l'hôte testée dans nos modèles.

Substitution : Remplacement d'un acide aminé par un autre. Elle est qualifiée de « conservative » si les propriétés chimiques restent similaires, ou de « radicale » si les propriétés changent fortement (impactant le virus).

Références

- [1] M. Azim ANSARI, Vincent PEDERGNANA et al. “Genome-to-genome analysis highlights the impact of the human innate and adaptive immune systems on the hepatitis C virus”. In : *Nature Genetics* 49.5 (2017), p. 666-673.
- [2] M. Azim ANSARI et al. “Interferon lambda 4 impacts the genetic diversity of hepatitis C virus”. In : *eLife* 8 (2019), e42463.
- [3] Amir BECK et Marc TEBoulLE. “A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems”. In : *SIAM Journal on Imaging Sciences* 2.1 (2009), p. 183-202.
- [4] Antonin CHAMBOLLE et Charles DOSSAL. *Convergence des itérées de FISTA*. Preprint, HAL. 2015. URL : <https://hal.science/hal-01060130>.
- [5] Yiqun CHEN, Sean JEWELL et Daniela WITTEN. *More Powerful Selective Inference for the Graph Fused Lasso*. 2022. arXiv : 2109.10451.
- [6] Stéphanie DEBETTE. “Comment lire une étude d’association génétique pangénomique (GWAS) ?” In : *Sang Thrombose Vaisseaux* (2012).
- [7] Olivier NARET et al. “Correcting for Population Stratification Reduces False Positive and False Negative Results in Joint Analyses of Host and Pathogen Genomes”. In : *Frontiers in Genetics* 9 (2018), p. 266.
- [8] Alkes L. PRICE et al. “Principal components analysis corrects for stratification in genome-wide association studies”. In : *Nature Genetics* 38.8 (2006), p. 904-909.
- [9] Wesley TANSEY et James G. SCOTT. *A Fast and Flexible Algorithm for the Graph-Fused Lasso*. 2015. arXiv : 1505.06475.
- [10] George TUCKER, Alkes L. PRICE et Bonnie BERGER. “Improving the Power of GWAS and Avoiding Confounding from Population Stratification with PC-Select”. In : *Genetics* 197.3 (2014), p. 1045-1049.
- [11] Miaoyan WANG et al. “Two-way mixed-effects methods for joint association analysis using both host and pathogen genomes”. In : *Proceedings of the National Academy of Sciences* 115.24 (2018), E5440-E5449.
- [12] Zhi Ming XU et al. “Genome-to-genome analysis reveals associations between human and mycobacterial genetic variation in tuberculosis patients from Tanzania”. In : *BMC Medical Genomics* (2025).
- [13] Jian YANG et al. “Genomic inflation factors under polygenic inheritance”. In : *European Journal of Human Genetics* 19.7 (2011), p. 807-812.