



**UNIVERSITÉ DE
MONTPELLIER**



**STATISTIQUE
SCIENCE DES DONNÉES**
UNIVERSITÉ DE MONTPELLIER

MASTER II STATISTIQUES ET SCIENCES DES DONNÉES

Parcours Biostatistique

Identification des déterminants génétiques de la pathogénicité de la dengue

Présenté par :
Damien MARIAC

Encadré par :
Vincent PEDERGNANA

Tuteur FdS :
Ludovic Menneteau

Jury :
Élodie BRUNEL-PICCININI
Xavier BRY
Benoite DE SAPORTA

Année universitaire 2025-2026



Table des matières

1	Environnement	2
2	Context	3
2.1	Context du sujet	3
2.2	Context biologique	3
2.3	Extraction des données	3
3	Préparation des données	4
3.1	Alignement	4
3.2	Traitement des valeurs manquantes	4
4	Modélisation statistique	5
4.0.1	Modèle d'association "classique"	5
4.0.2	Limites du modèle "classique"	6
4.1	Modèle avec dépendances : Graph Fused Lasso	6
4.1.1	Construction du graphe de corrélation	7
4.1.2	Choix des paramètres de régularisation	7
4.1.3	Optimisation du modèle : algorithme FISTA	8
4.2	Modèle avec effets aléatoires	9
4.2.1	Estimation - Test du score de Rao	10
5	Résultats et discussion	11
5.1	Choix du codage	11
5.2	Comparaison des modèles	11
5.3	Performances du modèle retenu	11
6	Conclusion et perspectives	12
7	Annexes	13
7.1	Annexe 1	13
8	Bibliographie	14

1 Environnement

Bla bla sur la laboratoire et sur l'UMR MIVEGEC.

2 Context

2.1 Context du sujet

D'un individu à un autre, les symptômes d'une infection virale peuvent varier allant d'une absence de symptômes à des formes sévères. Cette variabilité est en partie due à la diversité génétique de l'hôte et du virus. L'objectif de cette étude est de proposer de nouveaux modèles permettant de faciliter l'étude d'associations entre les variants génétiques de l'hôte et les mutations virales, afin de mieux comprendre les mécanismes des réponses immunitaires.

Historiquement, les études d'association sont menées sur les symptômes eux-mêmes. Mais ceux-ci sont souvent largement influencés par des facteurs tels que l'environnement, l'alimentation ou les habitudes physiques.

Il existe depuis quelques années une variante de cette approche qui consiste à considérer le code génétique du virus comme symptôme. L'idée est que les mutations virales sont le reflet de la pression de sélection exercée par le système immunitaire de l'hôte. Ainsi, en identifiant les variants génétiques de l'hôte associés à certaines mutations virales, on peut obtenir des informations sur les mécanismes immunitaires impliqués dans la réponse à l'infection.

Ce qui fait toute la difficulté de cette approche est la haute dimensionnalité des données. En effet, on a du côté des hôtes des centaines de milliers de variants génétiques et du côté des virus des centaines de mutations après avoir filtré les sites dépassant un certain taux de variabilité. De plus, les individus issus de régions géographiques et d'ethnies différentes présentent des différences génétiques ce qui biaise les résultats d'association. Il est donc nécessaire de prendre en compte la structure de population des hôtes. Mais il est également nécessaire de prendre en compte la structure de population des virus. En effet, les virus issus d'une même région géographique ou d'une même lignée évolutive partagent des mutations communes. Il est donc nécessaire de prendre en compte la structure de population des virus.

2.2 Context biologique

Le virus est une entité biologique qui ne peut pas se reproduire par elle-même. Il a besoin d'un hôte pour se multiplier et se propager. Il est constitué d'une coque qui protège son matériel génétique, qui peut être de l'ADN ou de l'ARN. La nature du support de l'information ADN ou ARN dicte la réplication, ce qui a un impact majeur sur sa diversité génétique. De ce fait, les virus à ARN ont un taux de mutation beaucoup plus élevé que les virus à ADN. Cela est dû au fait que l'ARN polymérase, l'enzyme responsable de la réplication de l'ARN, n'a pas de mécanisme de correction d'erreurs contrairement à l'ADN polymérase. Cette haute variance est fondamentale : elle permet au virus de s'adapter très rapidement pour trouver des solutions face aux défenses de l'hôte.

Dans le cadre de ce stage, nous avons travaillé sur le virus de l'hépatite C dont on a déjà identifié des liaisons afin de pouvoir l'étendre sur le virus de la dengue. Ce sont tous deux des virus à ARN qui présentent une grande diversité génétique.

2.3 Extraction des données

3 Préparation des données

3.1 Alignement

3.2 Traitement des valeurs manquantes

4 Modélisation statistique

4.0.1 Modèle d'association “classique”

Le modèle proposé par [?] vise à modéliser la probabilité d'une mutation virale en fonction d'un SNP de l'hôte et de covariables telles que l'âge et le sexe. Pour un site viral et un SNP donnés, une régression logistique est ajustée indépendamment, et ce pour l'ensemble des paires SNP–site viral.

Afin de corriger la structure de population, les auteurs incluent les composantes principales (CP) de l'hôte et du virus comme effets fixes. En effet, les premières CP de l'hôte capturent l'origine ethnique des individus [?], et les premières CP du virus capturent l'origine géographique des souches [?] (Figure 1).




FIGURE 1 – Structure de population capturée par l'ACP.

Les auteurs retiennent les 10 premières CP de l'hôte et les 5 premières du virus. Ce choix reste discutable : ces composantes ne capturent respectivement que XX % et 12 % de la variance cumulée, ce qui suggère qu'une part importante de la structure de population n'est pas corrigée.

Le modèle s'écrit finalement, pour un SNP j et un site viral i fixés :

$$\text{logit}(P(Y_i = 1)) = \beta_0 + \beta_{ij} \text{SNP}_j + \sum_{k=1}^{10} \gamma_k PC_k^{\text{hôte}} + \sum_{l=1}^5 \delta_l PC_l^{\text{virus}}$$

Une p-value est extraite pour chaque test SNP–site viral. Les tests étant menés indépendamment sur un très grand nombre de paires, une correction pour tests multiples est nécessaire afin de limiter les faux positifs : les auteurs utilisent une correction de Bonferroni, avec un seuil de significativité $\alpha = 10^{-8}$.

Afin de pouvoir représenter les résultats, on peut construire un *Manhattan plot*. Celui-ci est un graphique qui représente les p-values de chaque SNP pour un site viral donné.




FIGURE 2 – Manhattan plot pour un site viral donné.

4.0.2 Limites du modèle “classique”

Ce modèle présente plusieurs limites ce qui motivent le développement d’une approche plus adaptée à ce type de données.

D’abord, il ne capture qu’une fraction de la structure de population : se limiter à quelques composantes principales, en plus d’ignorer une part importante de la variance, ne permet pas de représenter plus précisément la dépendance génétique entre individus (côté hôte) ou entre souches (côté virus).

Ensuite, il ignore la corrélation entre sites : les mutations virales peuvent être corrélées entre elles du fait de leur proximité structurale (conformation 3D de la protéine), et les SNPs de l’hôte proches sur le génome sont corrélés par déséquilibre de liaison. Ne pas modéliser ces dépendances revient à traiter chaque test comme indépendant alors qu’il ne l’est pas, ce qui biaise l’estimation de la significativité.

Puis, la correction de Bonferroni, en supposant l’indépendance des tests, est très conservatrice dans ce contexte de forte corrélation : elle risque d’écraser un signal réel, en particulier étant donné la très haute dimensionnalité des données (des millions de tests SNP–site viral).

4.1 Modèle avec dépendances : Graph Fused Lasso

Un modèle de type Graph Fused Lasso (GFL) permettrait de pouvoir palier au problème de la corrélation entre sites. Celui-ci reprend le modèle logistique précédent, mais ajoute deux pénalisations sur les coefficients β_{ij} : une pénalité de type Lasso, qui contraint les coefficients à être nuls si le SNP j n’est pas suffisamment associé au site viral i , et une pénalité de fusion sur graphe, qui contraint les coefficients à être similaires lorsque les sites viraux i et i' sont corrélés.

Le modèle s’écrit alors, pour un SNP j fixé :

$$\hat{\beta}_{\cdot j} = \underset{\beta_{\cdot j}}{\operatorname{argmin}} \left\{ - \sum_{i=1}^p \ell_i(\beta_{ij}) + \lambda_1 \sum_{i=1}^p |\beta_{ij}| + \lambda_2 \sum_{(i,i') \in E} w_{ii'} |\beta_{ij} - \beta_{i'j}| \right\}$$

où $\ell_i(\beta_{ij})$ est la log-vraisemblance logistique associée au site viral i , E l’ensemble des arêtes

du graphe de corrélation entre sites viraux, $w_{ii'}$ le poids de l'arête reliant les sites i et i' , et λ_1 , λ_2 les paramètres de régularisation contrôlant respectivement la sparsité et l'homogénéité locale des coefficients sur le graphe.

4.1.1 Construction du graphe de corrélation

Afin d'implémenter ce modèle, il est nécessaire de construire un graphe représentant les corrélations entre sites viraux. Les sites viraux étant binaires, ils sont supposés suivre une loi de Bernoulli, ce qui permet d'estimer leur corrélation de façon paramétrique. Pour deux sites viraux i et i' , de probabilités marginales p_i et $p_{i'}$ et de probabilité jointe $p_{ii'} = P(Y_i = 1, Y_{i'} = 1)$, la corrélation s'écrit :

$$w_{ii'} = \text{corr}(Y_i, Y_{i'}) = \frac{p_{ii'} - p_i p_{i'}}{\sqrt{p_i(1-p_i)p_{i'}(1-p_{i'})}}$$

La matrice de corrélation ainsi obtenue sert de support au graphe : une arête est créée entre deux sites viraux lorsque leur corrélation dépasse un seuil fixé. La Figure 3 représente cette matrice sous forme de heatmap, où les valeurs proches de 1 sont en rouge et celles proches de 0 en jaune.




FIGURE 3 – Matrice de corrélation entre sites viraux sous forme de heatmap.

4.1.2 Choix des paramètres de régularisation

Il reste à définir les paramètres de régularisation λ_1 et λ_2 . Une validation croisée sur l'ensemble des données étant impossible à mettre en œuvre dans ce contexte de très haute dimensionnalité, elle a été réalisée sur plusieurs sous-ensembles de données, et les résultats ont ensuite été moyennés pour obtenir les paramètres optimaux. On obtient ainsi $\lambda_1 = XX$ et $\lambda_2 = XX$.

4.1.3 Optimisation du modèle : algorithme FISTA

L'estimation des coefficients du modèle revient à minimiser la fonction objectif présentée précédemment, qui se décompose en une partie lisse et une partie non lisse :

$$F(\beta) = \underbrace{f(\beta)}_{\text{log-vraisemblance logistique}} + \underbrace{g(\beta)}_{\text{pénalités}}, \quad g(\beta) = \lambda_1 \sum_{i=1}^p |\beta_{ij}| + \lambda_2 \sum_{(i,i') \in E} w_{ii'} |\beta_{ij} - \beta_{i'j}|$$

où f est convexe et différentiable, mais où g est convexe et non différentiable en raison des valeurs absolues. Cette fonction ne possède pas de solution analytique et doit donc être minimisée numériquement.

Pour cela, nous utilisons l'algorithme FISTA (Fast Iterative Shrinkage-Thresholding Algorithm) [?], particulièrement adapté aux problèmes de la forme $\min_{\beta} f(\beta) + g(\beta)$ lorsque f est différentiable à gradient L -Lipschitzien et g admet un opérateur proximal calculable. C'est la méthode principalement utilisée dans les packages R qui implémentent les modèles de type Lasso.

Étape de descente de gradient. À chaque itération k , l'algorithme réalise d'abord un pas de gradient sur la partie lisse f , évalué non pas en β_k mais en un point extrapolé $\mathbf{y}_k$:

$$\mathbf{z}_k = \mathbf{y}_k - \frac{1}{L} \nabla f(\mathbf{y}_k)$$

où $\nabla f(\mathbf{y}_k)$ est le gradient de la log-vraisemblance logistique, de la forme $\mathbf{X}^\top (\mathbf{p}(\mathbf{y}_k) - \mathbf{Y})$, avec $\mathbf{p}(\mathbf{y}_k)$ le vecteur des probabilités prédites $\text{logit}^{-1}(\mathbf{X}\mathbf{y}_k)$, et L une constante de Lipschitz du gradient (majorée ici par la plus grande valeur propre de $\mathbf{X}^\top \mathbf{X}/4$), qui fixe la taille du pas.

Étape de seuillage (opérateur proximal). Le point $\mathbf{z}_k$ est ensuite projeté via l'opérateur proximal de g , défini par :

$$\text{prox}_{g/L}(\mathbf{z}_k) = \underset{\beta}{\text{argmin}} \left\{ \frac{L}{2} \|\beta - \mathbf{z}_k\|_2^2 + g(\beta) \right\}$$

Pour la seule pénalité ℓ_1 , cet opérateur a une solution explicite, le seuillage doux (*soft-thresholding*) :

$$[\text{prox}_{\lambda_1/L, \|\cdot\|_1}(z)]_i = \text{sign}(z_i) \max(|z_i| - \lambda_1/L, 0)$$

qui annule progressivement les coefficients de faible amplitude, ce qui permet de sélectionner uniquement les mutations virales les plus associées au SNP étudié. En présence de la pénalité de fusion sur graphe, l'opérateur proximal combiné $\text{prox}_{g/L}$ n'a plus de forme close et est résolu par

Étape d'accélération. Enfin, FISTA ajoute une étape d'extrapolation de type Nesterov, en combinant les deux dernières estimations β_k et β_{k-1} :

$$\beta_k = \text{prox}_{g/L}(\mathbf{z}_k), \quad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \quad \mathbf{y}_{k+1} = \beta_k + \frac{t_k - 1}{t_{k+1}} (\beta_k - \beta_{k-1})$$

avec $t_1 = 1$ et $\mathbf{y}_1 = \beta_0$. Cette accélération permet d'obtenir une vitesse de convergence en $\mathcal{O}(1/k^2)$, contre $\mathcal{O}(1/k)$ pour l'algorithme ISTA classique (sans extrapolation), tout en conservant une implémentation relativement simple. Cette propriété est particulièrement intéressante dans notre contexte, où le modèle doit être estimé pour un très grand nombre de SNPs et de sites viraux.

Cependant, dans le contexte de très haute dimensionnalité des données, l'algorithme FISTA met un temps de calcul très long pour converger.

En effet, après avoir testé sur un sous-ensemble de données afin de pouvoir estimer le temps d'implémentation sur l'ensemble des données, on a pu constater un temps de calcul de plusieurs mois pour l'ensemble du jeu de données.

De plus, l'algorithme FISTA ne peut pas être parallélisé du à la dépendance entre les sites qui impose de calculer les coefficients simultanément.

Il est donc nécessaire de trouver une alternative à cette approche afin de pouvoir estimer le modèle sur l'ensemble des données.

4.2 Modèle avec effets aléatoires

Le modèle GFL présenté précédemment permet de prendre en compte la corrélation locale entre sites, mais uniquement via un graphe construit. Il ne modélise pas la structure globale de parenté génétique au sein des populations hôte et virale, pourtant décrite comme un facteur de confusion majeur dans les études d'interaction génome-à-génome [?]. Une approche alternative, largement utilisée dans les études d'association (GWAS) classiques, consiste à modéliser cette structure via des **effets aléatoires**, plutôt que par un nombre limité de composantes principales ou un graphe de corrélation. Cette stratégie a notamment été adaptée dans un contexte similaire par [?] au travers de la méthode ATOMM (*Adaptive Two-way Mixed Model*), qui introduit un effet aléatoire distinct pour l'hôte et pour le virus.

En reprenant cette idée, le modèle logistique s'écrit alors comme un modèle mixte linéaire généralisé (GLMM) à deux effets aléatoires :

$$\text{logit}(P(Y_i = 1)) = \beta_0 + W\alpha + X_j\beta_{ij} + \eta_v + \eta_h$$

où $W\alpha$ regroupe les effets fixes (covariables telles que l'âge ou le sexe), $X_j\beta_{ij}$ représente l'effet du SNP j sur le site viral i , et les deux effets aléatoires

$$\eta_v \sim \mathcal{N}(0, \sigma_v^2 K_v), \quad \eta_h \sim \mathcal{N}(0, \sigma_h^2 K_h)$$

capturent respectivement la structure de parenté génomique du virus et de l'hôte, via les matrices de parenté génomique K_v et K_h .

Contrairement aux composantes principales, ces matrices résument l'intégralité de la similarité génétique entre individus (ou souches), sans perte d'information liée à un nombre de dimensions fixé a priori.

Dans ce cadre, l'intérêt principal n'est plus seulement d'estimer les coefficients du modèle, mais de tester la significativité de l'association entre chaque SNP de l'hôte j et chaque site viral i , c'est-à-dire tester " $H_0 : \beta_{ij} = 0$ ". Or, ce test doit être répété pour un très grand nombre de paires SNP-site viral, et une estimation classique du modèle par maximum de vraisemblance nécessiterait de réinverser la matrice de covariance globale à chaque test, ce qui est numériquement impossible à l'échelle de nos données. Il est donc nécessaire d'utiliser une méthode d'estimation factorisée, qui sépare l'estimation des paramètres de nuisance (communs à tous les tests) de celle du test d'association lui-même : le test du score de Rao.

4.2.1 Estimation - Test du score de Rao

L'évaluation de chaque paires de variants (hôte, virus) implique d'ajuster le modèle mixte des millions de fois. Or, l'estimation des composantes de la variance (σ_v^2 , σ_h^2) par maximum de vraisemblance nécessite l'inversion répétée de matrices de grande dimension, ce qui représente un coût computationnel important.

Concrètement, la procédure se déroule en deux étapes :

1. **Ajustement sous H_0** : On force le coefficient d'intérêt β_{ij} à 0. Le modèle nul ne contenant que l'intercept, les covariables et les effets aléatoires est ajusté une seule fois par phénotype viral pour estimer les paramètres de nuisance et les composantes de la variance.
2. **Calcul du score** : Pour chaque variant de l'hôte j , on évalue le gradient de la log-vraisemblance au point $\beta_{ij} = 0$. Si ce gradient est significativement éloigné de zéro, l'hypothèse nulle est rejetée, indiquant une association entre X_j et Y_i .

Cette méthode permet d'éviter le réajustement des effets aléatoires pour chaque SNP testé, réduisant ainsi drastiquement la complexité algorithmique tout en conservant une grande robustesse statistique.

La contre partie de ce test est qu'il ne fournit pas d'estimation directe de l'effet β_{ij} , mais uniquement une statistique de test et une p value associée. Cependant, dans le contexte d'une étude exploratoire visant à identifier des associations potentielles, cette limitation est acceptable. Néanmoins, pour les associations les plus prometteuses, il est possible de réajuster le modèle complet afin d'obtenir des estimations précises des effets et de leurs intervalles de confiance.

Il existe quand même des façons d'obtenir une estimation de l'effet β_{ij} à l'aide des p-values.

5 Résultats et discussion

5.1 Choix du codage

5.2 Comparaison des modèles

5.3 Performances du modèle retenu

6 Conclusion et perspectives

7 Annexes

7.1 Annexe 1

8 Bibliographie