



**UNIVERSITÉ DE
MONTPELLIER**



**STATISTIQUE
SCIENCE DES DONNÉES**
UNIVERSITÉ DE MONTPELLIER

MASTER II STATISTIQUES ET SCIENCES DES DONNÉES

Parcours Biostatistique

Identification des déterminants génétiques de la pathogénicité de la dengue

Présenté par :
Damien MARIAC

Encadré par :
Vincent PEDERGNANA

Tuteur FdS :
Ludovic Menneteau

Jury :
Élodie BRUNEL-PICCININI
Xavier BRY
Benoite DE SAPORTA

Année universitaire 2025-2026



Table des matières

1	Environnement	2
2	Context	3
2.1	Context du sujet	3
2.2	Context biologique	3
2.3	Extraction des données	3
3	Préparation des données	4
3.1	Alignement	4
3.2	Traitement des valeurs manquantes	4
4	Modélisation statistique	5
4.0.1	Modèle d'association "classique"	5
4.0.2	Limites du modèle "classique"	6
4.1	Modèle avec dépendances : Graph Fused Lasso	6
4.1.1	Construction du graphe de corrélation	7
4.1.2	Choix des paramètres de régularisation	7
4.1.3	Optimisation du modèle : algorithme FISTA	7
4.2	Modèle avec effets aléatoires	7
4.2.1	Estimation - Test du score de Rao	7
5	Résultats et discussion	8
5.1	Choix du codage	8
5.2	Comparaison des modèles	8
5.3	Performances du modèle retenu	8
6	Conclusion et perspectives	9
7	Annexes	10
7.1	Annexe 1	10
8	Bibliographie	11

1 Environnement

Bla bla sur la laboratoire et sur l'UMR MIVEGEC.

2 Context

2.1 Context du sujet

D'un individu à un autre, les symptômes d'une infection virale peuvent varier allant d'une absence de symptômes à des formes sévères. Cette variabilité est en partie due à la diversité génétique de l'hôte et du virus. L'objectif de cette étude est de proposer de nouveaux modèles permettant de faciliter l'étude d'associations entre les variants génétiques de l'hôte et les mutations virales, afin de mieux comprendre les mécanismes des réponses immunitaires.

Historiquement, les études d'association sont menées sur les symptômes eux-mêmes. Mais ceux-ci sont souvent largement influencés par des facteurs tels que l'environnement, l'alimentation ou les habitudes physiques.

Il existe depuis quelques années une variante de cette approche qui consiste à considérer le code génétique du virus comme symptôme. L'idée est que les mutations virales sont le reflet de la pression de sélection exercée par le système immunitaire de l'hôte. Ainsi, en identifiant les variants génétiques de l'hôte associés à certaines mutations virales, on peut obtenir des informations sur les mécanismes immunitaires impliqués dans la réponse à l'infection.

Ce qui fait toute la difficulté de cette approche est la haute dimensionnalité des données. En effet, on a du côté des hôtes des centaines de milliers de variants génétiques et du côté des virus des centaines de mutations après avoir filtré les sites dépassant un certain taux de variabilité. De plus, les individus issus de régions géographiques et d'ethnies différentes présentent des différences génétiques ce qui biaise les résultats d'association. Il est donc nécessaire de prendre en compte la structure de population des hôtes. Mais il est également nécessaire de prendre en compte la structure de population des virus. En effet, les virus issus d'une même région géographique ou d'une même lignée évolutive partagent des mutations communes. Il est donc nécessaire de prendre en compte la structure de population des virus.

2.2 Context biologique

Le virus est une entité biologique qui ne peut pas se reproduire par elle-même. Il a besoin d'un hôte pour se multiplier et se propager. Il est constitué d'une coque qui protège son matériel génétique, qui peut être de l'ADN ou de l'ARN. La nature du support de l'information ADN ou ARN dicte la réplication, ce qui a un impact majeur sur sa diversité génétique. De ce fait, les virus à ARN ont un taux de mutation beaucoup plus élevé que les virus à ADN. Cela est dû au fait que l'ARN polymérase, l'enzyme responsable de la réplication de l'ARN, n'a pas de mécanisme de correction d'erreurs contrairement à l'ADN polymérase. Cette haute variance est fondamentale : elle permet au virus de s'adapter très rapidement pour trouver des solutions face aux défenses de l'hôte.

Dans le cadre de ce stage, nous avons travaillé sur le virus de l'hépatite C dont on a déjà identifié des liaisons afin de pouvoir l'étendre sur le virus de la dengue. Ce sont tous deux des virus à ARN qui présentent une grande diversité génétique.

2.3 Extraction des données

3 Préparation des données

3.1 Alignement

3.2 Traitement des valeurs manquantes

4 Modélisation statistique

4.0.1 Modèle d'association “classique”

Le modèle proposé par [?] vise à modéliser la probabilité d'une mutation virale en fonction d'un SNP de l'hôte et de covariables telles que l'âge et le sexe. Pour un site viral et un SNP donnés, une régression logistique est ajustée indépendamment, et ce pour l'ensemble des paires SNP–site viral.

Afin de corriger la structure de population, les auteurs incluent les composantes principales (CP) de l'hôte et du virus comme effets fixes. En effet, les premières CP de l'hôte capturent l'origine ethnique des individus [?], et les premières CP du virus capturent l'origine géographique des souches [?] (Figure 1).




FIGURE 1 – Structure de population capturée par l'ACP.

Les auteurs retiennent les 10 premières CP de l'hôte et les 5 premières du virus. Ce choix reste discutable : ces composantes ne capturent respectivement que XX % et 12 % de la variance cumulée, ce qui suggère qu'une part importante de la structure de population n'est pas corrigée.

Le modèle s'écrit finalement, pour un SNP j et un site viral i fixés :

$$\text{logit}(P(Y_i = 1)) = \beta_0 + \beta_{ij} \text{SNP}_j + \sum_{k=1}^{10} \gamma_k PC_k^{\text{hôte}} + \sum_{l=1}^5 \delta_l PC_l^{\text{virus}}$$

Une p-value est extraite pour chaque test SNP–site viral. Les tests étant menés indépendamment sur un très grand nombre de paires, une correction pour tests multiples est nécessaire afin de limiter les faux positifs : les auteurs utilisent une correction de Bonferroni, avec un seuil de significativité $\alpha = 10^{-8}$.

Afin de pouvoir représenter les résultats, on peut construire un *Manhattan plot*. Celui-ci est un graphique qui représente les p-values de chaque SNP pour un site viral donné.




FIGURE 2 – Manhattan plot pour un site viral donné.

4.0.2 Limites du modèle “classique”

Ce modèle présente plusieurs limites ce qui motivent le développement d’une approche plus adaptée à ce type de données.

D’abord, il ne capture qu’une fraction de la structure de population : se limiter à quelques composantes principales, en plus d’ignorer une part importante de la variance, ne permet pas de représenter plus précisément la dépendance génétique entre individus (côté hôte) ou entre souches (côté virus).

Ensuite, il ignore la corrélation entre sites : les mutations virales peuvent être corrélées entre elles du fait de leur proximité structurale (conformation 3D de la protéine), et les SNPs de l’hôte proches sur le génome sont corrélés par déséquilibre de liaison. Ne pas modéliser ces dépendances revient à traiter chaque test comme indépendant alors qu’il ne l’est pas, ce qui biaise l’estimation de la significativité.

Puis, la correction de Bonferroni, en supposant l’indépendance des tests, est très conservatrice dans ce contexte de forte corrélation : elle risque d’écraser un signal réel, en particulier étant donné la très haute dimensionnalité des données (des millions de tests SNP–site viral).

4.1 Modèle avec dépendances : Graph Fused Lasso

Un modèle de type Graph Fused Lasso (GFL) permettrait de pouvoir palier au problème de la corrélation entre sites. Celui-ci reprend le modèle logistique précédent, mais ajoute deux pénalisations sur les coefficients β_{ij} : une pénalité de type Lasso, qui contraint les coefficients à être nuls si le SNP j n’est pas suffisamment associé au site viral i , et une pénalité de fusion sur graphe, qui contraint les coefficients à être similaires lorsque les sites viraux i et i' sont corrélés.

Le modèle s’écrit alors, pour un SNP j fixé :

$$\hat{\beta}_{\cdot j} = \underset{\beta_{\cdot j}}{\operatorname{argmin}} \left\{ - \sum_{i=1}^p \ell_i(\beta_{ij}) + \lambda_1 \sum_{i=1}^p |\beta_{ij}| + \lambda_2 \sum_{(i,i') \in E} w_{ii'} |\beta_{ij} - \beta_{i'j}| \right\}$$

où $\ell_i(\beta_{ij})$ est la log-vraisemblance logistique associée au site viral i , E l’ensemble des arêtes

du graphe de corrélation entre sites viraux, $w_{ii'}$ le poids de l'arête reliant les sites i et i' , et λ_1 , λ_2 les paramètres de régularisation contrôlant respectivement la sparsité et l'homogénéité locale des coefficients sur le graphe.

4.1.1 Construction du graphe de corrélation

Afin d'implémenter ce modèle, il est nécessaire de construire un graphe représentant les corrélations entre sites viraux. Les sites viraux étant binaires, ils sont supposés suivre une loi de Bernoulli, ce qui permet d'estimer leur corrélation de façon paramétrique. Pour deux sites viraux i et i' , de probabilités marginales p_i et $p_{i'}$ et de probabilité jointe $p_{ii'} = P(Y_i = 1, Y_{i'} = 1)$, la corrélation s'écrit :

$$w_{ii'} = \text{corr}(Y_i, Y_{i'}) = \frac{p_{ii'} - p_i p_{i'}}{\sqrt{p_i(1-p_i)p_{i'}(1-p_{i'})}}$$

La matrice de corrélation ainsi obtenue sert de support au graphe : une arête est créée entre deux sites viraux lorsque leur corrélation dépasse un seuil fixé. La Figure ?? représente cette matrice sous forme de heatmap, où les valeurs proches de 1 sont en rouge et celles proches de 0 en jaune.

4.1.2 Choix des paramètres de régularisation

Il reste à définir les paramètres de régularisation λ_1 et λ_2 . Une validation croisée sur l'ensemble des données étant impossible à mettre en œuvre dans ce contexte de très haute dimensionnalité, elle a été réalisée sur plusieurs sous-ensembles de données, et les résultats ont ensuite été moyennés pour obtenir les paramètres optimaux. On obtient ainsi $\lambda_1 = XX$ et $\lambda_2 = XX$.

4.1.3 Optimisation du modèle : algorithme FISTA

Le problème d'optimisation est résolu par l'algorithme FISTA (Fast Iterative Shrinkage-Thresholding Algorithm) [?], une méthode itérative adaptée aux problèmes convexes dont la fonction de coût comporte une partie différentiable (ici la log-vraisemblance logistique) et une partie non différentiable (ici les pénalités ℓ_1 et de fusion sur graphe).

En effet, à chaque itération, FISTA effectue un pas de descente de gradient sur la partie différentiable de la fonction de coût, puis applique un opérateur proximal à la partie non différentiable pour imposer la sparsité et l'homogénéité des coefficients sur le graphe. Un terme d'accélération de type Nesterov est ensuite ajouté, ce qui permet à FISTA de converger plus rapidement que l'algorithme ISTA classique, tout en conservant sa simplicité d'implémentation.

4.2 Modèle avec effets aléatoires

4.2.1 Estimation - Test du score de Rao

5 Résultats et discussion

5.1 Choix du codage

5.2 Comparaison des modèles

5.3 Performances du modèle retenu

6 Conclusion et perspectives

7 Annexes

7.1 Annexe 1

8 Bibliographie