



**UNIVERSITÉ DE
MONTPELLIER**



**STATISTIQUE
SCIENCE DES DONNÉES**
UNIVERSITÉ DE MONTPELLIER

MASTER II STATISTIQUES ET SCIENCES DES DONNÉES

Parcours Biostatistique

Identification des déterminants génétiques de la pathogénicité de la dengue

Présenté par :
Damien MARIAC

Encadré par :
Vincent PEDERGNANA

Tuteur FdS :
Ludovic Menneteau

Jury :
Élodie BRUNEL-PICCININI
Xavier BRY
Benoite DE SAPORTA

Année universitaire 2025-2026



Table des matières

1	Environnement	2
2	Context	3
2.1	Context du sujet	3
2.2	Context biologique	3
3	Préparation des données	4
3.1	Le séquençage viral	4
3.2	Alignements multiples de séquences	5
3.2.1	Alignement progressif par rapport à une séquence de référence	5
3.2.2	Matrices de substitution	5
3.2.3	Pénalités de gap	6
3.3	Traitement des valeurs manquantes	6
4	Modélisation statistique	7
4.0.1	Modèle d’association “classique”	7
4.0.2	Limites du modèle “classique”	8
4.1	Modèle avec dépendances : Graph Fused Lasso	8
4.1.1	Construction du graphe de corrélation	9
4.1.2	Choix des paramètres de régularisation	9
4.1.3	Optimisation du modèle : algorithme FISTA	10
4.2	Modèle avec effets aléatoires	11
4.2.1	Estimation - Test du score de Rao	12
5	Résultats et discussion	13
5.1	Choix du codage	13
5.2	Comparaison des modèles	13
5.3	Performances du modèle retenu	13
6	Conclusion et perspectives	14
7	Annexes	15
7.1	Annexe 1	15
8	Bibliographie	16

1 Environnement

Bla bla sur la laboratoire et sur l'UMR MIVEGEC.

2 Context

2.1 Context du sujet

D'un individu à un autre, les symptômes d'une infection virale peuvent varier allant d'une absence de symptômes à des formes sévères. Cette variabilité est en partie due à la diversité génétique de l'hôte et du virus. L'objectif de cette étude est de proposer de nouveaux modèles permettant de faciliter l'étude d'associations entre les variants génétiques de l'hôte et les mutations virales, afin de mieux comprendre les mécanismes des réponses immunitaires.

Historiquement, les études d'association sont menées sur les symptômes eux mêmes. Mais ceux-ci sont souvent largement influencés par des facteurs tels que l'environnement, l'alimentation ou les habitudes physiques.

Il existe depuis quelques années une variante de cette approche qui consiste à considérer le code génétique du virus comme symptôme. L'idée est que les mutations virales sont le reflet de la pression de sélection exercée par le système immunitaire de l'hôte. Ainsi, en identifiant les variants génétiques de l'hôte associés à certaines mutations virales, on peut obtenir des informations sur les mécanismes immunitaires impliqués dans la réponse à l'infection.

Ce qui fait toute la difficulté de cette approche est la haute dimensionnalité des données. En effet, on a du côté des hôtes des centaines de milliers de variants génétiques et du côté des virus des centaines de mutations après avoir filtré les sites dépassant un certain taux de variabilité. De plus, les individus issus de régions géographiques et d'ethnies différentes présentent des différences génétiques ce qui biaise les résultats d'association. Il est donc nécessaire de prendre en compte la structure de population des hôtes. Mais il est également nécessaire de prendre en compte la structure de population des virus. En effet, les virus issus d'une même région géographique ou d'une même lignée évolutive partagent des mutations communes. Il est donc nécessaire de prendre en compte la structure de population des virus.

2.2 Context biologique

Le virus est une entité biologique qui ne peut pas se reproduire par elle-même. Il a besoin d'un hôte pour se multiplier et se propager. Il est constitué d'une coque qui protège son matériel génétique, qui peut être de l'ADN ou de l'ARN. La nature du support de l'information ADN ou ARN dicte la réplication, ce qui a un impact majeur sur sa diversité génétique. De ce fait, les virus à ARN ont un taux de mutation beaucoup plus élevé que les virus à ADN. Cela est dû au fait que l'ARN polymérase, l'enzyme responsable de la réplication de l'ARN, n'a pas de mécanisme de correction d'erreurs contrairement à l'ADN polymérase. Cette haute variance est fondamentale : elle permet au virus de s'adapter très rapidement pour trouver des solutions face aux défenses de l'hôte.

Dans le cadre de ce stage, nous avons travaillé sur le virus de l'hépatite C dont on a déjà identifié des liaisons afin de pouvoir l'étendre sur le virus de la dengue. Ce sont tous deux des virus à ARN qui présentent une grande diversité génétique.

3 Préparation des données

Cette partie détaille les étapes de collecte, d'alignement des séquences virales et de gestion des données manquantes faites avant toute modélisation statistique.

Les données utilisées dans ce type d'étude nécessitent l'acquisition simultanée d'informations génétiques sur le pathogène et sur son hôte. Les échantillons biologiques consistent généralement en des prélèvements sanguins effectués chez les patients infectés. Pour le génome viral, l'ARN de l'HCV est extrait à partir du plasma sanguin des patients. Ce matériel est ensuite amplifié et séquencé à l'aide de technologies de séquençage, ce qui permet de capturer l'ensemble des variants présents chez un individu et d'en dégager une séquence consensus par patient.

3.1 Le séquençage viral

Pour analyser le génome du virus présent chez un patient, il est important de comprendre comment les données génétiques sont techniquement lues par les machines (les séquenceurs).

Contrairement à ce que l'on pourrait penser, un séquenceur ne lit pas le génome du virus d'une seule traite, de la première à la dernière « lettre » (nucléotide). Les technologies modernes de séquençage à haut débit procèdent différemment : elles découpent l'ARN viral en des millions de minuscules fragments, appelés des *reads*. La machine va ensuite lire ces petits fragments de manière individuelle et désordonnée. Pour se représenter ce processus, on peut imaginer un livre (le génome viral) qui serait passé dans une déchiqueteuse à papier. On se retrouve avec des milliers de petites bandes de papier contenant chacune quelques mots. Pour reconstituer l'histoire, un algorithme informatique va comparer ces bandes, chercher les mots qui se chevauchent, et les aligner les unes par rapport aux autres, souvent en s'aidant d'un « texte de référence » connu (comme la séquence externe H77 pour le HCV).

Puisque nous avons généré des millions de petits fragments à partir de milliers de copies du virus présentes dans le sang du patient, un « mot » spécifique du livre ne sera pas lu une seule fois, mais des dizaines, voire des centaines de fois.




FIGURE 1 – Représentation schématique de l'alignement des lectures (*reads*) sur une séquence de référence.

Lorsqu'on observe un site précis du génome (par exemple, la position 1450), on constate que de nombreux petits fragments se superposent à cet endroit. Le nombre total de fragments qui couvrent une position donnée définit sa profondeur.

La profondeur est une information cruciale puisqu'elle permet la correction des erreurs. Les séquenceurs font parfois des erreurs de lecture. Si un seul fragment indique une mutation à une position, il peut s'agir d'un artefact technique. En revanche, si la profondeur est de 100 et que 99 fragments indiquent cette même mutation, nous avons la certitude statistique qu'elle est réelle.

Ainsi, l'alignement de cette multitude de petits fragments n'est pas un défaut technique, mais une nécessité qui donne tout son relief et sa fiabilité à l'analyse génétique du virus.

3.2 Alignements multiples de séquences

L'alignement multiple de séquences (MSA) consiste à disposer simultanément plusieurs séquences biologiques (nucléotidiques ou protéiques) de manière à faire correspondre les positions homologues, c'est-à-dire dérivées d'un ancêtre commun au cours de l'évolution. Contrairement à l'alignement par paires (deux séquences), l'alignement multiple permet d'identifier des régions conservées, des motifs fonctionnels ou structuraux communs à un ensemble de séquences, et sert de base à des analyses phylogénétiques.

Il s'agit d'un problème de haute complexité algorithmique : trouver l'alignement optimal de N séquences exacte a une complexité qui croît exponentiellement avec le nombre de séquences, de l'ordre de $O(L^N)$ pour N séquences de longueur L . Pour cette raison, des méthodes heuristiques sont généralement utilisées en pratique.

3.2.1 Alignement progressif par rapport à une séquence de référence

Dans notre cas, nous avons réalisé un alignement progressif basé sur une séquence de référence.

Cette approche consiste dans un premier temps à choisir une séquence de référence (souvent la plus longue, la plus représentative, ou une séquence d'intérêt particulier ou consensus).

Puis aligner successivement chaque autre séquence du jeu de données contre cette référence, par alignement deux à deux.

Enfin, fusionner progressivement ces alignements par paires en un alignement multiple global, en insérant des gaps (-) aux positions nécessaires pour maintenir la cohérence des colonnes entre toutes les séquences.

Cette stratégie est une simplification efficace par rapport aux méthodes progressives classiques (type ClustalW) qui construisent d'abord un arbre guide (*guide tree*) à partir des similarités deux à deux, puis alignent les séquences en suivant cet arbre. L'approche par référence unique est plus rapide, mais suppose que la séquence de référence est suffisamment représentative pour bien guider l'alignement de l'ensemble des autres séquences.

3.2.2 Matrices de substitution

Pour évaluer la qualité d'un alignement, et guider les alignements par paires sous-jacents, nous avons utilisé une matrice de substitution, qui attribue un score à chaque paire de caractères alignés :

- **Séquences protéiques** : matrices de type BLOSUM (*BLOcks SUBstitution Matrix*, ex. BLOSUM62) ou PAM (*Point Accepted Mutation*). Ces matrices sont dérivées empiriquement des fréquences observées de substitutions d'acides aminés au sein de familles de protéines apparentées. Un score positif élevé indique une substitution fréquente et

conservative (acides aminés aux propriétés physico-chimiques proches), tandis qu'un score négatif indique une substitution rare ou défavorable.

Dans notre cas, la matrice BLOSUM62 a été utilisée pour scorer chaque paire de résidus alignés. Chaque case (i, j) de la matrice donne le score de substitution de l'acide aminé i par l'acide aminé j , calculé à partir du logarithme du rapport entre la fréquence observée de la paire dans des blocs de séquences protéiques alignées et la fréquence attendue sous hypothèse d'indépendance :

$$S(i, j) = \frac{1}{\lambda} \ln \left(\frac{q_{ij}}{p_i p_j} \right)$$

où q_{ij} est la fréquence observée de la paire (i, j) dans les blocs conservés, p_i et p_j les fréquences individuelles des acides aminés i et j , et λ un facteur d'échelle. Un score positif traduit ainsi une substitution plus fréquente qu'attendue par hasard (souvent entre résidus aux propriétés physico-chimiques proches, par exemple entre deux acides aminés hydrophobes), tandis qu'un score négatif traduit une substitution défavorable ou rare au regard de l'évolution des familles de protéines.

3.2.3 Pénalités de gap

Enfin, l'algorithme d'alignement utilisé (de type Needleman-Wunsch, pour un alignement global) intègre une pénalité d'ouverture de gap (un trou dans la séquence) ainsi qu'une éventuelle pénalité d'extension de gap (une suite de trous), afin d'éviter la multiplication de petites insertions/délétions dispersées et de favoriser des gaps regroupés, biologiquement plus plausibles (une seule insertion/délétion plutôt que plusieurs événements ponctuels indépendants).

3.3 Traitement des valeurs manquantes

La présence de valeurs manquantes est inhérente aux limites techniques du séquençage et du génotypage, notamment aux erreurs de lecture. Dans le cadre des modèles mixtes (GLMM) utilisés pour les tests d'association (voir plus bas), ces données manquantes bloquent les calculs d'algèbre linéaire, comme l'inversion des matrices de parenté. Le traitement appliqué dépend donc du type de codage retenu pour le jeu de données.

Afin de rester cohérent avec un codage initialement binaire, les valeurs manquantes ont été imputées par la modalité la plus fréquente. Ce choix évite d'obtenir des valeurs différentes de 0 ou 1, ce qui aurait pu compromettre les modèles logistiques, tout en conservant une puissance statistique suffisante lors du recodage par transition d'acide aminé (voir section suivante). Cette approche permet enfin de disposer d'un support commun pour comparer les différentes méthodes entre elles.

4 Modélisation statistique

Dans cette approche *Genome-to-Genome* (GxG), le but est d’identifier des variants génétiques de l’hôte qui influencent l’évolution du génome viral. Cette problématique relève naturellement de modèle supervisé : les caractéristiques génétiques de l’hôte constituent les variables explicatives, tandis que les mutations observées chez le virus représentent les variables à expliquer. Contrairement à une approche non supervisée, qui se limite à décrire les structures présentes dans les données, un modèle supervisé permet de mettre en évidence des associations statistiques entre les deux génomes tout en tenant compte d’éventuels facteurs de confusion, tels que la stratification des populations hôtes et virus ou de caractère propre à l’individu.

4.0.1 Modèle d’association “classique”

Le modèle proposé par [?] vise à modéliser la probabilité d’une mutation virale en fonction d’un SNP de l’hôte et de covariables telles que l’âge et le sexe. Pour un site viral et un SNP donnés, une régression logistique est ajustée indépendamment, et ce pour l’ensemble des paires SNP–site viral.

Afin de corriger la structure de population, les auteurs incluent les composantes principales (CP) de l’hôte et du virus comme effets fixes. En effet, les premières CP de l’hôte capturent l’origine ethnique des individus [?], et les premières CP du virus capturent l’origine géographique des souches [?] (Figure 2).




FIGURE 2 – Structure de population capturée par l’ACP.

Les auteurs retiennent les 10 premières CP de l’hôte et les 5 premières du virus. Ce choix reste discutable : ces composantes ne capturent respectivement que XX % et 12 % de la variance cumulée, ce qui suggère qu’une part importante de la structure de population n’est pas corrigée.

Le modèle s’écrit finalement, pour un SNP j et un site viral i fixés :

$$\logit(P(Y_i = 1)) = \beta_0 + \beta_{ij} \text{SNP}_j + \sum_{k=1}^{10} \gamma_k PC_k^{\text{hôte}} + \sum_{l=1}^5 \delta_l PC_l^{\text{virus}}$$

Une p-value est extraite pour chaque test SNP–site viral. Les tests étant menés indépendamment sur un très grand nombre de paires, une correction pour tests multiples est nécessaire afin de limiter les faux positifs : les auteurs utilisent une correction de Bonferroni, avec un seuil de significativité $\alpha = 10^{-8}$.

Afin de pouvoir représenter les résultats, on peut construire un *Manhattan plot*. Celui-ci est un graphique qui représente les p-values de chaque SNP pour un site viral donné.




FIGURE 3 – Manhattan plot pour un site viral donné.

4.0.2 Limites du modèle “classique”

Ce modèle présente plusieurs limites ce qui motivent le développement d’une approche plus adaptée à ce type de données.

D’abord, il ne capture qu’une fraction de la structure de population : se limiter à quelques composantes principales, en plus d’ignorer une part importante de la variance, ne permet pas de représenter plus précisément la dépendance génétique entre individus (côté hôte) ou entre souches (côté virus).

Ensuite, il ignore la corrélation entre sites : les mutations virales peuvent être corrélées entre elles du fait de leur proximité structurale (conformation 3D de la protéine), et les SNPs de l’hôte proches sur le génome sont corrélés par déséquilibre de liaison. Ne pas modéliser ces dépendances revient à traiter chaque test comme indépendant alors qu’il ne l’est pas, ce qui biaise l’estimation de la significativité.

Puis, la correction de Bonferroni, en supposant l’indépendance des tests, est très conservatrice dans ce contexte de forte corrélation : elle risque d’écraser un signal réel, en particulier étant donné la très haute dimensionnalité des données (des millions de tests SNP–site viral).

4.1 Modèle avec dépendances : Graph Fused Lasso

Un modèle de type Graph Fused Lasso (GFL) permettrait de pouvoir palier au problème de la corrélation entre sites. Celui-ci reprend le modèle logistique précédent, mais ajoute deux pénalisations sur les coefficients β_{ij} : une pénalité de type Lasso, qui contraint les coefficients à être nuls si le SNP j n’est pas suffisamment associé au site viral i , et une pénalité de fusion sur graphe, qui contraint les coefficients à être similaires lorsque les sites viraux i et i' sont corrélés.

Le modèle s’écrit alors, pour un SNP j fixé :

$$\hat{\beta}_{\cdot j} = \underset{\beta_{\cdot j}}{\operatorname{argmin}} \left\{ - \sum_{i=1}^p \ell_i(\beta_{ij}) + \lambda_1 \sum_{i=1}^p |\beta_{ij}| + \lambda_2 \sum_{(i,i') \in E} w_{ii'} |\beta_{ij} - \beta_{i'j}| \right\}$$

où $\ell_i(\beta_{ij})$ est la log-vraisemblance logistique associée au site viral i , E l’ensemble des arêtes

du graphe de corrélation entre sites viraux, $w_{ii'}$ le poids de l'arête reliant les sites i et i' , et λ_1 , λ_2 les paramètres de régularisation contrôlant respectivement la sparsité et l'homogénéité locale des coefficients sur le graphe.

4.1.1 Construction du graphe de corrélation

Afin d'implémenter ce modèle, il est nécessaire de construire un graphe représentant les corrélations entre sites viraux. Les sites viraux étant binaires, ils sont supposés suivre une loi de Bernoulli, ce qui permet d'estimer leur corrélation de façon paramétrique. Pour deux sites viraux i et i' , de probabilités marginales p_i et $p_{i'}$ et de probabilité jointe $p_{ii'} = P(Y_i = 1, Y_{i'} = 1)$, la corrélation s'écrit :

$$w_{ii'} = \text{corr}(Y_i, Y_{i'}) = \frac{p_{ii'} - p_i p_{i'}}{\sqrt{p_i(1-p_i)p_{i'}(1-p_{i'})}}$$

La matrice de corrélation ainsi obtenue sert de support au graphe : une arête est créée entre deux sites viraux lorsque leur corrélation dépasse un seuil fixé choisit arbitrairement à 0.7 (comme dans l'article [?]). La Figure 4 représente cette matrice sous forme de heatmap, où les valeurs proches de 1 sont en rouge et celles proches de 0 en jaune.




FIGURE 4 – Matrice de corrélation entre sites viraux sous forme de heatmap.

4.1.2 Choix des paramètres de régularisation

Il reste à définir les paramètres de régularisation λ_1 et λ_2 . Une validation croisée sur l'ensemble des données étant impossible à mettre en œuvre dans ce contexte de très haute dimensionnalité, elle a été réalisée sur plusieurs sous-ensembles de données, et les résultats ont ensuite été moyennés pour obtenir les paramètres optimaux. On obtient ainsi $\lambda_1 = XX$ et $\lambda_2 = XX$.

4.1.3 Optimisation du modèle : algorithme FISTA

L'estimation des coefficients du modèle revient à minimiser la fonction objectif présentée précédemment, qui se décompose en une partie lisse et une partie non lisse :

$$F(\beta) = \underbrace{f(\beta)}_{\text{log-vraisemblance}} + \underbrace{g(\beta)}_{\text{pénalités}}, \quad \text{où } g(\beta) = \lambda_1 \sum_{i=1}^p |\beta_{ij}| + \lambda_2 \sum_{(i,i') \in E} w_{ii'} |\beta_{ij} - \beta_{i'j}|$$

où f est convexe et différentiable, mais où g est convexe et non différentiable en raison des valeurs absolues. Cette fonction ne possède pas de solution analytique et doit donc être minimisée numériquement.

Pour cela, nous utilisons l'algorithme FISTA (Fast Iterative Shrinkage-Thresholding Algorithm) [?], particulièrement adapté aux problèmes de la forme $\min_{\beta} f(\beta) + g(\beta)$ lorsque f est différentiable à gradient L -Lipschitzien et g admet un opérateur proximal calculable. C'est la méthode principalement utilisée dans les packages R qui implémentent les modèles de type Lasso.

Étape de descente de gradient. À chaque itération k , l'algorithme réalise d'abord un pas de gradient sur la partie lisse f , évalué non pas en β_k mais en un point extrapolé $\mathbf{y}_k$:

$$\mathbf{z}_k = \mathbf{y}_k - \frac{1}{L} \nabla f(\mathbf{y}_k)$$

où $\nabla f(\mathbf{y}_k)$ est le gradient de la log-vraisemblance logistique, de la forme $\mathbf{X}^\top (\mathbf{p}(\mathbf{y}_k) - \mathbf{Y})$, avec $\mathbf{p}(\mathbf{y}_k)$ le vecteur des probabilités prédites $\text{logit}^{-1}(\mathbf{X}\mathbf{y}_k)$, et L une constante de Lipschitz du gradient (majorée ici par la plus grande valeur propre de $\mathbf{X}^\top \mathbf{X}/4$), qui fixe la taille du pas.

Étape de seuillage (opérateur proximal). Le point $\mathbf{z}_k$ est ensuite projeté via l'opérateur proximal de g , défini par :

$$\text{prox}_{g/L}(\mathbf{z}_k) = \underset{\beta}{\text{argmin}} \left\{ \frac{L}{2} \|\beta - \mathbf{z}_k\|_2^2 + g(\beta) \right\}$$

Pour la seule pénalité ℓ_1 , cet opérateur a une solution explicite, le seuillage doux (*soft-thresholding*) :

$$[\text{prox}_{\lambda_1/L, \|\cdot\|_1}(z)]_i = \text{sign}(z_i) \max(|z_i| - \lambda_1/L, 0)$$

qui annule progressivement les coefficients de faible amplitude, ce qui permet de sélectionner uniquement les mutations virales les plus associées au SNP étudié. En présence de la pénalité de fusion sur graphe, l'opérateur proximal combiné $\text{prox}_{g/L}$ n'a plus de forme close et est résolu par

Étape d'accélération. Enfin, FISTA ajoute une étape d'extrapolation de type Nesterov, en combinant les deux dernières estimations β_k et β_{k-1} :

$$\beta_k = \text{prox}_{g/L}(\mathbf{z}_k), \quad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \quad \mathbf{y}_{k+1} = \beta_k + \frac{t_k - 1}{t_{k+1}} (\beta_k - \beta_{k-1})$$

avec $t_1 = 1$ et $\mathbf{y}_1 = \beta_0$. Cette accélération permet d'obtenir une vitesse de convergence en $\mathcal{O}(1/k^2)$, contre $\mathcal{O}(1/k)$ pour l'algorithme ISTA classique (sans extrapolation), tout en conservant une implémentation relativement simple. Cette propriété est particulièrement intéressante dans notre contexte, où le modèle doit être estimé pour un très grand nombre de SNPs et de sites viraux.

Cependant, dans le contexte de très haute dimensionnalité des données, l'algorithme FISTA met un temps de calcul très long pour converger.

En effet, après avoir testé sur un sous-ensemble de données afin de pouvoir estimer le temps d'implémentation sur l'ensemble des données, on a pu constater un temps de calcul de plusieurs mois pour l'ensemble du jeu de données.

De plus, l'algorithme FISTA ne peut pas être parallélisé du à la dépendance entre les sites qui impose de calculer les coefficients simultanément.

Il est donc nécessaire de trouver une alternative à cette approche afin de pouvoir estimer le modèle sur l'ensemble des données.

4.2 Modèle avec effets aléatoires

Le modèle GFL présenté précédemment permet de prendre en compte la corrélation locale entre sites, mais uniquement via un graphe construit. Il ne modélise pas la structure globale de parenté génétique au sein des populations hôte et virale, pourtant décrite comme un facteur de confusion majeur dans les études d'interaction génome-à-génome [?]. Une approche alternative, largement utilisée dans les études d'association (GWAS) classiques, consiste à modéliser cette structure via des effets aléatoires, plutôt que par un nombre limité de composantes principales ou un graphe de corrélation. Cette stratégie a notamment été adaptée dans un contexte similaire par [?] au travers de la méthode ATOMM (*Adaptive Two-way Mixed Model*), qui introduit un effet aléatoire distinct pour l'hôte et pour le virus.

En reprenant cette idée, le modèle logistique s'écrit alors comme un modèle mixte linéaire généralisé (GLMM) à deux effets aléatoires :

$$\text{logit}(P(Y_i = 1)) = \beta_0 + W\alpha + X_j\beta_{ij} + \eta_v + \eta_h$$

où $W\alpha$ regroupe les effets fixes (covariables telles que l'âge ou le sexe), $X_j\beta_{ij}$ représente l'effet du SNP j sur le site viral i , et les deux effets aléatoires

$$\eta_v \sim \mathcal{N}(0, \sigma_v^2 K_v), \quad \eta_h \sim \mathcal{N}(0, \sigma_h^2 K_h)$$

capturent respectivement la structure de parenté génomique du virus et de l'hôte, via les matrices de parenté génomique K_v et K_h .

Contrairement aux composantes principales, ces matrices résument l'intégralité de la similarité génétique entre individus (ou souches), sans perte d'information liée à un nombre de dimensions fixé a priori.

Dans ce cadre, l'intérêt principal n'est plus seulement d'estimer les coefficients du modèle, mais de tester la significativité de l'association entre chaque SNP de l'hôte j et chaque site viral i , c'est-à-dire tester " $H_0 : \beta_{ij} = 0$ ". Or, ce test doit être répété pour un très grand nombre de paires SNP-site viral, et une estimation classique du modèle par maximum de vraisemblance nécessiterait de réinverser la matrice de covariance globale à chaque test, ce qui est numériquement impossible à l'échelle de nos données. Il est donc nécessaire d'utiliser une méthode d'estimation factorisée, qui sépare l'estimation des paramètres de nuisance (communs à tous les tests) de celle du test d'association lui-même : le test du score de Rao.

4.2.1 Estimation - Test du score de Rao

L'évaluation de chaque paires de variants (hôte, virus) implique d'ajuster le modèle mixte des millions de fois. Or, l'estimation des composantes de la variance (σ_v^2 , σ_h^2) par maximum de vraisemblance nécessite l'inversion répétée de matrices de grande dimension, ce qui représente un coût computationnel important. Les tests du score de Rao est implémenté dans le package *GMMAT* de **R**.

Concrètement, la procédure se déroule en deux étapes :

1. **Ajustement sous H_0** : On force le coefficient d'intérêt β_{ij} à 0. Le modèle nul ne contenant que l'intercept et les effets aléatoires. On ajuste le modèle une seule fois par phénotype viral pour estimer les paramètres de nuisance et les composantes de la variance.
2. **Calcul du score** : Pour chaque variant de l'hôte j , on évalue le gradient de la log-vraisemblance au point $\beta_{ij} = 0$. Si ce gradient est significativement éloigné de zéro, l'hypothèse nulle est rejetée, indiquant une association entre X_j et Y_i .




FIGURE 5 – Test du score de Rao

Cette méthode permet d'éviter le réajustement des effets aléatoires pour chaque SNP testé, réduisant ainsi drastiquement la complexité algorithmique tout en conservant une grande robustesse statistique.

La contre partie de ce test est qu'il ne fournit pas d'estimation directe de l'effet β_{ij} , mais uniquement une statistique de test et une p value associée. Cependant, dans le contexte d'une étude exploratoire visant à identifier des associations potentielles, cette limitation est acceptable. Néanmoins, pour les associations les plus prometteuses, il est possible de réajuster le modèle complet afin d'obtenir des estimations précises des effets et de leurs intervalles de confiance.

Il existe quand même des façons d'obtenir une estimation de l'effet β_{ij} à l'aide des p-values.

5 Résultats et discussion

5.1 Choix du codage

Le choix du codage des données du virus est un point qui a longtemps été discuté pendant ce stage. En effet, le codage initial des données est binaire : 0 pour l'absence de mutation et 1 pour la présence de mutation par rapport à la séquence de référence (majoritaire au jeu de donnée). Ceci afin de pouvoir garantir suffisamment de puissance statistique pour les tests d'association. Les sites viraux sont très variables puisque il est à ARN. Mais certains sites sont très conservés et ne présentent que très peu de mutations. Il est donc nécessaire dans un premier temps de filtrer les sites viraux afin de ne garder que ceux présentant une variabilité suffisante. Les sites viraux présentant une variabilité de moins de 5% ont été retirés du jeu de données.

A ce stade, plusieurs codages ont été envisagés pour le jeu de données du virus. Le codage initial binaire et un codage par transition d'acide aminé.

Avec le codage binaire, on ne prend pas en compte la nature de la mutation. On ne sait pas si la mutation est grave ou non. Puisque passer d'un acide aminé à un autre pourrait avoir un impact sur la structure de la protéine et donc sur son rôle pouvant induire des comportements différents du virus. Mais celui-ci présente l'avantage de pouvoir garder un maximum de sites viraux et donc de pouvoir garder une puissance statistique suffisante pour les tests d'association.

Au final, après filtrage des sites viraux, on a pu garder 427 sites viraux pour le codage binaire.

Avec le codage par transition d'acide aminé, on prend en compte la nature de la mutation. On encode les mutations par rapport à une matrice de substitution qui permet de savoir si la mutation est conservatrice ou non. Il s'agit de la matrice de Grantham. Mais celui-ci présente l'inconvénient de réduire le nombre de sites viraux et donc de réduire la puissance statistique pour les tests d'association. Ainsi, le fait de passer à un codage continu baisse le nombre de sites viraux et la précision des tests d'association.

5.2 Comparaison des modèles

5.3 Performances du modèle retenu

6 Conclusion et perspectives

7 Annexes

7.1 Annexe 1

8 Bibliographie